

阶段 1 PPN 验证网络 设计说明书

RAW 域 2DNR/3DNR 融合参数预测

2026 年 7 月 10 日

目录

1 阶段目标与 PPN 定位 2

2 前期准备：数据处理与算子仿真 2

2.1 RAW 数据规范化 2

2.2 加噪仿真 3

2.3 2DNR、3DNR 与 MD 的角色 3

2.4 训练数据包组织 3

3 数据表示与样本流动 4

3.1 Bayer 四平面表示 4

3.2 视频输入到门控输入 5

4 U-Net 验证网络结构 5

4.1 整体结构 6

4.2 编码器 6

4.3 瓶颈层 6

4.4 解码器与跳跃连接 6

4.5 Sigmoid 输出 7

5 PPN 门控融合机制 7

5.1 融合公式 7

5.2 控制语义 7

6 监督训练与验证方式 7

6.1 监督目标 8

6.2 训练策略 8

7 阶段 1 交付价值与范围说明 8

7.1 交付价值 8

7.2 阶段交付范围 9

8 结论 9

1 阶段目标与 PPN 定位

阶段 1 的核心任务不是直接训练一个端到端网络去替代完整 ISP，也不是让网络从 RAW 图像直接生成最终 sRGB 图像，而是验证一种更可控的 AI-ISP 协同方式：传统 RAW 域降噪模块继续承担明确的专家职责，AI 网络只负责预测融合参数。这样既保留了传统链路可解释、可拆解、便于调参的优点，又把最难人工设定的空间自适应控制问题交给数据驱动模型学习。

本文中的 PPN 指 Parameter Prediction Network，即参数预测网络。它的输出不是去噪后的图像，而是一张逐像素控制图。该控制图决定同一位置应更信任单帧空间降噪结果，还是更信任多帧时域降噪结果。换言之，PPN 是 2DNR 与 3DNR 之上的控制层，而不是新的独立降噪专家。

阶段 1 采用 U-Net 作为验证网络，主要原因有三点。第一，U-Net 的编码器-解码器结构可以同时获得局部边缘细节与较大范围上下文，适合判断运动边缘、静止背景和纹理区域。第二，跳跃连接能够保证输出控制图与 RAW 像素位置精确对齐。第三，结构足够轻量，便于在阶段 1 中高效验证数据处理、融合公式与监督方式。

本说明书聚焦阶段 1 的验证网络设计，说明 PPN 如何在 RAW 域预测两路降噪结果的融合参数，并形成可训练、可评价、可迁移到自采 RAW 视频数据的设计闭环。

2 前期准备：数据处理与算子仿真

2.1 RAW 数据规范化

PPN 的输入链路建立在 RAW-first 原则上。原始视频帧保持 Bayer mosaic 形式，不先做 demosaic，也不转到 RGB 或 YUV 域。这样可以避免颜色插值带来的额外伪影，并让 2DNR、3DNR 和 PPN 都在最接近传感器输出的线性信号上工作。

自采数据进入训练流程前，需要统一以下约束：

- **位深约束：**按传感器有效位深保存，例如 12 bit 信号可存放在 16 bit 容器中。
- **黑白电平约束：**记录或约定 black level 与 white level，用于归一化、加噪与指标计算。
- **CFA 相位约束：**裁剪起点和裁剪尺寸保持偶数，避免破坏 2×2 Bayer 单元相位。
- **时序约束：**同一 scene 内帧序号连续，保证前后帧差分具有真实运动意义。

这些约束使阶段验证数据和后续自建数据具有一致的工程接口。即使验证阶段采用标准 RAW 视频组织方式，后续只要自采裁剪数据满足相同 RAW 规范，就可以继续复用相同的专家算子输出和 PPN 训练流程。

2.2 加噪仿真

为了让网络学习真实 RAW 噪声下的融合策略，噪声视频不宜仅通过简单高斯噪声构造。更合理的方式是同时模拟信号相关噪声和信号无关噪声。设 I_{clean} 为干净 RAW， BL 为 black level， WL 为 white level，同 ISO 下的 dark frame 为 D_i ，则先估计暗场固定底纹：

$$DS_{\text{iso}} = \frac{1}{N} \sum_{i=1}^N D_i, \quad R_k = D_k - DS_{\text{iso}}.$$

其中 R_k 表示随机采样 dark frame 后去除平均底纹得到的暗场残差。再用 Poisson 分布模拟 shot noise，并叠加暗场残差：

$$I_{\text{noisy}} = \text{clip} \left(K \cdot \text{Poisson} \left(\frac{\max(I_{\text{clean}} - BL, 0)}{K} \right) + BL + R_k, 0, WL \right).$$

这里 K 可由 ISO 与系统增益近似确定。该噪声模型保留了 RAW 域中“信号越强，shot noise 方差越大”的物理特征，同时引入读出噪声、暗电流残差和固定模式噪声等成分，更适合构造 noisy-clean 配对训练数据。

2.3 2DNR、3DNR 与 MD 的角色

在网络训练前，noisy RAW 会离线经过 2DNR 与 3DNR 两条专家分支。两类专家的能力和 risk 不同，正是 PPN 需要学习融合控制的原因。

简单 MD 的核心可写为：

$$M_t = \sigma(20 \cdot G_\sigma(|X_t - X_{t-1}|) - 5),$$

其中 G_σ 表示空间高斯平滑， M_t 越接近 1 表示局部帧间变化越明显。传统手工融合可直接使用 M_t 构造 3DNR 权重，但这种方法依赖阈值和运动检测质量。PPN 的设计目标则是让网络从相邻帧特征中学习更灵活的门控图。

2.4 训练数据包组织

完成加噪和专家分支处理后，每个训练样本应包含：

- noisy RAW 序列，用于保留原始噪声和时序信息；
- 2DNR 输出序列，作为安全但可能残留噪声的空间专家；
- 3DNR 输出序列，作为强降噪但可能拖影的时域专家；
- clean 或高质量参考 RAW，作为监督目标；

表 1: 前置算子在 PPN 数据准备中的作用

算子	主要作用	对 PPN 的意义
2DNR	在单帧空间邻域内降噪, 常见实现包括双边滤波或 Bayer RAW 联合双边滤波。	运动区域更安全, 不会引入历史帧拖影; 但静止区域降噪上限有限。
3DNR	利用相邻帧或历史背景进行时域降噪。	静止区域可显著降低随机噪声; 但运动区域可能出现 ghosting 或边缘残留。
MD	根据相邻帧差异估计运动强度图。	帮助理解 2DNR/3DNR 何时切换, 也为样本检查与拖影分析提供参考。
加噪	将 clean RAW 构造成更接近传感器输出的 noisy RAW。	提供可监督训练所需的 noisy-clean 配对, 使网络看到真实噪声统计。

- 可选的 MD 结果或诊断图, 用于检查运动区域和拖影风险。

U-Net 验证网络本身主要从 2DNR 相邻帧平面构造门控输入, 2DNR 与 3DNR 则共同参与最终融合。这样做的好处是: 网络不需要从 noisy RAW 中重新学习完整降噪, 而是集中学习“何处该偏向哪一个专家”。

3 数据表示与样本流动

3.1 Bayer 四平面表示

输入 RAW 保持 Bayer mosaic 后, 可按 CFA 模式拆成四个子平面:

$$\mathcal{P} = \{R, G_1, G_2, B\}.$$

若原始 RAW 尺寸为 $H \times W$, 拆分后每个子平面尺寸为 $\frac{H}{2} \times \frac{W}{2}$ 。例如, 对于 GBGR 排布, 四个采样位置会按 2×2 单元映射到对应颜色平面。训练和验证阶段, 融合后的四个平面还会按原 CFA 相位重新拼回 Bayer mosaic, 用于计算 RAW 域损失和指标。

这种表示方式有两个优势。第一, 卷积不会把不同颜色采样点错误混合为普通灰度邻域。第二, 网络输出的门控图仍能对应 RAW 空间位置, 后续可以自然回到完整 Bayer 图。

3.2 视频输入到门控输入

验证链路接收正常连续 RAW 视频输入，而不依赖固定长度片段。设一段输入视频为：

$$\mathcal{V} = \{X_1, X_2, \dots, X_T\}.$$

网络在视频上按相邻帧滑窗构造门控输入。对选定门控平面 C ，第 t 帧对应的输入为：

$$Z_t = \text{concat} (D_{t-1,C}^{2D}, D_{t,C}^{2D}, D_{t,C}^{2D} - D_{t-1,C}^{2D}), \quad t = 2, \dots, T.$$

其中 $D_{t,C}^{2D}$ 表示 2DNR 输出在第 t 帧、颜色平面 C 上的图像。三通道分别表示前一帧、当前帧和差分图。前一帧提供时间参考，当前帧提供待控制内容，差分图突出运动和时序不一致区域。因此，输入可以是任意长度的真实视频；训练和验证只是在视频内部抽取相邻帧对来形成网络样本。

表 2: PPN 验证网络的主要张量流

阶段	张量形式	含义
RAW 输入	$H \times W$	单通道 Bayer mosaic。
CFA 拆分	$4 \times H/2 \times W/2$	分为 $R/G_1/G_2/B$ 四个子平面。
视频序列	$T \times H/2 \times W/2$	单一门控平面的连续视频帧。
门控输入	$(T-1) \times 3 \times H/2 \times W/2$	相邻帧滑窗，每组为前帧、当前帧、差分。
U-Net 输出	$(T-1) \times 1 \times H/2 \times W/2$	逐像素 2DNR 融合权重。
融合输出	$(T-1) \times 4 \times H/2 \times W/2$	四个 Bayer 平面的融合结果。
监督图像	$(T-1) \times H \times W$	重新拼回 mosaic 后与目标 RAW 计算损失。

自采裁剪数据进入该流程后，只要保持位深、CFA、裁剪相位和时序编号一致，网络看到的相邻帧差分就具有稳定含义。此时训练样本直接对应真实拍摄裁剪的 RAW 视频片段，门控图学习目标与视觉展示数据来源保持一致。

4 U-Net 验证网络结构

4.1 整体结构

PPN 验证网络采用两级下采样、两级上采样的轻量 U-Net。为避免与原始 RAW 尺寸混淆，本节用 $h \times w$ 表示拆分后的单个 Bayer 子平面尺寸，即 $h = H/2, w = W/2$ 。网络输入为 $[B, 3, h, w]$ ，输出为 $[B, 1, h, w]$ 。其中 B 可以理解为批量维度与时间帧对维度合并后的数量。




图 1: U-Net验证网络的数据流、上采样拼接与跳跃连接

4.2 编码器

第一层编码器将三通道输入映射为 C 个基础通道，并经过两次 3×3 卷积和 ReLU 激活。该层主要捕获局部边缘、噪声纹理和相邻帧差分中的细粒度变化。随后最大池化将空间分辨率降为一半。

第二层编码器将通道数提升到 $2C$ ，继续通过两次 3×3 卷积提取更抽象的区域特征。此时网络的感受野扩大，可以综合判断局部区域是稳定背景、运动物体、边缘过渡还是纹理噪声。

4.3 瓶颈层

瓶颈层在四分之一分辨率上把通道数提升到 $4C$ 。对于 PPN 来说，瓶颈层不是为了生成图像内容，而是为了完成区域级控制判断：哪些区域应更多使用时域信息，哪些区域应抑制历史帧贡献。较低分辨率的上下文有助于减少孤立噪点对门控图的干扰。

4.4 解码器与跳跃连接

解码器分两级恢复分辨率。第一次上采样后与第二层编码特征拼接，第二次上采样后与第一层编码特征拼接。跳跃连接的作用是把浅层空间细节重新引入门控预测，避免输出只保留粗区域判断。

最终权重图必须与 RAW 子平面逐像素对齐。如果运动边缘被过度平滑，3DNR 可能在边缘处留下拖影；如果静止纹理被误判为运动，融合结果又会失去 3DNR 的降噪收益。因此，U-Net 同时利用高层上下文和浅层细节，是验证阶段较合适的结构选择。

4.5 Sigmoid 输出

输出层使用 1×1 卷积将通道数压缩到 1，再经过 Sigmoid 得到连续门控图：

$$x_t = \sigma(\text{Conv}_{1 \times 1}(\Phi_t)), \quad x_t \in [0, 1].$$

其中 Φ_t 表示解码器输出的特征图。 x_t 不是图像亮度，也不是二值运动 mask，而是逐像素融合参数。连续权重比硬切换更稳定，可以在运动边缘、半透明拖影和弱纹理区域形成平滑过渡。

5 PPN 门控融合机制

5.1 融合公式

PPN 输出的权重图直接控制 2DNR 与 3DNR 的混合。对时间 t 、颜色平面 c 和像素位置 (i, j) ，融合公式为：

$$F_{t,c}(i, j) = x_t(i, j)D_{t,c}^{2D}(i, j) + (1 - x_t(i, j))D_{t,c}^{3D}(i, j).$$

其中 $D_{t,c}^{2D}$ 是 2DNR 结果， $D_{t,c}^{3D}$ 是 3DNR 结果， $F_{t,c}$ 是融合后的 RAW 子平面。 x_t 越接近 1，输出越偏向 2DNR； x_t 越接近 0，输出越偏向 3DNR。

5.2 控制语义

2DNR 和 3DNR 的互补性决定了门控图的学习目标。运动区域、物体边缘和帧间差异大的位置，应提高 x_t ，更多保留 2DNR，以减少 3DNR 的历史帧拖影。静止背景、纹理稳定区域和噪声主导区域，应降低 x_t ，更多利用 3DNR 的时域平均能力。

与手工融合相比，PPN 的关键优势在于融合参数不是固定公式直接给出，而是通过监督学习从数据中拟合。传统规则可以写为：

$$w_{3D} = \sigma((\tau - M_t)s),$$

其中 M_t 是运动图， τ 是阈值， s 是 Sigmoid 陡峭程度。这种方式清晰但依赖阈值调节。PPN 则把相邻帧结构交给 U-Net 处理，让网络学习更细致的空间权重分布，同时仍然保持“两个专家 + 一个控制器”的可解释框架。

6 监督训练与验证方式

6.1 监督目标

训练阶段，PPN 对连续视频中的相邻帧滑窗逐一预测门控图。若输入视频长度为 T ，则形成 $(T - 1)$ 张门控图，并分别作用到对应时刻 2DNR 和 3DNR 的四个 Bayer 平面。融合后的四平面会被重新拼回 mosaic：

$$F_t = \text{Mosaic}(F_{t,R}, F_{t,G_1}, F_{t,G_2}, F_{t,B}).$$

目标图像也以相同方式组织：

$$G_t = \text{Mosaic}(G_{t,R}, G_{t,G_1}, G_{t,G_2}, G_{t,B}).$$

训练损失采用 L1 重建误差：

$$\mathcal{L}_{\text{rec}} = \frac{1}{(T - 1)|\Omega|} \sum_{t=2}^T \sum_{(i,j) \in \Omega} |F_t(i,j) - G_t(i,j)|.$$

该损失直接约束最终融合 RAW 与目标 RAW 的像素级一致性。网络不需要人工标注“某个位置应该使用多少 2DNR”，而是通过融合误差反向学习合适的门控图。

6.2 训练策略

训练时按 scene 划分训练集与验证集，避免同一场景的相邻帧同时出现在训练和验证中造成信息泄露。训练数据还可以进行颜色平面排列增强，使网络在不同颜色平面和局部排列下学习更稳健的控制规律。

验证阶段，同时记录融合结果、2DNR 基线和 3DNR 基线相对于目标 RAW 的指标。PSNR 可写为：

$$\text{PSNR} = 10 \log_{10} \frac{\text{MAX}^2}{\text{MSE}}.$$

SSIM 用于辅助观察结构相似性。若 PPN 设计有效，融合结果不应简单退化为固定 2DNR 或固定 3DNR，而应在不同区域自适应继承二者优势。

7 阶段 1 交付价值与范围说明

7.1 交付价值

该 PPN 验证网络已经完成阶段 1 方法有效性的验证：在 RAW 域保留 2DNR 与 3DNR 两路专家结果，并由 U-Net 输出逐像素融合参数后，融合链路能够形成稳定、可监督、可评价的闭环。验证结果表明，AI 可以有效承担传统 RAW 域降噪链路中的控制器角色，而不是必须直接替代所有传统模块。

阶段 1 的交付价值不仅是一个网络结构图，而是一套可复用的方法闭环：RAW 数据规范化、专家结果生成、门控参数预测、RAW 域融合、监督训练和指标对比均已打通。这说明“AI 预测融合参数控制传统降噪分支”的路线具备工程可行性，也为后续在自采裁剪 RAW 视频数据上的训练、展示和迭代提供了稳定接口。

7.2 阶段交付范围

本说明书交付的是阶段 1 的 PPN 融合控制验证方案，重点在于证明参数预测网络能够有效控制 2DNR 与 3DNR 两路专家分支，并形成可训练、可验证、可迁移到真实自采数据的 RAW 域融合流程。完整 ISP 集成、部署级网络压缩、硬件适配和更复杂的时空特征设计属于后续阶段的工程展开内容，并不影响本阶段对方法有效性的验证结论。

换言之，阶段 1 已经完成的是“方法是否成立”的核心验证，而不是把所有系统工程问题一次性纳入同一份交付物中。本阶段产出的数据组织方式、门控网络、融合公式和监督训练方式，已经构成后续阶段继续扩展的基础；后续无论引入多平面输入、显式运动先验、时序一致性损失，还是替换为更强的轻量时空网络，都建立在本阶段已经验证成立的 PPN 控制思想之上。

8 结论

阶段 1 的 PPN 验证网络以 U-Net 为参数预测器，以 2DNR 和 3DNR 为专家分支，以逐像素门控图为控制变量，实现了 RAW 域空间降噪与时域降噪的自适应融合。该方案避免了端到端替代完整 ISP 的高复杂度，同时比手工运动阈值融合更具学习能力。通过合理的数据准备、专家结果缓存、CFA 保持、L1 监督和基线指标对比，该网络能够清晰验证“AI 控制传统降噪链路”的阶段 1 思路，并为后续自建 RAW 视频数据集上的训练和展示提供可复用框架。