

任务三设计思路

0.初步结果

计划研究一种直接处理原始 RAW 噪声图像的 Diffusion 降噪方法。模型输入是公司传感器输出的 noisy RAW，输出是恢复后的 RAW，不依赖公司的 2DNR、3DNR 或融合结果。

方法：

1. 使用 NAF 结构作为 Diffusion 网络，学习真实 RAW 图像的结构和细节先验；
2. 使用现有数据中的真实暗帧和静止色块的重复 RAW 帧建立传感器噪声分布，在推理时约束结果必须能够解释当前观测。

训练分为两个阶段。第一阶段使用之前拍摄的苹果 ProRes RAW 中相对干净的片段训练通用图像先验；第二阶段在公司没有 clean GT 的情况下，通过后验采样产生暂定样本，再进行无GT配对适配。因此，公司数据适配属于“无 GT 的无配对训练”，不是完全从零开始、只使用 noisy 数据的训练。

1. 问题背景

极低照度下，直接对 RAW 做普通卷积降噪会遇到三个问题：

1. 噪声不只是简单的高斯-泊松噪声；
2. 不同传感器、增益和曝光条件下噪声分布不同；
3. 公司数据没有对应的 clean RAW，无法直接使用普通监督学习。

因此，模型既要学习“图像中哪些结构是真实的”，又要判断“当前输出是否符合这台传感器的观测规律”。

2. 为什么考虑用 Diffusion

2.1 普通回归网络的局限

普通网络通常学习一个确定性映射：

noisy RAW → clean RAW

当噪声很强、信息已经丢失时，同一个 noisy 输入可能对应多个合理的 clean 结果。确定性网络容易采取平均策略，表现为：

- 细节变模糊；
- 暗部被过度平滑；
- 网络可能把噪声误认为纹理；
- 没有办法表达“这个区域有多不确定”。

2.2 Diffusion 的优势

Diffusion 不直接学习一次性输出 clean 图像，而是学习一个逐步去除随机噪声的过程：

高噪声状态 → 较少噪声状态 → ... → clean 估计

它适合本任务的原因是：

1. 可以逐步恢复结构，降低一次性回归造成的过度平滑；
2. 可以生成多个后验候选，观察恢复结果的不确定性；
3. 可以在每个采样步骤加入真实 RAW 的物理观测约束；
4. 先验和传感器噪声可以分开建模，便于分析失败原因。

Diffusion 不是自动解决噪声问题。它的效果依赖于训练先验和观测噪声模型是否匹配，因此本项目不使用“只靠网络生成一张看起来干净的图”的方式。

3. 总体方法

```
苹果 clean RAW
    ↓
按噪声模型合成训练数据
    ↓
训练单帧 NAF Diffusion 先验
    ↓
固定先验，对公司 noisy RAW 做后验采样
    ↓
使用后验样本进行 E/M 无 GT 适配
```

4. 网络架构

4.1 NAF U-Net

采用四次下采样的 NAF U-Net。每次下采样把空间尺寸缩小一半、增加通道数，使网络逐步从像素细节扩大到整块区域的结构；上采样阶段通过 skip connection 把高分辨率细节传回来。

```
4 通道输入
    ↓ 3×3 卷积
64 通道，分辨率 1 倍：2 个 NAFBlock
    ↓ 下采样
128 通道，分辨率 1/2：2 个 NAFBlock
    ↓ 下采样
256 通道，分辨率 1/4：2 个 NAFBlock
    ↓ 下采样
384 通道，分辨率 1/8：2 个 NAFBlock
    ↓ 下采样
512 通道，分辨率 1/16：瓶颈 NAFBlock
    ↓ 低分辨率空间长距离模块（可选 Transformer）
    ↓ 上采样并融合 skip connection
384 → 256 → 128 → 64 通道
    ↓ 3×3 卷积
4 通道噪声预测
```

每个尺度使用 2 个 NAFBlock，正式训练可根据显存增加到 3--4 个。

4.2 长距离建模模块

NAFBlock 已经有了通道注意力，但它主要通过局部卷积理解邻域。四次下采样后，特征图已经缩小到原图的 $1/16$ ，此时加入 1--2 个窗口 Transformer 或低分辨率空间注意力，可以让远距离区域交换信息，帮助处理大面积亮度变化、色块结构和暗部的整体一致性。注意力放在瓶颈处，计算量远小于在原始高分辨率图像上做全局注意力。

先使用低分辨率 Transformer 尝试；后续可将同一瓶颈模块尝试替换为二维 Mamba。

4.3 NAFBlock

每个 NAFBlock 包含：

1. 归一化，减少不同 RAW 强度范围带来的训练不稳定；
2. 1×1 卷积 扩展通道；
3. depthwise 3×3 卷积 提取局部空间信息；
4. SimpleGate，将两组特征逐元素相乘；
5. Simple Channel Attention（SCA）通道注意力，让网络判断哪些通道更重要；
6. 残差连接，保留输入中的真实结构。

4.4 Diffusion 时间条件

同一个网络需要处理不同噪声强度，因此时间步先经过正弦位置编码和 MLP，再注入每个 NAFBlock：

```
h = Norm(h)
h = (1 + gamma_t) * h + beta_t
```

噪声较小时，网络重点修复细微残留；噪声较大时，网络需要依靠更大范围的结构先验恢复内容。最外层不使用“输出加回 noisy 输入”的残差，保证网络输出严格表示 Diffusion 噪声 `epsilon`。

5. 噪声模型设计

5.1 为什么不把 Poisson-Gaussian 作为完整模型

Poisson 可以描述光子到达的随机性，但极暗 RAW 的完整噪声还包括：

- 暗电流和颜色相关的 DC 偏置；
- 重尾读出噪声；
- 行噪声、列噪声和 banding；
- 固定模式噪声；
- 量化误差；
- 饱和和下限裁剪；
- 不同像素和不同增益之间的相关性。

ELD 研究指出，简单异方差 Gaussian 不能解释极暗下的 banding；其更完整的模型分别处理 shot noise、重尾 read noise、color bias、row noise 和 quantization。ICCV 2021 的研究进一步显示，直接从真实传感器噪声 patch 采样可以更好地保留空间相关性。PNNP 则采用暗帧分解和可微 CDF/quantile loss 来学习复杂残差。

因此，本项目把 Poisson-Gaussian 只作为对照实验，不作为最终噪声模型。

5.2 当前采用的经验噪声模型

现有数据中已经有两类可用于噪声建模的校准数据：

- `mis20s1_calibrationdata/black/{100...25600}`：不同增益下的暗帧，每个条件有 50 个重复帧；
- `mis20s1_calibrationdata/color/{100...25600}`：静止色块校准视频在不同增益下的 RAW 帧，每个条件有 50 帧。不同增益是分段拍摄的，不能按相同帧号进行跨增益配对。

其中，`black` 是暗帧；`color` 是现有的有信号校准序列。

暗帧是模型的主要数据来源。它在三个位置被使用：

1. 计算固定暗场和帧级、行列级结构；
2. 从真实暗帧残差中采样噪声 patch，合成训练输入并保留空间相关性；
3. 用留出的暗帧残差建立经验 density，给后验采样提供观测约束。

暗帧先分解为：

$$\text{暗帧} = \text{固定暗场} + \text{帧级偏置} + \text{行/列结构} + \text{像素残差}$$

像素残差不强行拟合成 Gaussian，而是直接使用真实暗帧残差样本估计经验分布。第一版用 Laplace 核进行可微插值：

$$p_{\text{emp}}(r) = 1/N \sum_i \text{Laplace}(r - r_i; h)$$

Laplace 核只是从离散样本得到可微 density 的数值插值器，不代表传感器一定服从 Laplace 分布。

现有 `color` RAW 帧可以按每个增益分别建立信号相关的经验分布。由于不同增益是分段拍摄的，不能把不同增益的同一帧编号相减，也不能把它们当作严格同步视频。正确做法是在每个增益内部，用该段 50 帧的平均值作为该增益下的近似稳定信号，再统计这一段内部每帧相对平均值的残差，得到：

$$p_{\text{emp}}(\text{noise} \mid \text{gain}, \text{channel}, \text{observed signal})$$

由于现有 color 序列覆盖多个增益，第一版可以在各增益内部估计噪声，再比较不同增益的统计量。正式模型还应按 RAW 强度区间、通道和曝光参数分桶，避免把不同条件混成一个分布。

理想情况下还可以用不同亮度的平场重复帧建立：

$$p_{\text{emp}}(\text{noise} \mid \text{signal}, \text{gain}, \text{exposure}, \text{channel})$$

因为仅靠暗帧无法识别信号相关噪声。

因此，当前主方案是：暗帧按增益分别负责黑电平、固定模式和信号无关噪声；静止色块视频按增益分别估计有光条件下的噪声。其他运动、暗室和室外视频只用于场景验证，不能用于跨增益残差配对。新增采集只能作为后续提高标定覆盖范围的可选增强，不是本方案的必要条件。

5.3 完整噪声模型的后续方向

第一版不训练大型噪声生成网络，而是先用真实暗帧和静止色块残差完成数值闭环。完整方案可以按以下顺序升级：

阶段一：条件分位数网络

输入当前像素或小块的条件：

```
RAW 信号强度、增益、曝光、通道、行列位置
```

网络输出噪声分布的多个分位点，或输出噪声 CDF：

```
q_0.01, q_0.05, ..., q_0.99
```

训练目标使用真实暗帧和静止色块的残差分位数，而不是假设 Gaussian。这样可以表达偏置、重尾、banding 和不同增益下的分布变化。

阶段二：Conditional Normalizing Flow

在分位数网络验证稳定后，再使用条件 Normalizing Flow 学习：

```
p(noise | signal, gain, exposure, channel, position)
```

Flow 可以计算似然，也可以从指定条件下直接采样噪声，用于生成更真实的 noisy RAW。它比 GAN 更容易检查分布是否匹配，也比直接训练噪声 Diffusion 更适合当前数据规模。

阶段三：空间相关噪声模型

逐像素独立模型无法表达行噪声、列噪声和局部 banding。因此后续将把输入从单像素条件扩展为局部 RAW patch，并显式保留：

```
固定暗场 + 行列结构 + 帧级偏置 + patch 残差
```

模型输出一个有空间相关性的噪声块，而不是逐点独立采样。训练和验证仍然按增益分别进行，不能把不同增益的视频逐帧配对。

阶段四：与 Diffusion 后验结合

噪声模型成熟后，用它构造观测似然：

```
p(X | Y) ∝ p(Y | X, noise_model) p(X)
```

其中 NAF Diffusion 提供图像先验，条件噪声网络提供传感器约束。后验采样结果必须同时满足图像结构合理和能够解释真实 RAW 观测。

这四个阶段是完整设计方向；第一版只实现暗帧经验分布和可微 likelihood，不把后续网络写成已经完成的结果。

6. Loss 设计

6.1 Diffusion 先验损失

对近似 clean 的 x_0 随机加入标准高斯扩散噪声：

```
x_t = sqrt(alpha_bar_t) * x0
      + sqrt(1 - alpha_bar_t) * epsilon
```

网络学习预测 ϵ ：

```
L_diff = ||epsilon_theta(x_t, t) - epsilon||^2
```

这是第一版的主要训练损失。暂时不加入 GAN、感知或锐化损失，避免模型为了视觉锐利而生成虚假纹理。

6.2 观测约束损失

真实公司数据没有 clean GT，因此不能计算普通的 $||x - GT||$ 。对候选恢复结果 x ，使用经验噪声分布计算：

```
L_data(X) = -log p_emp(Y - X)
```

在后验采样中只使用它的梯度：

```
g_data = -∇X L_data(X)
```

这个梯度要求候选结果与真实观测之间的残差符合真实传感器噪声，而不是只追求网络先验中的“干净外观”。

6.3 E/M 适配损失

E 步得到后验候选 x_{hat} 后，M 步把它们作为暂定训练样本：

```
L_post = ||epsilon_theta(q(X_hat, t), t) - epsilon||^2
```

同时继续使用苹果数据防止模型遗忘原有结构先验：

```
L_clean = ||epsilon_theta(q(X_apple, t), t) - epsilon||^2
```

总损失为：

```
L_EM = 0.5 * L_post + 0.5 * L_clean
```

后验候选不是真实 GT，训练时停止其梯度，也不能把它们写成 clean 标签。

7. 如何进行无 GT 训练

7.1 先训练通用先验

公司数据没有 GT，但 Diffusion 不能完全没有先验。因此先使用苹果中相对干净的 RAW 片段训练图像结构先验：

1. 按完整视频片段划分训练集和验证集；
2. 降低 clean 素材的有效信号强度，覆盖极暗范围；
3. 使用目标传感器的经验噪声模型合成 noisy RAW；
4. 对 x_0 加 Diffusion 高斯噪声；
5. 用 L_{diff} 训练网络；
6. 在合成留出集上选择 checkpoint。

苹果素材只负责提供图像结构，传感器噪声由目标传感器的校准数据生成。

7.2 E 步：从公司 noisy RAW 产生后验候选

给定公司观测 y ：

1. 从高噪声 Diffusion 状态开始；
2. 网络预测当前状态中的高斯噪声；
3. 反推出当前 clean 估计 $\hat{x}$ ；
4. 计算经验噪声约束的梯度；
5. 用该梯度修正下一步采样；
6. 重复 50 个采样步；
7. 对同一输入生成 4 个候选。

这样得到的候选同时满足两个条件：图像结构符合先验，观测残差尽量符合真实传感器噪声。

7.3 M 步：使用候选更新先验

将 E 步候选当作暂定训练样本，但不把它们当作确定正确的 GT：

后验候选 50% + 苹果先验样本 50%

使用较小学习率更新 2000 次，然后重新执行 E 步。比较 0、1、2、3 轮适配，使用开发场景选择模型，最终测试场景不能参与调参。

这种方法是近似的 EM 风格无配对适配，不保证每轮都提升，也不能通过增加轮数掩盖错误的噪声模型。