视频去噪研究报告

方法探索、最终方案与多数据集泛化效果

肖纬杰　邸锦承

摘要

本报告记录 Stage2 RAW 视频去噪项目从公司数据适配、监督构建到跨传感器验证的研究过程。针对预训练教师在公司 RAW 上噪声与细节难以兼顾的问题，项目探索了两类方案：一类以 ExposureDiffusion 为基础，依次检查噪声建模、单帧适配、多帧与频域补偿、主干解冻，最后形成五帧输出残差候选；另一类直接微调 RViDeformer，并继续考察动态监督、传感器适配和推理融合。前一类方案虽降低了部分代理误差，但未取得稳定的细节恢复优势，未被采纳。最终采用方法 3：以 RViDeformer-L 为基座，混合真实跨增益样本与标定噪声合成样本，使用带有效区域掩码的重建、梯度和高通损失进行全参数微调，并固定第 5000 步的 EMA 权重用于推理。sc635hai 另保留方法 8 的专用可选输出头。

效果展示覆盖公司 MIS20S1、SC465SL、sc635hai 和 sc450ai 多个数据集与拍摄条件。方法 3 在 MIS20S1 645x 跨增益参考评测中达到 29.57 dB，在未参与训练的 1000x 原生参考评测中达到 53.27 dB；在未进行目标传感器训练的 SC465SL 和 sc635hai 静态序列上，零样本 PSNR 分别提升约 10.52–13.21 dB 和 13.59 dB。报告同时展示高增益动态及 sc450ai 的实际输出，按静态定量、动态观察和专用适配三种协议解释结果。正文依次介绍方法探索、最终方案和多数据集效果，附录集中列出采纳方案的训练超参数、损失、模型与推理配置。

关键词： RAW 视频去噪；RViDeformer；时域均值监督；跨传感器泛化；固定 ISP

目录

1 引言 **3**
1.1 项目起点与研究目标 . . . 3
1.2 研究过程与报告主线 . . . 3

2 相关工作与数据基础 **3**
2.1 技术背景 . . . 3
2.2 公司数据集与实验分工 . . . 4
2.3 RAW 适配与参考资格 . . . 4
2.4 评测口径 . . . 5

3 ExposureDiffusion 与多帧补偿的探索 **5**
3.1 起点：先让噪声模型与公司 RAW 对应起来 . . . 5
3.2 单帧适配：误差下降后，细节问题仍然存在 . . . 6
3.3 从五帧残差到特征与频域补偿 . . . 7
3.4 进一步检查监督与主干冻结的影响 . . . 8
3.5 回到清晰的输出残差：五帧候选的完整验证 . . . 8
3.6 从实际画面决定是否采用 . . . 10
3.7 未采纳的原因与 RViDeformer 路线的衔接 . . . 11

4 RViDeformer 微调与后续方案选择 **12**
4.1 方法 0 至方法 4：形成静态基线 . . . 12
4.2 方法 5 至方法 7：运动保真探索 . . . 12
4.3 方法 8 至方法 10：跨传感器适配与退化验证 . . . 13
4.4 方法 11：高增益推理门控 . . . 13
4.5 最终方案的确定 . . . 13

5 最终采纳的方法 **14**
5.1 整体流程 . . . 14
5.2 真实样本与静态监督构建 . . . 14
5.3 实测噪声合成与混合采样 . . . 14
5.4 网络与优化目标 . . . 15
5.5 训练、权重选定与完整画面推理 . . . 15
5.6 sc635hai 专用可选输出头 . . . 16

6 多数据集泛化效果展示 **16**
6.1 展示范围与分组 . . . 16
6.2 MIS20S1：训练覆盖增益与未见真实增益 . . . 16
6.3 SC465SL 与 sc635hai：跨传感器零样本静态泛化 . . . 17
6.4 sc635hai 专用输出头：适配域与动态保留集 . . . 20
6.5 室外、高增益和 sc450ai 数据集的实际输出 . . . 21

A 采纳方法的超参数与模型配置 **26**
A.1 权重与运行环境 . . . 26
A.2 方法 3 训练超参数 . . . 26
A.3 参考、归一化与损失设置 . . . 27
A.4 网络构造参数 . . . 28
A.5 噪声合成参数 . . . 29
A.6 推理、评测与固定 ISP 参数 . . . 30
A.7 方法 8 的 sc635hai 专用头完整配置 . . . 32
A.8 结果来源与复现入口 . . . 33

B 补充探索的记录与图表来源 **33**

1 引言

1.1 项目起点与研究目标

Stage1 使用预训练的 RViDeformer-L_CRVD 教师生成伪干净目标。在公司 MIS20S1 数据上，该教师对图卡细线、棋盘和文字边缘的处理偏软，影响了下游监督质量。Stage2 因而研究如何得到更适合公司数据的 RAW 去噪模型：既尝试以另一种预训练恢复主干替代教师，也直接适配已有的视频教师，目标都是兼顾噪声抑制与高频结构，并检查不同传感器、增益和运动条件下的表现。

项目没有公司数据的逐像素干净动态真值。可利用的资源是低增益静态序列、同场景不同增益拍摄、平场与黑帧标定，以及少量其他传感器的真实场景流。因此，研究首先需要解决监督从哪里来，再判断相应监督能够支撑哪些模型改动。

1.2 研究过程与报告主线

报告先讨论 ExposureDiffusion 路线：公司域适配带来可测改善后，为什么仍需要引入邻帧；多帧模块确实训练后，为什么还要检查信息接入位置、主干冻结和监督方式；最后又如何根据固定验证与实际画面决定不采用这一候选。由此引出直接优化 RViDeformer 时空主干与监督的方案选择。

RViDeformer 路线中，方法 0 至方法 4 依次完成数据适配、参考构建、噪声合成、模型微调和评估，形成方法 3。随后，动态内容被过度平滑的现象推动了方法 5 至方法 7 的运动保真探索；跨传感器测试引出了方法 8 至方法 10 的适配与退化建模；高增益动态预览又促成了方法 11 的置信门控实验。最终默认权重仍为方法 3 的第 5000 步 EMA，方法 8 仅保留 sc635hai 专用输出头。

两条路线的实际工作时间存在交叠，本文按问题与方案选择的逻辑组织，而非将章节顺序等同于实验日期。ExposureDiffusion 存档包含 9 月的噪声研究及 10 月 18–25 日的适配与补偿实验，方法 3 则已于 9 月 23 日完成验收。下文先写尝试与取舍，再详述采纳方法和多数据集效果；方法 0 至方法 11 沿用 RViDeformer 路线原编号，另一条路线用模型与实验名称区分。

2 相关工作与数据基础

2.1 技术背景

RAW 保留了传感器的线性响应和 Bayer 采样信息，适合在噪声统计层面建立恢复模型。CRVD/RViDeNet[1]、RViDeformer[2] 和 RVRT[3] 利用多帧信息进行恢复；HDR+[10]、Deep Burst Denoising[9] 与核预测方法 [17] 则体现了对齐和帧间融合对低照度成像的作用。EMVD[15]、FastDVDNet[16] 以及 DnCNN[14]、CBDNet[20] 提供了不同的时空恢复与真实噪声建模思路；NL-means[18] 和 BM3D[19] 是非局部恢复的经典参照。本项目采用官方 CRVD 权重初始化 RViDeformer-L，在公司数据上微调。

在缺少干净真值时，Noise2Noise[4] 依赖噪声观测之间的统计关系，Noise2Void[5] 与 Noise2Self[6] 通过盲点构造自监督。静态长序列还可利用时域均值降低随机噪声，但运动区域的

均值会混合不同时间的内容。项目据此将静态均值监督与动态探索分开处理，不把动态均值直接当作干净目标。

噪声标定以信号相关方差模型 [7] 为基础，并参考 RAW 数据合成的思路 [8]。实际生成器采用逐增益经验系数、通道相关高斯采样、固定图样偏置和量化。动态探针使用 DIS 光流 [11]。视觉比较在各自协议内冻结 ISP 参数；全数据集预览使用 Reinhard 色调映射 [12]，奇偶参考面板和专用头比较沿用原审计渲染。

2.2 公司数据集与实验分工

全数据集预览覆盖 4 种传感器的 45 条原始 RAW 流，其中 27 条为场景流、18 条为标定流。按传感器统计，MIS20S1 为 29 条（含 18 条标定），SC465SL 为 12 条，sc635hai 和 sc450ai 各 2 条。包含其他算法 2DNR/3DNR 处理的 03 组派生流不计入这 45 条。

表 1 采用 RViDeformer 主线的目录归类。ExposureDiffusion 交付包对其中 10 条型号未确认的 465 流保留 `465_unspecified` 标识，按 5 个开发域统计；其训练、验证及测试划分也单独制定，见第 3 节。同一条 RAW 在一条路线中留出，不意味着在另一条路线中也未参与训练。

表 1: 主要数据集、内容与实验用途。

数据集	内容	用途
MIS20S1 暗房	同场景 7 档增益，10x–1000x	10x 静态主参考；128x/313x/632x/645x 真实训练；1000x 真实增益留出
MIS20S1 室外	黄昏公园、人物运动，4 档增益	场景迁移与高增益动态展示
MIS20S1 标定	9 档平场、9 档黑帧，每流 50 帧	噪声拟合与合成验证；不作为场景泛化成绩
SC465SL 暗室	256x、2000x，各 300 帧	未参与方法 3 训练的跨传感器静态定量
SC465SL 超市与复杂纹理	增益梯子及 difficultpattern，共 10 流	多场景视觉与复杂纹理动态测试
sc635hai	131x 低色温 150 帧、16x 运动彩色 200 帧	方法 3 零样本测试；131x 另用于方法 8 适配，16x 保留
sc450ai	804x 灯光变化 150 帧、1435x 黑物运动 210 帧	跨传感器压力测试；1435x 不参与适配

2.3 RAW 适配与参考资格

不同数据源的位对齐、CFA 和黑电平并不统一。04 场景流和 05 组通常需要从高 12 位右移 4 位；02 组采用低位对齐。sc450ai 虽然附带说明写为高 12 位和 4128 DN 黑电平，实测却是低位对齐、有效 10 位，样本均落在 4 DN 格点，黑电平约 256–258 DN。若直接套用说明，会把有效信号裁掉。场景流以 RGGB 为主，标定流为 GRBG；所有数据经适配器转换到统一的 R/Gr/Gb/B 通道顺序。

黑电平逐流、逐通道测量；帧数从文件字节数核实。标称增益不作为网络输入条件，因为不同

档位伴随照明变化，实际噪声不随标签单调增加。例如暗房 128x 的分半绿色通道噪声约 79.05 DN，1000x 约 28.93 DN。噪声合成因此使用标定实测系数，而非只按场景文件名推断强度。

监督资格随数据而定。10x 低增益静态参考用于主方法训练；同流奇偶分半参考用于可信静态区域的测试或适配。旧教师输出、运动时域均值和盲点观测只作为对应探索的信号，不被登记为干净动态真值。

2.4 评测口径

静态评测在有效区域计算对应参考 DN 域的 PSNR、RMSE、高频保持率和残差。645x 使用映射到 10x 亮度的参考域，1000x 及跨传感器静态测试使用各自 native DN 域。跨传感器测试采用互斥奇偶帧池：偶数帧片段对奇数帧参考，再交换方向；只保留在全部、奇数、偶数帧池中均达到 90% 静态置信度的像素。运动筛选采用 $\text{median} + 3 \times 1.4826 \times \text{MAD}$ 的鲁棒阈值。

动态序列没有干净逐帧目标，报告其时序响应、高频与裁剪等诊断量，并结合固定 ISP 视频观察。高频比下降既可能来自去噪，也可能来自结构损失；temporal MAD 下降既可能表示抑制噪声，也可能表示运动被平均。因此，两者均与视觉结果一起解释。

所有同序列输入与输出共享白平衡和曝光，关闭 ISP 的 2DNR/3DNR。全数据集展示采用 edge-aware 去马赛克、高光重建和 Reinhard 映射。PSNR 在 RAW 域计算，展示视频用于观察降噪、纹理与运动；不同数据集的参考域和有效区域不同，绝对 PSNR 不作跨数据集排名。

以上静态参考指标用于 RViDeformer 主线。ExposureDiffusion 路线主要报告静态有噪参考与运动教师目标构成的代理误差，以及同帧固定显示参数下的视觉结果。该误差没有干净真值含义，不能换算为本报告静态参考表中的 PSNR，也不能把不同裁块、掩码和损失定义下的百分比相加。

3 ExposureDiffusion 与多帧补偿的探索

3.1 起点：先让噪声模型与公司 RAW 对应起来

这条路线尝试直接从含噪 RAW 得到去噪 RAW，以公司适配模型承担恢复任务，推理不依赖公司 2DNR 或 3DNR 输出。起初的问题是：除模型预训练域不同外，公司 RAW 的噪声、量化与固定图样是否也没有被正确表达？因此，存档中的早期工作先从噪声生成和观测模型展开。

单暗帧频谱方案以每档第一张暗帧建模，其余 49 张作检查。平均频谱与总体噪声量级接近真实数据，但高增益的稳定高频固定图样被部分随机化，合成的时间噪声标准差高出约 4%–7%。进一步检查还发现，暗帧存在 2 DN 码格及逐帧奇偶状态变化；此前按 1 DN 取整的分布距离不能继续使用。研究由此从“匹配一张暗帧的分布”推进到“区分固定图样、帧级偏置与随机残差”。

随后使用 40 张暗帧拟合多帧分解，并与剩余 10 张作同条件比较。以 25600 档为例，固定图样 RMSE 从单帧方案的 9.628 DN 降到 6.858 DN，时间标准差相对误差从 +6.63% 降到 +0.08%；但合并码值分布的 Wasserstein 距离从 0.194 DN 增到 0.236 DN。低增益也未表现出全面优势。这个结果促使评价从单一平均频谱转向固定结构、时间方差和码值分布的共同检查，不能仅凭一个指标决定噪声模型已经适用。

散粒噪声拟合也经历了修正：最初把约 83 毫秒暗帧的方差固定为不同曝光彩色帧的截距，后

来改用彩色重复帧对拟合，并在内部选择暗截距、非负截距或零截距。25600 档的末 5 对检查误差由 19.74% 降至 9.85%。不过，参与该检查的最低扣黑信号仍为 48 DN，高增益系数保留为暂定估计，不能直接把结果外推到近黑区。

存档还记录了泊松散粒项、高斯混合暗残差与量化区间概率组成的可微似然，以及静态背景的条件残差模型。量化似然修正了正态分布函数的重复缩放，并重新进行了九档拟合与暗帧留出检查；条件残差候选在同记录的时间、位置留出中得到最差逐通道方差相对误差 3.12%。这些工作提供了噪声统计证据，但暗场曝光与有光场景并不完全一致，尚不能据此宣称真实场景后验重建成功。七帧联合似然、DPS 与条件更新代码亦被保留，交付记录未提供可对应的完整七帧扩散去噪训练及效果结果。实际模型适配于是采用可核查的真实帧监督，未将这些候选合成器直接登记为最终训练退化。早期噪声记录与后续训练产物的来源分别列于附录 B。

进入多传感器开发后，又逐流检查位对齐、CFA、黑电平与信号相关方差。一次具体修正发生在运动掩码：若先把扣黑均值截为非负，黑电平增加 8 DN 会使最暗 465 流约 26.96% 的位置改判为静态；保留有符号统计均值、仅给最终方差设置正下限后，复核的最大分类变化降至 0.4349%。只有先把这类统计偏差厘清，静态有噪帧对才具有训练意义。

3.2 单帧适配：误差下降后，细节问题仍然存在

模型采用 ExposureDiffusion 的官方 SID 预训练 NAFNet 权重。主干包含四级编码器、12 个中间块和四级解码器，通道宽度从 16 增加到 256 再恢复到 16。每次前向接收 4 通道 RAW 状态及 4 通道光子条件，同一网络共享参数进行三次曝光递推，并保留泊松采样。这里的“三次”是递推次数，不是三帧输入；虚拟曝光比例 100 也不是传感器增益标签。

本路线的 45 条流被分为 20 条开发流、18 条标定流和 7 条 MIS20S1 暗房测试流。开发流包含 2 条 SC450AI、2 条 SC635HAI、2 条 SC465SL、4 条 MIS20S1 室外流及 10 条型号未确认的 465 流。每条开发流的前约 70% 用于训练，间隔 10 帧后使用尾段验证；输入、参考、引导与教师窗口均须完整落在所属区间。7 条暗房流不参与本路线的训练和权重选择，属于暗房序列留出；由于开发集也有 MIS20S1，且其他传感器可能拍摄相同室内布景，不能称为传感器型号与物理布景均未见过。

中心输入为 x_t，静态区使用独立有噪帧 x_{t+6} 作为目标；运动区使用冻结官方 CRVD 权重的八帧 RViDeformer 输出 T_t 作为软目标。定义 M_s 和 M_m 为静态、运动掩码，单次输出 z 的训练误差为

$$\mathcal{L}_{\mathrm{mix}}(z) = \mathrm{MSE}_{M_s}(z, x_{t+6}) + 0.5\,\mathrm{MSE}_{M_m}(z, T_t). \tag{1}$$

式中 x、T 与 z 均为扣除黑电平后按逐通道有效范围 $4095 - b_c$ 归一化的量，因此代理 MSE 为无量纲数值。两类误差分别按各自有效元素数归一化，空区域不贡献相应项；三次递推输出的损失再平均。七张独立引导帧只用于构造掩码，并非七帧网络输入。噪声归一化的时域变化用于区分静态、运动与忽略区，过亮及不可靠区域剔除。教师只参与训练监督和对照，推理无需教师。

单帧主干全参数适配 1000 步，使用 FP32、128×128 packed 裁块、batch size 32、AdamW、学习率 10^{-5}、零权重衰减及梯度裁剪 1。原固定 40 裁块的代理误差从 1.802499×10^{-4} 降至 1.602098×10^{-4}，下降 11.118%，最优权重在第 1000 步。公司域适配确实有效，但 128x 留出视频多个时刻的文字、线条和图卡仍偏软。这使下一轮实验不再只增加单帧训练，而是尝试让邻帧

提供中心帧中较弱的结构信息。

3.3 从五帧残差到特征与频域补偿

第一轮多帧尝试冻结公司单帧主干，增加 BIPNet 五帧 RAW 残差分支，用 $t-2$ 到 $t+2$ 补偿最终输出。新增分支约 667 万参数，从头训练 250 步。固定代理误差仅从 3.254105×10^{-4} 降至 3.253263×10^{-4}，下降 0.0259%。进一步将五帧替换为重复中心帧，第 60 帧输出的差异仅 0.002104 DN；多组画面中，残差能量的 74.8%–86.0% 可由常量通道偏移解释。网络虽产生了非零修正，却没有给出文字和分辨率卡恢复的明确证据。

这一诊断把问题从“是否需要更多参数”推进到“邻帧信息究竟在哪里进入、学到的是否为内容”。因此，后续分别尝试在第一次曝光递推中注入 TAP 对齐特征、在特征域加入 AdaIR 频域补偿，以及在输出域加入 ORNet 残差。TAP 从冻结主干抽取五帧 64 通道特征，经金字塔可变形对齐与融合后注入对应解码跳接；AdaIR 和 ORNet 这两项实际使用单帧信号，作为不同补偿机制的对照，不能都算作时序模型。

表 2: 不同补偿位置的实际试验。前三项共用混合代理误差基线 3.254105×10^{-4}；多尺度首步另用独立评测设置。

尝试	实际步数	最优代理误差	实验后的判断
TAP 首步特征注入	750	3.190954×10^{-4}，第 250 步	下降 1.941%，邻帧作用仍弱
AdaIR 频域补偿	750	3.157863×10^{-4}，第 750 步	下降 2.958%，视觉细节未形成稳定优势
ORNet 输出残差	750	3.214685×10^{-4}，第 750 步	下降 1.211%，与原输出总体接近
确定性首步、三级 TAP	750	单看 MSE 第 250 步略降	梯度项未通过，正式选择退回第 0 步

前三项在补充裁块中仍有小幅代理误差下降，但图卡和字牌的改善并不与数值同比例出现。逐递推诊断还发现，一个固定设置下第三步代理误差高于第一步，且泊松路径会影响比较。因此又尝试确定性首步恢复，并按 64、32、16 通道逐级增加 TAP 融合，各训练 250 步。第 250 步的 MSE 仅略降，梯度误差却升高；第 750 步 MSE 也回退。按“重建与梯度均不劣于基线”的规则，正式选择仍是未训练的第 0 步。

同时进行的无训练对照，在静态掩码内平均五帧 RAW 或五次去噪输出。在一个首步设置下，先平均五帧 RAW、再经冻结的单步 ExposureDiffusion 恢复，使代理 MSE 从 2.62842×10^{-4} 降至 1.68969×10^{-4}；但完整三步的另一设置没有同样结论。它说明重复观测中存在可利用信息，也说明简单平均及按帧数缩放散粒噪声不足以替代对运动、读出噪声与固定图样的处理。

3.4 进一步检查监督与主干冻结的影响

既然附加模块的收益较小，研究继续检查两种可能：冻结主干是否限制了新特征的使用；运动教师目标是否使模型更倾向于复现已有平滑结果。相应实验取消教师监督，只在可信静态区域使用真实帧对，并依次解冻解码器和完整主干。训练目标改为 $t+4, t+6, t+8$ 三帧平均，验证仍使用 $t+6$；评价采用静态 MSE、细节 MSE 与 0.25 倍梯度 MSE 之和。

表 3: 静态监督与主干更新实验。各行按自身起点比较，指标是组合目标，不是干净真值 PSNR。

尝试	训练与继承	起点 → 最优目标	相对下降
解码器与三级 TAP 联合训练	2500 步，最佳 2250 步	7.850996×10^{-4} $\rightarrow 7.588867 \times 10^{-4}$	3.339%
完整主干继续微调	继承上行最佳，再 2500 步	7.588867×10^{-4} $\rightarrow 7.446752 \times 10^{-4}$	1.873%
官方 TAP64 公司适配	独立预训练初始化，1500 步	7.635421×10^{-4} $\rightarrow 7.352122 \times 10^{-4}$	3.710%

联合解码器训练后，真实五帧与重复中心帧的验证输出差异达到约 9.31 DN，说明模型开始明显使用邻帧。然而，局部玩偶与纹理仍偏软，输出差异本身不能证明真实结构已经恢复。独立的官方 TAP64 预训练对照在部分局部更清楚，也提示预训练表征和完整视频主干值得重视。上述结果没有把 ExposureDiffusion 改造方案推到可稳定替代原教师的程度，因此保留为探索记录。

3.5 回到清晰的输出残差：五帧候选的完整验证

后续实现曾组合 TAP 对齐、DarkIR 模块与 FrENet 频域模块，通过内部钩子注入特征。服务器准备快照记录的仍是未更新状态，迁移说明另记录该组合版本曾试训 20 步；这些机械检查不能计作有效效果结论。最终候选在交付代码中标为 V3，删除内部注入与复杂组合，恢复完整冻结的三步 ExposureDiffusion，在最终 RAW 输出处叠加一条五帧残差分支：

$$\widehat{y}_t = B(x_t) + R_\theta(x_{t-2:t+2}, \eta), \tag{2}$$

其中 B 为公司适配单帧主干，η 为噪声条件。残差分支共享卷积提取 16、32、64 通道的三级特征，用 TAP 的金字塔对齐与融合组件汇聚五帧，再生成 4 通道 RAW 修正。输出层零初始化，使训练起点等于冻结主干；分支约 70 万参数，全模型约 760 万参数。它不把固定高通结果强行加回画面，推理也不需要教师或参考帧。

这一版本继续使用式 (1)，只约束最终输出。五帧输入与 $t+6$ 目标互不重叠，8 张独立引导帧负责掩码，静态区域还需通过更保守的局部一致性检查。实际训练为 FP32、192×192 packed 裁块、batch size 2、梯度累积 4、有效 batch 8；AdamW 学习率 10^{-4}、权重衰减 0、梯度裁剪 1，共 5000 次优化器更新。固定验证每条开发流取 1 个裁块，共 20 个，先在域内汇总，再对 5 个开发域等权平均，每 100 步验证一次。

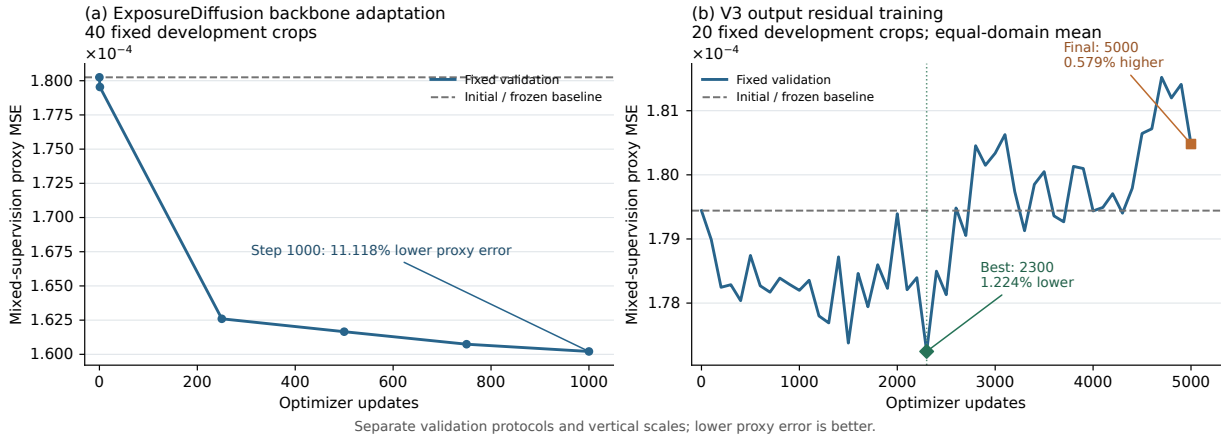


图 1: 单帧适配与五帧输出补偿的固定验证曲线。左图使用单帧阶段的 40 裁块；右图使用五帧阶段的 20 裁块及等域汇总。两图各自比较训练前后的代理误差，不能直接比较绝对值或累加下降比例。五帧候选在第 2300 步最佳，继续训练至 5000 步后反而高于冻结基线。

如图 1，五帧阶段的冻结基线为 1.794418×10^{-4}，第 2300 步降至 1.772457×10^{-4}，下降 1.224%；第 5000 步升至 1.804805×10^{-4}，比基线高 0.579%。因此，在额外测试前已固定第 2300 步为本路线候选，第 5000 步仅作训练终点对照。它与单帧适配的 11.118% 使用不同验证设置，不能合成为总改善比例。

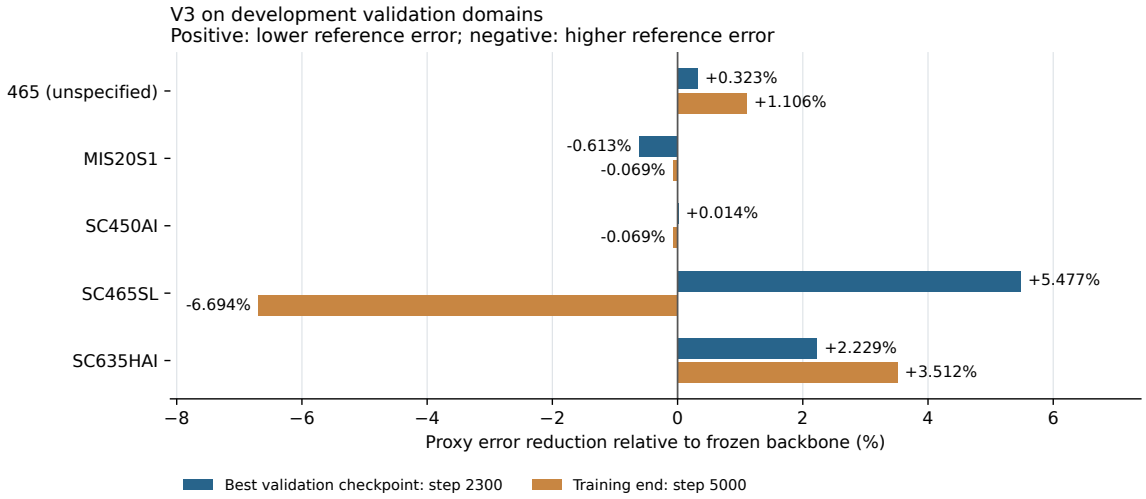


图 2: 五帧候选的分域固定验证。正值表示代理误差相对冻结单帧基准下降。所有域均在开发训练中出现，属于同域时间留出；465 型号未确认的 10 条流独立统计。改善随数据域和训练阶段改变，没有形成各域一致的优势。

分域结果进一步解释了为什么总体数字不足以支持采用。第 2300 步在 SC465SL 和 SC635HAI 分别下降 5.477% 和 2.229%，MIS20S1 却增加 0.613%；到第 5000 步，SC465SL 又变为增加 6.694%。复查固定裁块发现，SC465SL 其中一个裁块只有 2 个有效运动位置，SC635HAI 其中一个只有 1 个。由于静态和运动误差分别归一化，这些少量位置仍承担 0.5 倍运动项权重，代理误差会对局部教师目标很敏感。这里的位置指 packed Bayer 空间位置，并在四通道上计算损失。

补充实验在相同开发视频中另取两组 20 裁块，第 2300 步分别改善 0.352% 和 0.931%，第 5000 步反而改善 0.807% 和 2.283%。这些是裁块位置种子的变化，不是新数据集或独立训练重复，也没有据此重选权重。邻帧诊断中，第 2300 步将真实五帧换为重复中心帧，输出差异 RMS 的中位数仅 0.0134 DN；反转邻帧顺序为 0.00834 DN，而残差 RMS 的中位数为 0.880 DN。三项均先在显示 ISP 前的 12 位 DN 域逐裁块计算 RMS，再取 20 裁块的中位数。综合起来，候选确有小幅统计收益，但其排序受裁块构成影响，最佳候选的邻帧作用也较弱，仍需回到实际画面判断结构改善。

3.6 从实际画面决定是否采用

交付结果覆盖 27 条场景流的 165 个同帧案例：20 条开发流各 3 帧，共 60 例；7 条暗房留出流各 15 帧，共 105 例。每例保留输入、官方 RViDeformer、公司单帧基准、第 2300 步候选和第 5000 步终点。全图与局部面板只是同一案例的不同展示，不另计样本数。下列四列均使用逐流固定的白平衡与亮度映射，展示参数从该流首个展示输入帧确定；它们没有干净真值。

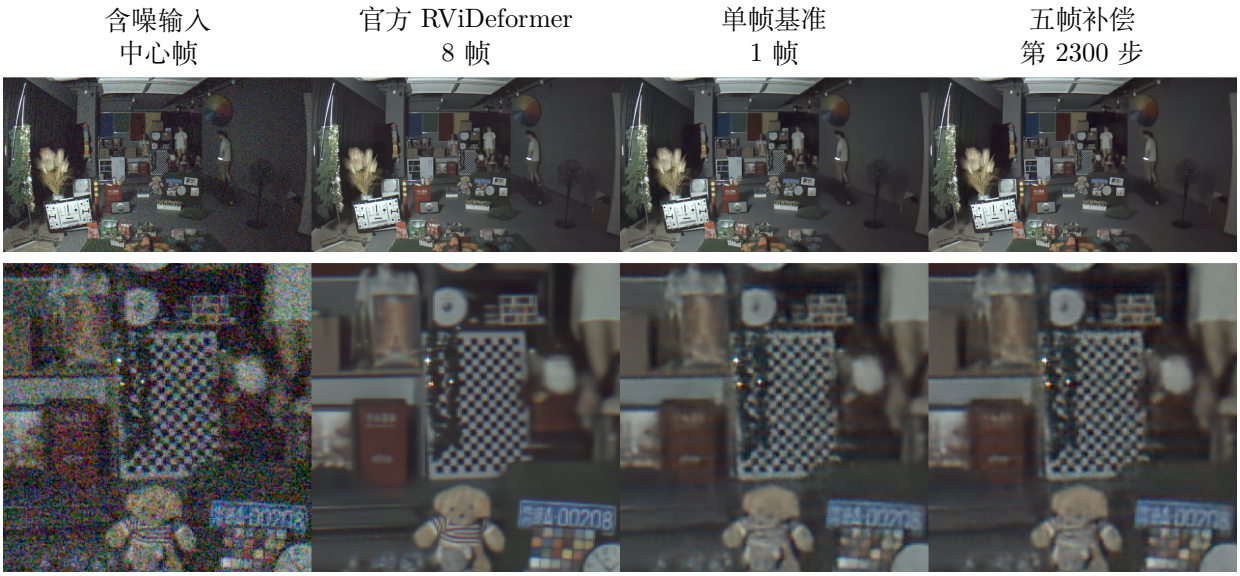


图 3: MIS20S1 暗房 1000x 序列第 99 帧：全图与同位置局部。该序列未参加本路线训练及选权重。四列依次为输入、官方 CRVD 权重的八帧 RViDeformer、公司单帧基准、五帧输出补偿第 2300 步。后两列总体接近，棋盘格和玩偶衣物条纹在官方 RViDeformer 输出中更易辨认。此处的 RViDeformer 是冻结官方参照，并非后文方法 3 微调权重。

图 3 体现了这条路线最直接的取舍依据：单帧适配与残差补偿都能压低噪声，但在高噪声图卡和玩偶区域，五帧候选仍接近单帧基准，未显示出足够明确的细节恢复。官方 RViDeformer 虽然也存在平滑问题，在此样本中仍保留了更可辨的结构。这不是等参数或等帧数消融，而是项目能否用当前候选替换现有视频教师的实际对照。

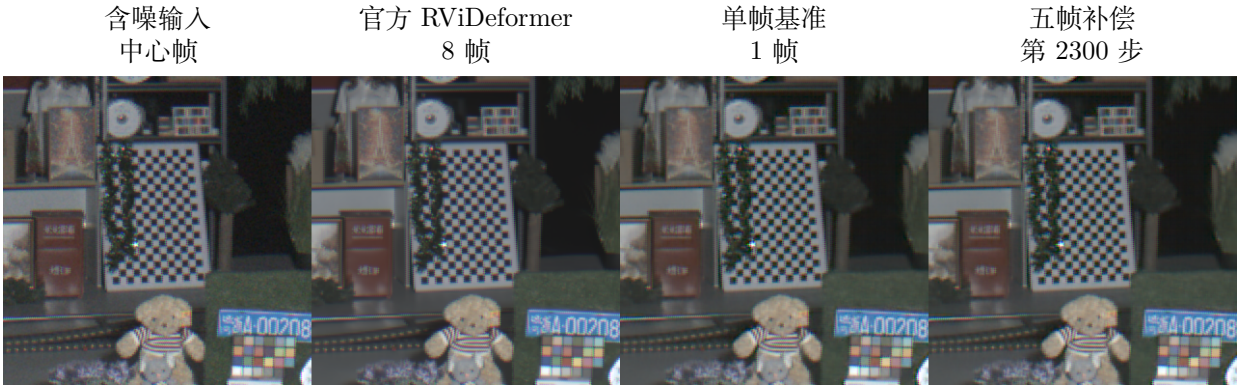


图 4: MIS20S1 暗房 10x 序列第 8 帧，列顺序同图 3。该流亦为本路线留出。低噪输入原本含有较清楚的结构，模型间差异小于 1000x 样本，五帧补偿仍未呈现普遍、清晰的细节增益。该流在后文方法 3 中用于构建参考，数据身份随路线分别记录。

低噪留出样本和开发域尾段用于检查上述判断是否只来自最难样本。图 4 中差别整体较小；图 5 中，SC450AI 人物与 SC635HAI 图卡的五帧输出仍与单帧基准接近。分域代理误差下降并不意味着每个实际局部都获得可见收益。这批静帧也不提供连续视频闪烁或重影改善的结论。

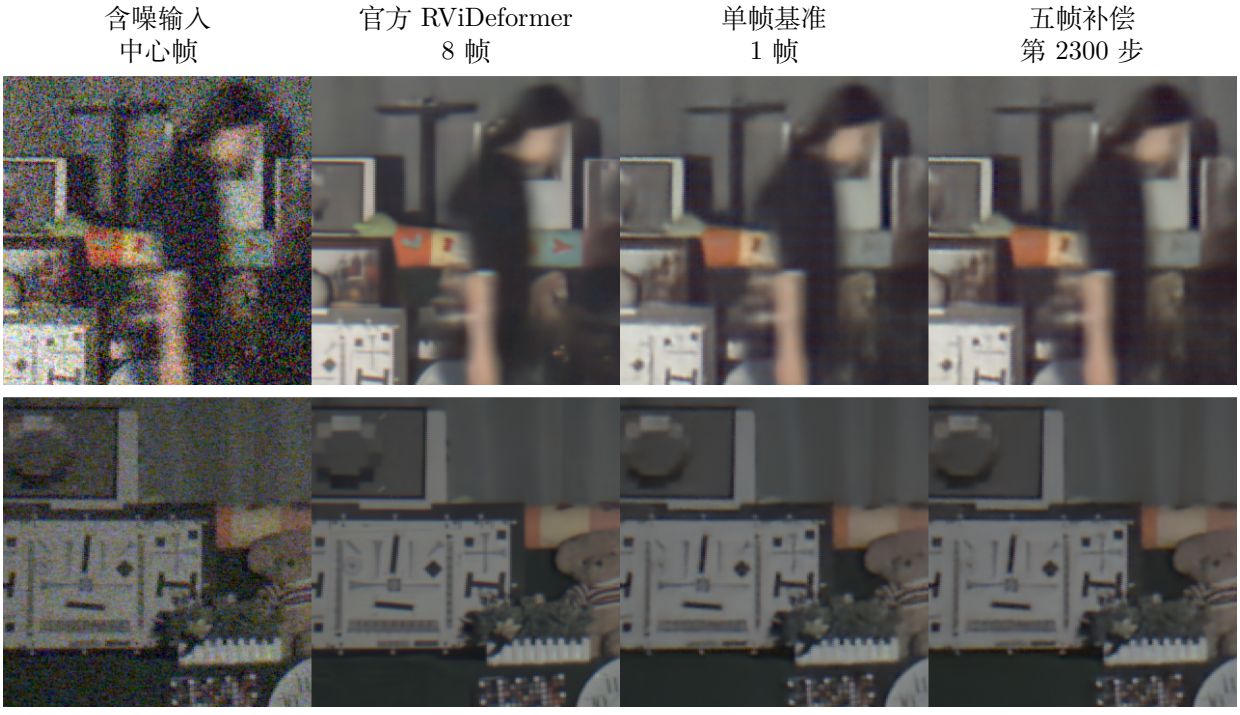


图 5: 开发域的时间留出画面：上为 SC450AI 灯光变化 804x 序列第 132 帧，下为 SC635HAI 低色温 131x 序列第 132 帧。四列仍为输入、官方 RViDeformer、单帧基准和五帧第 2300 步候选。两流的前段参与训练，图示尾段属于验证，不能称为新传感器零样本结果。

3.7 未采纳的原因与 RViDeformer 路线的衔接

这条探索并非所有环节都无效：公司单帧适配明显降低了原固定代理误差，部分补偿和解冻实验也产生了可测收益。但项目需要的是可稳定替换现有教师的 RAW 视频恢复结果。经过多种

信息接入位置、监督方式和更新范围的尝试，最后五帧候选的整体增益仍小，随域和裁块变化，真实图卡与纹理也没有建立稳定优势。因此，在本项目已有数据和已完成实验范围内，这条改造路线未达到采用要求，最终不作为 Stage2 默认方案。

这些实验给方案选择带来的启发是明确的：单纯增加外围补偿模块，并不能保证网络利用邻帧恢复真实结构；而在实际对照中，已有视频教师仍体现出可用的时空表征。报告由此转入另一条路线：直接把 RViDeformer 本身作为优化对象，同时用可信的静态时域参考和实测噪声构造监督，让公司域适配发生在完整时空主干内。下一节说明这一方案如何形成方法 3，以及为什么后续尝试最终仍保留它。

4 RViDeformer 微调与后续方案选择

4.1 方法 0 至方法 4：形成静态基线

方法 0 建立逐流适配、配准、曝光映射与运动掩码。方法 1 用暗房 10x 的 200 帧构建静态参考，奇偶均值残差为 0.51–0.80 DN，曝光归一化后的跨增益偏差为 1.17–1.86 DN。方法 2 利用平场和黑帧生成 9 档合成噪声，最大逐通道统计误差 8.66%，低于 15% 验收阈值。上述准备共同支撑方法 3 的混合数据微调，方法 4 负责评估。

评估中出现过一次口径修正：1000x 与 10x 跨捕获曝光关系在高亮处偏离线性，同一模型按该映射仅有 18.84 dB；配准复核后，改用 1000x 自身的静态参考得到 53.27 dB，奇偶互斥验证为 53.10/53.07 dB。该结果使项目保留方法 3，并将跨捕获映射与模型误差分开检查。方法 3 的监督、损失和推理流程在第 5 节统一说明。

4.2 方法 5 至方法 7：运动保真探索

方法 3 的静态去噪改善后，645x 视频中的运动人物仍有半透明残影。原运动审计中，输出的运动区帧差仅为输入的 27%–32%。这推动了三条后续路线，比较时均要求运动响应改善且静态、原生增益及高频指标不回退。

表 4: 运动保真路线的简要比较。

方法	设计	主要结果	取舍
方法 5	光流对齐的动态 N2N；教师静态锚；冻结范围与损失权重实验	收紧运动置信规则后覆盖仅 1.81%–3.82%；多组候选未同时通过运动、静态和 1000x 门槛	未采纳
方法 6	冻结方法 3，训练空间残差运动专家；共 4 版	门控 IoU 达 0.533，但真实动态内容未稳定恢复；更强残差伴随静态偏移或目标误差增大	未采纳
方法 7	在运动区融合旧教师残差，扫描 36 组配置	最强配置的运动比相对增加 0.9162%；固定 ISP 未见稳定的人物轮廓改善	未采纳

方法 5 用 DIS 光流将后帧对齐到当前帧，以前后向误差和光度误差筛选可信像素。增加严格

的 1 像素运动门槛后，监督覆盖明显缩小。方法 6 转而冻结主干，减少全模型漂移；方法 7 再取消训练，检验旧教师残差是否能直接补充运动信息。三者依次减少了参数更新带来的影响，但在既定数据与验收条件下，均未得到足以替换基线的结果。

因此，后续实验继续保留方法 3，研究重心转向跨传感器：先测同一权重在哪些数据域有效，再决定是否需要目标域适配。

4.3 方法 8 至方法 10：跨传感器适配与退化验证

零样本测试表明，方法 3 在 SC465SL 暗室和 sc635hai 低色温静态域有明显降噪收益，而 sc450ai 黑色运动物体仍明显发软。方法 8 据此考察逐传感器适配：sc635hai 使用奇偶静态监督，sc450ai 使用单帧盲点监督，均混入 MIS20S1 回放。结果仅保留 sc635hai 的专用输出头，详细配置见第 5.6 节；sc450ai 的 5 个检查点均没有恢复高频，1435x 端点裁剪还从 3.28% 升至 4.64%。

方法 9 尝试统一微调 4 种传感器，只更新 15,508 个参数、训练 100 步。SC465SL 和 sc635hai 静态指标略升，但 sc450ai 的高频比由 0.126621 降至 0.126589，未改善黑衣与运动轮廓，故没有作为统一模型采纳。

方法 10 随后检查 sc450ai 的监督来源。现有数据只有两条动态场景流，没有独立暗场、平场或干净 RAW 配对。其补充退化实验比较了原独立噪声、4 DN 量化独立噪声和频谱整形噪声；频谱整形虽改善 804x 的聚合相关误差，却未通过逐通道噪声与 1435x 保留集验证。该生成器未进入最终方法。

这组实验使最终方案保持清晰：默认使用同一方法 3 权重评测泛化，仅给 sc635hai 保留一个专用可选头。目标域的零样本结果与专用适配结果分别报告。

4.4 方法 11：高增益推理门控

全数据集预览显示，MIS20S1 室外 1500x 等序列仍有运动朦胧。四路诊断比较原始输入、正常时域推理、加权空间拼接和单帧重复 8 次的推理：改变拼接权重对主体影响很小，单帧重复则恢复了更多当前帧结构，同时带回明显彩噪。这些观察支持将时域融合视为该现象的重要来源。

方法 11 尝试用输入残差、梯度和光流置信度，在正常时域输出与单帧重复输出之间融合。两条代表序列的非零门控覆盖仅 0.487% 和 0.713%，全局输出接近原时域分支，逐帧观察也未见稳定的主体重影改善，因此未纳入最终推理流程。

4.5 最终方案的确定

从 ExposureDiffusion 替代方案到 RViDeformer 直接微调，再到运动与传感器专项实验，研究逐步区分了代理误差下降、实际结构恢复与跨域可用性。最终保留的方法 3 具有完整的监督与评测记录，静态恢复结果稳定；其余默认替代候选未在各自目标上满足采用条件。方法 8 的 sc635hai 输出头以专用可选权重单独保留。接下来围绕这两项说明最终实现，并将其效果统一放到多数据集测试中展示。

5 最终采纳的方法

5.1 整体流程

默认方法由四个环节组成：RAW 适配、可信静态监督、真实与合成混合训练、EMA 多帧推理。方法 0 至方法 2 提供的数据处理和监督构造均属于方法 3 的完整训练管线。

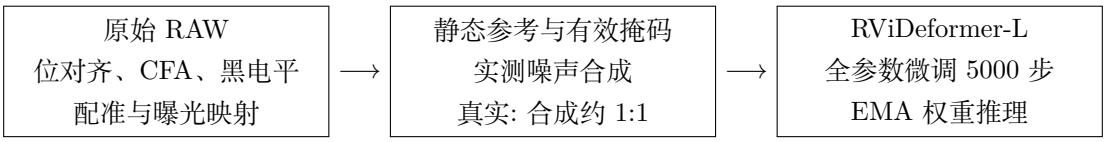


图 6: 最终方法 3 的完整流程。训练数据进入统一参考域；输出在对应协议的参考 DN 域评测，再使用该协议的固定 ISP 展示。

模型输入为 8 帧、4 通道的 packed Bayer，输出对应的 8 帧。训练采用 64×64 packed patch，即原 Bayer 的 128×128 区域；推理通过重叠分块处理完整画面。方法 3 不增加增益标签输入或传感器条件分支。

5.2 真实样本与静态监督构建

主参考来自 MIS20S1 暗房 10x 序列的 200 帧平均。参考构建包含固定图样修正，并记录运动及无效区域。参考形状为 $4 \times 540 \times 960$。奇偶分半残差在 R/Gr/Gb/B 上分别为 0.511、0.797、0.763 和 0.560 DN；图卡高频检查确认平均后仍保留可用结构。

真实输入选用 128x、313x、632x 和 645x。对每个输入增益，先读取其位对齐、黑电平和运动记录，再使用整数配准及逐通道仿射曝光映射进入主参考坐标和亮度域。设映射后的像素为 x_c，参考黑电平为 b_c，归一化为

$$\widetilde{x}_c = \mathrm{clip}\left(\frac{x_c - b_c}{4095 - b_c}, 0, 1\right). \tag{3}$$

目标为相同位置的静态参考，在 8 个时间位置上重复。

有效掩码同时满足参考有效、输入 8 帧均为静态、全部输入通道均未饱和。饱和阈值为映射域 3800 DN，运动掩码阈值为 0.5。只有这些位置参与损失，避免对错位运动和饱和内容施加静态均值目标。1000x 真实序列不进入训练。

5.3 实测噪声合成与混合采样

合成分支仍以同一静态参考为干净目标，通过 9 档平场与黑帧建立噪声模型。信号相关方差可写为

$$\sigma_c^2(s, G) = a_c\, sG + b_c^{\mathrm{read}} G^2. \tag{4}$$

实际生成器保留了每档增益的经验 shot 系数 $\alpha_{c,g}$ 和 read variance $v_{c,g}$，用于处理标定中的非单调变化。令 d 为固定图样偏置，$z \sim \mathcal{N}(0, I)$，$LL^\top = C$ 为聚合通道相关矩阵的 Cholesky 分解，则

合成为

$$q = y + d, \qquad s_c = \max(q_c - b_c, 0), \tag{5}$$

$$x^{\text{syn}} = \text{clip}\left(\text{round}\left[q + \sqrt{\alpha_g \odot s + v_g} \odot (Lz)\right], 0, 4095\right). \tag{6}$$

该实现使用相关高斯采样匹配信号相关方差。合成后按 1 DN 格点量化，保留原始黑电平与合法范围。

合成增益标签为 100、200、400、800、1600、3200、6400、12800 和 25600，每档生成 8 个独立噪声时序变体。8 帧具有相同干净内容和不同噪声，真实与合成分支按约 1:1 混合。真实性检验比较合成与真实同档数据的高通差分噪声，最大逐通道相对误差 8.66%，通过 15% 阈值。逐档参数列于附录。

5.4 网络与优化目标

网络采用 RViDeformer-L，严格加载官方 CRVD 权重后全参数微调。构造配置包含 11 组深度参数，前 7 组深度为 4、嵌入维度 84，后 4 组深度为 2、嵌入维度 108；注意力头数均为 6，时空窗口为 $6 \times 8 \times 8$。重建使用浅层特征残差连接，最终卷积输出再与输入 RAW 相加。实际模型共有 7,505,716 个可训练参数。完整构造参数见表 11。

训练先将预测裁剪到 $[0, 1]$，再计算带掩码的损失。记

$$\langle z \rangle_M = \frac{\sum M \odot z}{\max(\sum M, 1)}, \tag{7}$$

其中掩码沿通道维展开。总损失为

$$\mathcal{L} = \mathcal{L}_{\text{char}} + 0.1\mathcal{L}_{\text{grad}} + 0.1\mathcal{L}_{\text{hp}}. \tag{8}$$

Charbonnier 项 [13] 约束重建误差：

$$\mathcal{L}_{\text{char}} = \left\langle \sqrt{(\hat{y} - y)^2 + 10^{-6}} \right\rangle_M. \tag{9}$$

若写为 ϵ^2，则 $\epsilon = 10^{-3}$。梯度项约束水平、垂直梯度的幅值差：

$$\mathcal{L}_{\text{grad}} = \tfrac{1}{2}\left(\langle ||D_x\hat{y}| - |D_x y|| \rangle_{M_x} + \langle ||D_y\hat{y}| - |D_y y|| \rangle_{M_y}\right), \tag{10}$$

其中 M_x, M_y 是相邻有效掩码的乘积。高通项为

$$H(u) = u - \text{AvgPool}_{3\times3}(u), \qquad \mathcal{L}_{\text{hp}} = \langle |H(\hat{y}) - H(y)| \rangle_M. \tag{11}$$

高通仅在空间计算，不跨时间平均。重建项负责整体恢复，两个 0.1 权重的结构项补充边缘和局部高频约束。

5.5 训练、权重选定与完整画面推理

方法 3 使用 batch size 1、固定学习率 10^{-4} 的 Adam，以 FP32 完成总计 5000 步训练。训练从第 200 步恢复至第 5000 步；总步数不额外累加。EMA 衰减为 0.999，逐优化步更新。最终固定第 5000 步 EMA，后续探索和多数据集测试均使用该权重作为默认模型。

完整画面推理采用 8 帧时间窗口、时间步长 4，空间 tile 为 64×64 packed、步长 56。空间和时间重叠处等权平均；不足 8 帧时重复末帧补齐。输出归一化裁剪后，按相应评测管线恢复 DN 值。分块批大小仅影响一次并行处理多少 tile，不改变训练 batch size。

5.6 sc635hai 专用可选输出头

方法 8 在方法 3 EMA 基础上冻结主干，仅更新 `norm`、`conv_after_body` 和 `conv_last`，共 6 个张量、12,400 个参数。对应头部由 108 维 LayerNorm、$108 \to 84$ 线性映射及 $84 \to 4$、核为 $1 \times 3 \times 3$ 的卷积组成。

适配使用 sc635hai 131x 低色温序列，奇偶输入与参考帧池互斥；以 0.5 概率混入 MIS20S1 回放，减少原域漂移。batch size 为 1、学习率 10^{-5}、训练 500 步，采用 BF16 autocast、FP32 损失和 0.999 EMA；梯度范数裁剪为 1.0。实际 500 步中，sc635hai 采样 238 步，回放 262 步。16x 运动彩色序列完整保留，不参与反向传播。

该输出头通过既定自动检查并被登记为 sc635hai 专用可选权重；默认方法 3 继续用于统一比较。下节分别展示默认权重的零样本结果和专用头的适配结果。

6 多数据集泛化效果展示

6.1 展示范围与分组

本节展示的是**公司多数据集、跨传感器及跨拍摄条件的泛化表现**。默认方法 3 只在 MIS20S1 暗房真实样本及其合成噪声上训练；SC465SL、sc635hai 和 sc450ai 均以同一权重先做零样本测试。MIS20S1 室外用于检查场景变化，1000x 用于检查未参与训练的真实增益。另列的方法 8 结果只表示 sc635hai 专用适配。

45 条原始流均完成输入与方法 3 的固定 ISP 对比。每流取首、中、尾 3 个连续 8 帧片段，共 24 帧，总计 1080 帧。27 条场景流用于观察画质，18 条标定流用于噪声与数值诊断；45/45 表示推理覆盖。以下按具体数据集给出静态指标和代表画面。

6.2 MIS20S1：训练覆盖增益与未见真实增益

表 5: MIS20S1 静态结果。645x 在训练覆盖内，使用 10x 跨增益参考；1000x 真实序列未参与训练，使用原生静态参考。

协议	输入 PSNR (dB)	方法 3 PSNR (dB)	提升 (dB)	输入 RMSE (DN)	方法 3 RMSE (DN)	HF 比
645x 跨增益参考	24.3519	29.5729	+5.2210	248.1197	136.0228	0.9712
1000x 原生参考	44.6204	53.2675	+8.6471	24.0565	8.8895	0.8562

645x 的噪声显著下降，高频比 0.9712，说明静态图卡结构与参考较为接近。图 7 展示同帧输入与最终输出：墙面和图卡周围的彩噪减少，棋盘、文字及卡片轮廓仍可分辨。由于 645x 参与训

练，这一行用于说明训练域的恢复效果，不作为未见增益成绩。



图 7: MIS20S1 暗房 645x 固定 ISP 对比，上为全景，下为固定中心裁剪。该图展示最终方法 3 在训练覆盖域的恢复效果；静态定量只统计有效区域。

1000x 原生参考评测的 PSNR 提升 8.65 dB，RMSE 由 24.06 DN 降至 8.89 DN。为检查同流参考的影响，另使用互斥奇偶帧池验证，方法 3 得到 53.10/53.07 dB。该结果与完整原生参考评测接近，支持模型对未参与训练的 1000x 真实流具有静态去噪能力；它仍是同一暗房场景下的真实增益测试。



图 8: MIS20S1 1000x 输入、方法 3 与原生参考。该序列不参与主方法训练；展示保持相同亮度映射，定量按表 5 所列协议计算。

6.3 SC465SL 与 sc635hai：跨传感器零样本静态泛化

表 6 中所有结果使用同一方法 3 EMA，没有目标传感器训练。SC465SL 两档增益的提升为 10.52–13.21 dB，sc635hai 低色温静态提升约 13.59 dB。两个奇偶方向的结果接近，且高频保持率为 0.911–0.958；输出 legal RAW fraction 均为 100%。

表 6: 不同数据集上的零样本静态泛化。偶/奇表示输入帧池，参考使用相反奇偶池；HF 为输出/参考高频 RMS，MAD 为时序平均绝对差。

数据集	输入池	输入 PSNR (dB)	方法 3 PSNR (dB)	提升 (dB)	HF 比	MAD 输入 → 输出 (DN)
SC465SL 256x	偶	41.840	55.052	+13.211	0.957	31.889→1.567
	奇	41.840	54.999	+13.158	0.958	31.886→1.578
SC465SL 2000x	偶	46.039	56.563	+10.523	0.911	20.238→1.312
	奇	46.034	56.647	+10.613	0.912	20.248→1.301
sc635hai 131x	偶	38.737	52.325	+13.588	0.919	47.481→2.165
	奇	38.736	52.324	+13.587	0.921	47.481→2.163

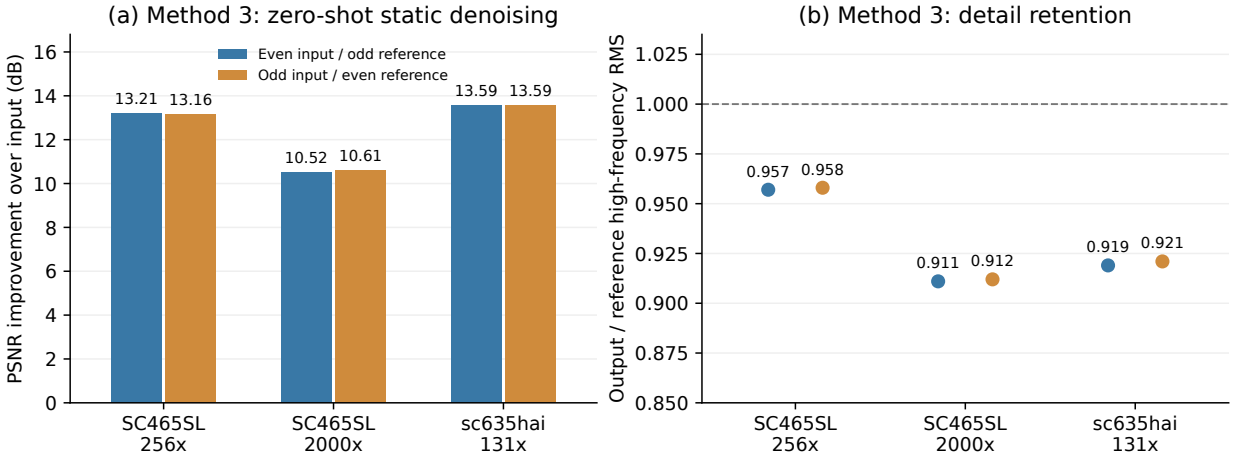


图 9: 方法 3 在三组未参与训练的目标域静态数据上的泛化：左为相对输入的 PSNR 提升，右为高频保持率。数据来自表 6，参考均采用互斥奇偶帧池。

SC465SL 两档结果在图 10 和图 11 中展示。输入中的细碎彩噪和背景波动得到抑制，风扇、人偶、线缆及背景卡片仍可辨。两图来自完整画面预览，静态定量则按各自的有效区域计算。

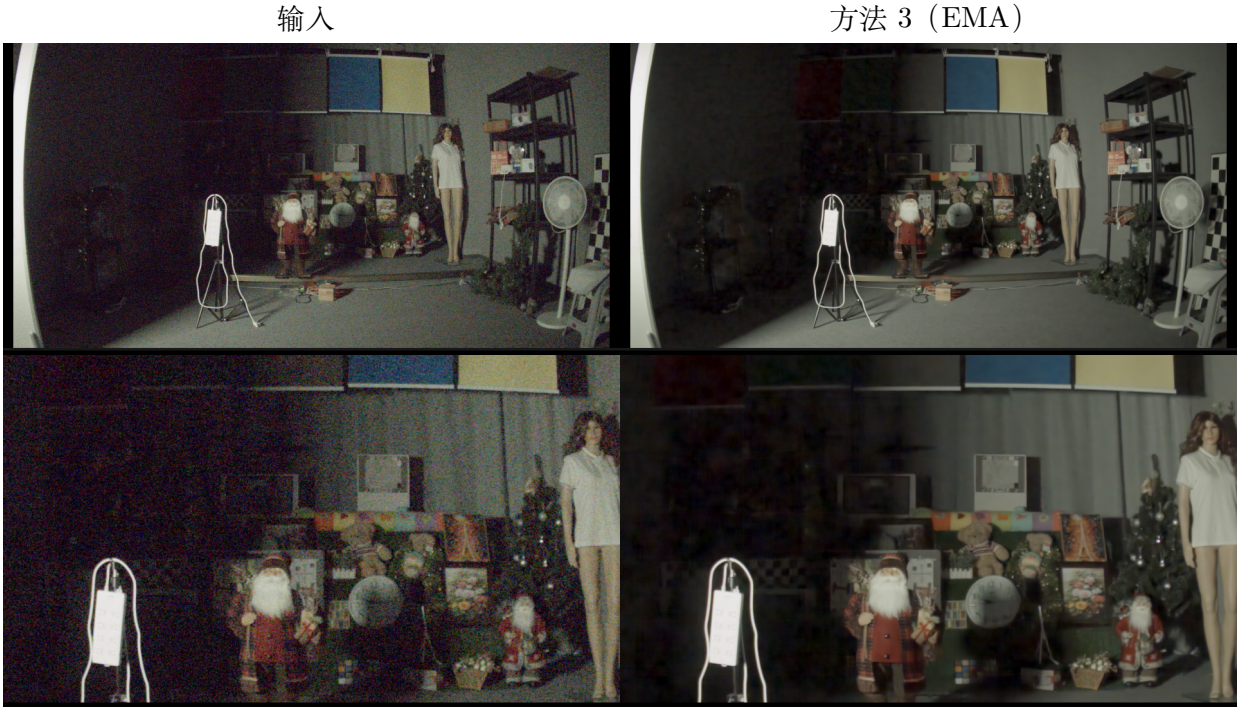


图 10: SC465SL 暗室 256x 的零样本结果，上为全景，下为中心裁剪。模型未在 SC465SL 训练；固定 ISP 下可观察到明显降噪及背景结构保留。

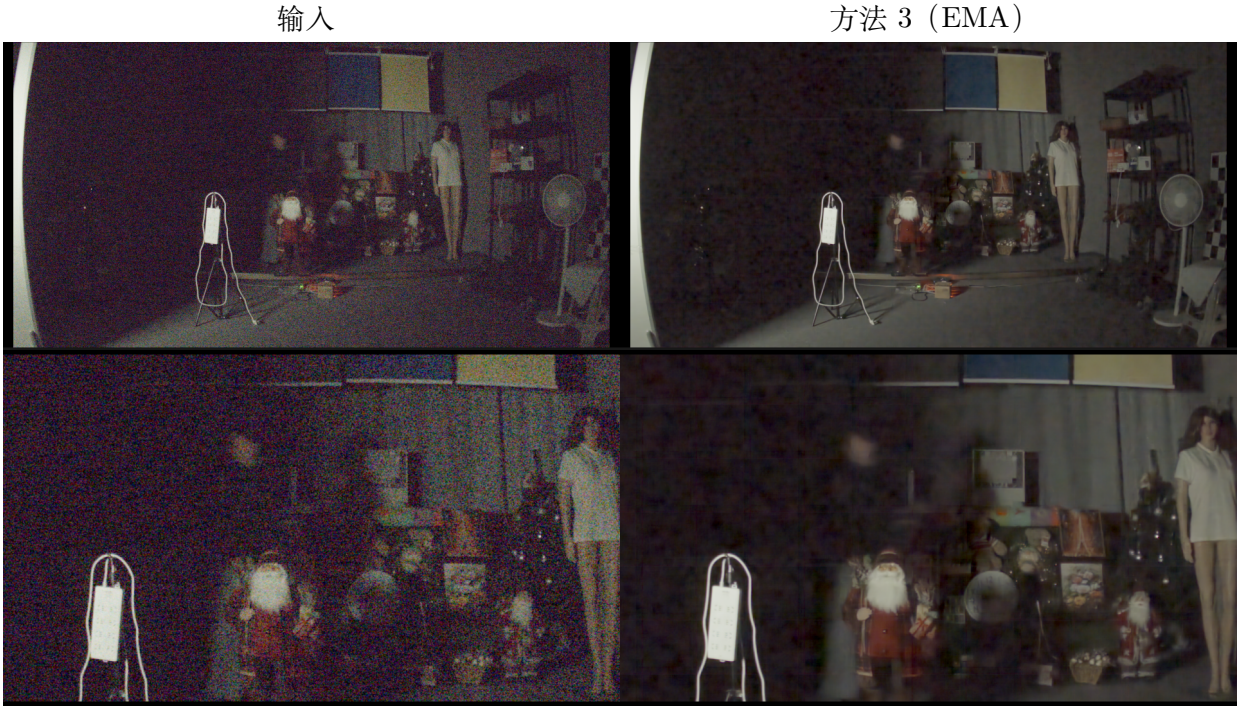


图 11: SC465SL 暗室 2000x 的零样本结果，使用与 256x 相同的方法 3 权重和推理流程。静态 PSNR 提升约 10.52–10.61 dB，高频比约 0.911–0.912。

sc635hai 131x 在低色温和较大蓝通道白平衡补偿下，仍显示较强的静态去噪能力。图 12 给出输入、方法 3 与相反奇偶池静态参考，展示背景卡片和人偶结构的保留。表 6 对应方法 3 的零

样本结果；后续使用 131x 训练专用头所得的数字单独列在第 6.4 节，保持两个实验的含义独立。



图 12: sc635hai 131x 低色温数据集的零样本静态对比，选自偶输入方向的第 8 帧。参考为对侧奇数帧池的静态均值，动态像素不计入静态指标。

6.4 sc635hai 专用输出头：适配域与动态保留集

方法 8 的 131x 指标来自训练数据尾段复评，该尾段参与过训练采样，不计为独立泛化结果。表 7 显示，专用头在静态域仅带来约 0.034 dB 的小幅变化，高频与时序指标保持接近。其 16x 动态保留集未参加训练；由于缺少干净动态目标，只报告诊断量。

表 7: sc635hai 专用头效果。131x 为训练数据尾段复评，16x 为完整保留的动态序列；本表与零样本表采用不同评测样本，基线数值不混用。

数据与协议	指标	方法 3	方法 8 专用头
131x 适配域	静态 PSNR，偶方向 (dB)	52.3535	52.3875
	静态 PSNR，奇方向 (dB)	52.3552	52.3884
	HF 比（约）	0.9199	0.9181
	temporal MAD(DN)	2.1628	2.1247
16x 动态保留集	HF 诊断比	0.763605	0.763078
	motion/input ratio	0.599602	0.596438
	temporal MAD(DN)	14.6745	14.6218
	端点裁剪	2.1994%	1.9344%
	legal RAW fraction	100%	100%

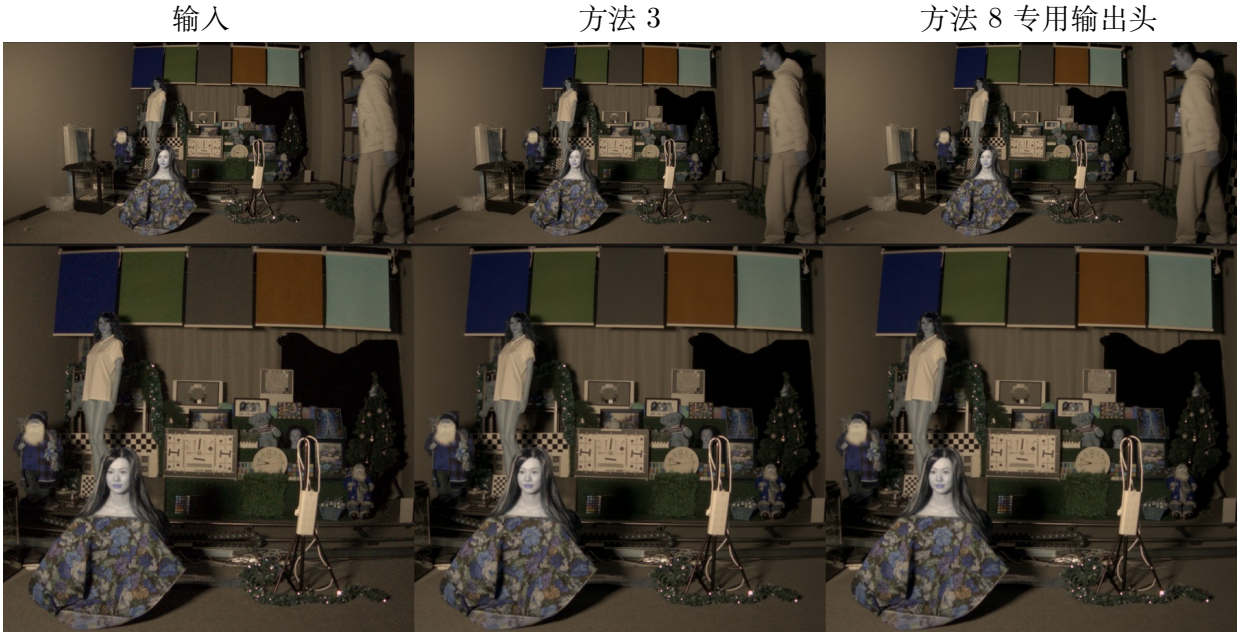


图 13: sc635hai 16x 动态保留集：输入、默认方法 3 和方法 8 专用输出头。两种输出在结构与纹理上接近，固定 ISP 首、中、末帧复核未见明显新增重影、断边或色偏。

方法 8 的变化主要集中在输出映射，未形成可辨的动态结构提升，因此保留其“sc635hai 专用可选头”的身份。跨传感器静态泛化的主要证据仍是未经目标域适配的方法 3。

6.5 室外、高增益和 sc450ai 数据集的实际输出

多数据集展示也包含强噪声、运动和复杂纹理。MIS20S1 室外 1500x 与训练暗房具有场景和噪声差异。图 14 中方法 3 明显压低彩噪，但人物局部有姿态平均，树木纹理偏软。该序列没有干净动态参考，因此不提供动态 PSNR。

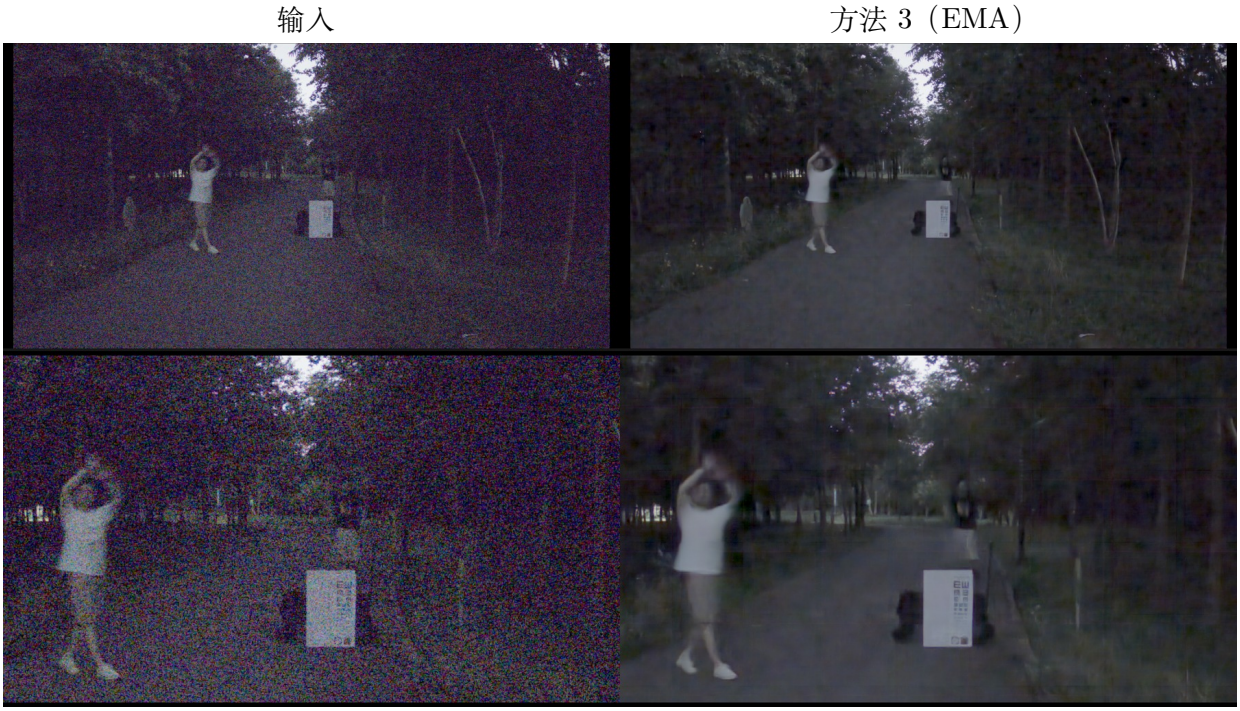


图 14: MIS20S1 室外 1500x 跨场景输出。上为全景，下为中心裁剪；同一默认方法 3 显著降噪，同时可见人物与背景细节的平滑现象。

sc450ai 1435x 黑物运动在零样本诊断中，高频比为 0.127，端点裁剪约 3.28%，运动/静态时序比为 0.057/0.088。图 15 保留了方法 3 原始结果：黑衣内部结构偏空、边界偏软。804x 灯光变化的高频比为 0.690，暗部仍有低频色斑。SC465SL difficultpattern 视频也观察到拖影和重影。上述画面与前三组静态定量共同构成了多数据集展示的完整结果。

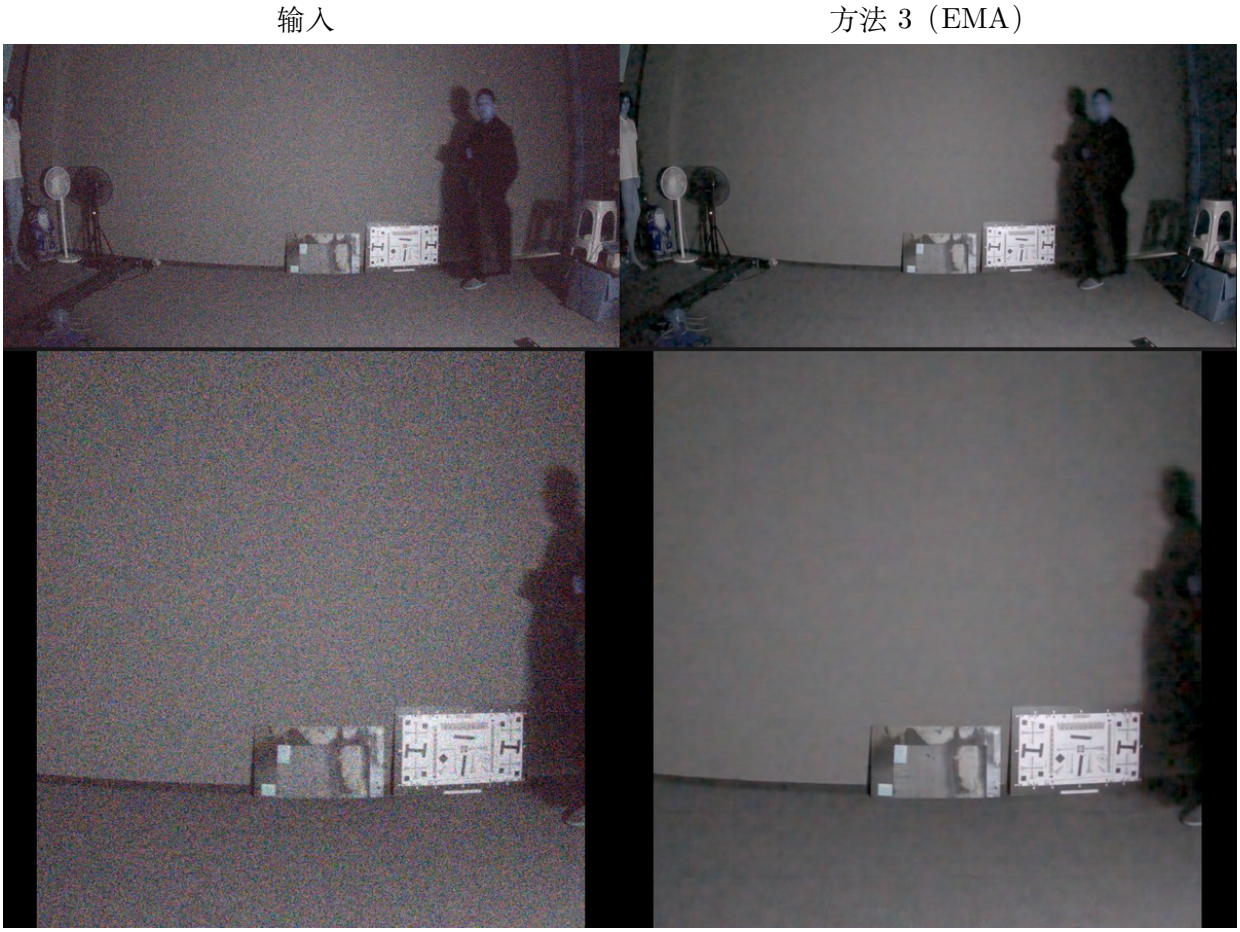


图 15: sc450ai 1435x 黑物运动的零样本结果。此处仅显示原对比图的输入与最终方法 3 两列；黑色衣物内部与运动轮廓仍偏软。

表 8: 最终方法在不同公司数据集中的展示结果。

数据条件	使用权重与协议	已观察结果
MIS20S1 暗房 645x	方法 3；训练覆盖域、跨增益参考	+5.22 dB，HF 0.971
MIS20S1 暗房 1000x	方法 3；真实增益留出、原生参考	+8.65 dB；互斥奇偶验证 53.10/53.07 dB
SC465SL 暗室 256x/2000x	方法 3；跨传感器零样本静态	+10.52–13.21 dB，HF 0.911–0.958
sc635hai 低色温 131x	方法 3；跨传感器零样本静态	约 +13.59 dB，HF 0.919–0.921
sc635hai 动态 16x	方法 3 及方法 8 专用头；动态保留集	两者画面接近；专用头未见明显新增伪影
MIS20S1 室外 1500x	方法 3；跨场景动态观察	噪声下降，人物姿态与树木结构偏平滑
sc450ai、复杂纹理动态	方法 3；零样本压力测试	可见结构平滑、色斑或重影，不计为通过的静态泛化结果

参考文献

[1] H. Yue, C. Cao, L. Liao, R. Chu, and J. Yang. Supervised Raw Video Denoising With a Benchmark Dataset on Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2301–2310, 2020.

[2] H. Yue, C. Cao, L. Liao, and J. Yang. RViDeformer: Efficient Raw Video Denoising Transformer With a Larger Benchmark Dataset. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(9):8929–8944, 2025. DOI: 10.1109/TCSVT.2025.3553160.

[3] J. Liang, Y. Fan, X. Xiang, R. Ranjan, E. Ilg, S. Green, J. Cao, K. Zhang, R. Timofte, and L. Van Gool. Recurrent Video Restoration Transformer with Guided Deformable Attention. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[4] J. Lehtinen, J. Munkberg, J. Hasselgren, S. Laine, T. Karras, M. Aittala, and T. Aila. Noise2Noise: Learning Image Restoration without Clean Data. In *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 80:2965–2974, 2018.

[5] A. Krull, T.-O. Buchholz, and F. Jug. Noise2Void – Learning Denoising from Single Noisy Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2129–2137, 2019.

[6] J. Batson and L. Royer. Noise2Self: Blind Denoising by Self-Supervision. In *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 97:524–533, 2019.

[7] A. Foi, M. Trimeche, V. Katkovnik, and K. Egiazarian. Practical Poissonian-Gaussian Noise Modeling and Fitting for Single-Image Raw-Data. *IEEE Transactions on Image Processing*, 17(10):1737–1754, 2008.

[8] T. Brooks, B. Mildenhall, J. T. Barron, J. Chen, D. Sharlet, and R. Ng. Unprocessing Images for Learned Raw Denoising. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11036–11045, 2019.

[9] C. Godard, K. Matzen, and M. Uyttendaele. Deep Burst Denoising. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.

[10] S. W. Hasinoff, D. Sharlet, R. Geiss, A. Adams, J. T. Barron, F. Kainz, J. Chen, and M. Levoy. Burst Photography for High Dynamic Range and Low-Light Imaging on Mobile Cameras. *ACM Transactions on Graphics*, 35(6):192, 2016.

[11] T. Kroeger, R. Timofte, D. Dai, and L. Van Gool. Fast Optical Flow Using Dense Inverse Search. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 471–488, 2016.

[12] E. Reinhard, M. Stark, P. Shirley, and J. Ferwerda. Photographic Tone Reproduction for Digital Images. *ACM Transactions on Graphics*, 21(3):267–276, 2002.

[13] P. Charbonnier, L. Blanc-Feraud, G. Aubert, and M. Barlaud. Two Deterministic Half-Quadratic Regularization Algorithms for Computed Imaging. In *Proceedings of the IEEE International Conference on Image Processing (ICIP)*, vol. 2, pp. 168–172, 1994.

[14] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.

[15] D. Maggioni, E. Sanchez-Monge, and A. Foi. Efficient Multi-Stage Video Denoising With Recurrent Spatio-Temporal Fusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[16] M. Tassano, J. Delon, and T. Veit. FastDVDNet: Towards Real-Time Deep Video Denoising Without Flow Estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[17] B. Mildenhall, J. T. Barron, J. Chen, D. Sharlet, R. Ng, and R. Carroll. Burst Denoising with Kernel Prediction Networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.

[18] A. Buades, B. Coll, and J.-M. Morel. A Non-Local Algorithm for Image Denoising. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2005.

[19] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian. Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering. *IEEE Transactions on Image Processing*, 16(8):2080–2095, 2007.

[20] S. Guo, Z. Yan, K. Zhang, L. Zhang, and W. Zuo. Toward Convolutional Blind Denoising of Real Photographs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

A 采纳方法的超参数与模型配置

本附录记录最终方法 3 及方法 8 的 sc635hai 专用可选头。训练设置以最终 checkpoint 中保存的配置和优化器状态为准，模型与损失以对应实现核对；展示视频的编码以实际产物为准。下列路径均相对于项目根目录。

A.1 权重与运行环境

项目目录 `/Data4/Xiao/RECOVERED_Stage2_DenoiseModel_20261010`

Python `/home/jingzeliang/miniconda3/envs/aaa_312/bin/python`

方法 3 最终权重 `artifacts/finetune_mis20s1/training/checkpoint_step_005000.pth`，读取 `ema` 字段。

方法 3 SHA-256 `97c4332f685f98959b243e4b100434469f714aed6329e100d22b6d8552592e0b`

方法 8 专用权重 `artifacts/a8_sensor_adaptation/sc635hai/training_20261013/checkpoint_step_000500.pth`，读取 `ema` 字段。

方法 8 SHA-256 `8e4980a43767b5b83ecc064e8cdce2f685ea452e94af48a1f4ca252004765b3f`

A.2 方法 3 训练超参数

表 9: 最终主方法的训练与采样配置。

项目	实际设置
初始化	官方 `RViDeformer-L_CRVD.pth`，strict 加载；恢复后的本地预训练文件位于 `artifacts/pretrained/`
可训练范围	全模型，共 7,505,716 个参数、1208 个参数张量
总优化步数	5000；从 step 200 恢复至 step 5000
训练 batch size	1；每次优化包含 1 个 8 帧样本
学习率	固定 1×10^{-4}，无学习率调度器
优化器	Adam，$\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$
优化器其他项	weight decay 为 0，amsgrad 为 False
数值精度	FP32；无 autocast、GradScaler 或梯度累积
梯度裁剪	未使用
EMA	decay=0.999，每次 optimizer step 后更新参数，buffer 直接复制；推理读取 EMA

项目	实际设置（续）
随机种子	20260921；设置 Python、NumPy、PyTorch 和 CUDA 随机种子
输入/输出	$(B, T, C, H, W) = (1, 8, 4, 64, 64)$，输出对应 8 帧
真实: 合成比例	配置 0.5:0.5；512 项采样序列的前 256 项为真实、后 256 项为合成
真实训练序列	MIS20S1 暗房 128x、313x、632x、645x；不含 1000x 真实序列
真实时间采样	随机起点的连续 8 帧，frame stride=1
合成时间采样	每个增益 8 个噪声变体，从变体池循环取 8 帧，干净内容相同
裁剪与增强	随机 64×64 packed 裁剪、真实时窗、合成噪声；未加入翻转或旋转
样本随机状态	索引 i 使用 `seed + i * 104729`；合成变体使用 `seed + record_index * 1009 + variant`
DataLoader	默认 512 项，shuffle=False，num_workers=0，drop_last=True；耗尽后重新遍历
训练输出裁剪	预测先 clamp 到 $[0, 1]$，再计算损失
最终权重选择	step-5000 EMA；未将后续运动、统一微调或门控候选合并进去

实际配置文件为 `artifacts/finetune_mis20s1/training/a3_config.json`；训练及采样实现为 `src/raw_fusion/finetune/a3.py`。

A.3 参考、归一化与损失设置

表 10: 主方法监督与损失参数。

项目	设置
主参考	MIS20S1 暗房 10x 的 200 帧；packed 形状 $(4, 540, 960)$
通道顺序	R、Gr、Gb、B
主参考黑电平	R=266.125、Gr=275.625、Gb=275.375、B=267.0 DN
白电平	4095 DN
真实输入映射	按每条流 manifest 中的整数位移配准；逐通道 slope/intercept 映射到参考域，再按式 (3) 归一化
有效掩码	参考有效区 $\cap$ 8 帧均静态 $\cap$ 全部 8 帧/4 通道均未饱和；合成样本不另加运动掩码
饱和阈值	映射参考域 3800 DN，归一化阈值按各参考通道黑电平换算

项目	设置（续）
运动阈值	对应采样位置的运动 mask < 0.5，全部 8 帧同时满足
损失总式	$\mathcal{L}_{\text{char}} + 0.1\mathcal{L}_{\text{grad}} + 0.1\mathcal{L}_{\text{hp}}$
Charbonnier	$\sqrt{(\hat{y}-y)^2 + 10^{-6}}$；标准 ϵ^2 记法下 $\epsilon = 10^{-3}$
梯度损失	水平、垂直梯度幅值差的 masked L1，两方向各 0.5；相邻 mask 相乘
高通损失	$H(u) = u - \text{AvgPool3d}(u)$ 后的 masked L1
高通池化	kernel=$(1,3,3)$，stride=1，padding=$(0,1,1)$；默认零填充且包含填充计数
掩码归约	掩码沿通道展开；分母为 mask.sum().clamp_min(1)，逐有效元素平均
动态损失/教师蒸馏	最终方法 3 未使用

参考统计与空间资源分别见 `artifacts/finetune_mis20s1/supervision/references/a1_reference_report.json` 和同目录 `a1_reference_manifest.json`。配准、曝光系数与运动掩码逐流记录于 `artifacts/finetune_mis20s1/supervision/stream_manifests/`，因此不以单组曝光系数替代所有流。

A.4 网络构造参数

表 11: RViDeformer-L 在最终方法中的实际构造配置。

参数	设置
输入/输出通道	4 / 4
`upscale`	1
`img_size`	[8, 64, 64]
`window_size`	[6, 8, 8]
`depths`	[4, 4, 4, 4, 4, 4, 4, 2, 2, 2, 2]
`embed_dims`	[84, 84, 84, 84, 84, 84, 84, 108, 108, 108, 108]
`num_heads`	[6, 6, 6, 6, 6, 6, 6, 6, 6, 6, 6]
`indep_reconsts`	[11, 12]，按构造实参记录
`mul_attn_ratio`	0.75
`mlp_ratio`	2
`qkv_bias / qk_scale`	True / None

参数	设置（续）
drop_path_rate	0.2（配置最大值）
归一化	LayerNorm
pa_frames	2
deformable_groups	12
spynet_path	None
recal_all_flows	False
nonblind_denoising	False
激活检查点构造参数	use_checkpoint_attn=False， use_checkpoint_ffn=False； no_checkpoint_attn_blocks 和 no_checkpoint_ffn_blocks 均为空列表
前 7 级空间尺度	[1, 2, 4, 8, 4, 2, 1]；先降采样再恢复
参数与 buffer	参数 7,505,716 个；buffer 57 个，共 2,668,800 个元素
状态字典	每套 model/EMA 共 1265 张量，其中 1208 个为参数张量； 张量个数不等于参数量

模型配置入口为 src/raw_fusion/finetune/a3.py 的 build_rvideformer，结构实现为 src/raw_fusion/finetune/rvideformer_arch.py。

A.5 噪声合成参数

表 12 和表 13 列出实际生成器使用的逐档经验参数。增益标签 g 对应的 G 为标签除以 100；shot 系数已包含该档增益，不应在式 (6) 中再乘一次 G。表中数值保留 6 位小数，精确复现读取原 JSON 的完整精度。

表 12: 逐增益经验 shot 系数 $\alpha_{c,g}$，单位 DN。

增益标签	G	R	Gr	Gb	B
100	1	0.146240	0.133124	0.134059	0.153964
200	2	0.303604	0.262204	0.263975	0.301672
400	4	0.595802	0.525547	0.529092	0.569351
800	8	1.234060	1.038338	1.045279	1.185013
1600	16	2.553175	2.271041	2.286595	2.535520
3200	32	5.057363	4.411844	4.442612	4.909565
6400	64	10.160087	8.932881	8.913312	10.015178
12800	128	24.593596	24.830152	24.722971	25.129168
25600	256	48.717270	50.454506	50.209071	50.189296

表 13: 逐增益 read variance $v_{c,g}$，单位 DN^2。

增益标签	G	R	Gr	Gb	B
100	1	1.582505	1.582505	1.582505	1.582505
200	2	2.813700	2.813700	2.813700	2.813700
400	4	8.617427	8.616957	8.616957	8.617427
800	8	29.718838	29.718838	29.718838	29.718838
1600	16	4.396071	4.396071	4.396071	4.396071
3200	32	11.254265	11.254265	11.254265	11.254265
6400	64	39.564642	34.466890	34.466890	34.467829
12800	128	114.346263	114.346263	114.346263	114.346263
25600	256	364.052709	364.046605	364.049657	364.049657

生成器使用的聚合通道相关矩阵为

$$C = \begin{bmatrix} 1 & 0.01588756 & 0.00647320 & 0.00093781 \\ 0.01588756 & 1 & 0.00753526 & 0.00049242 \\ 0.00647320 & 0.00753526 & 1 & 0.02030878 \\ 0.00093781 & 0.00049242 & 0.02030878 & 1 \end{bmatrix}. \tag{12}$$

固定图样偏置读取主参考 manifest 中的 `fpn_paths.offset_dn` 空间数组。每档 8 个噪声变体使用独立随机数，随后先 round 至 1 DN 格点、再 clip 至 $[0, 4095]$，保存为 uint16。完整模型位于 `artifacts/finetune_mis20s1/noise_model/noise_model.json`；生成器位于 `src/raw_fusion/finetune/noise.py` 的 `generate_noisy_frame`。

A.6 推理、评测与固定 ISP 参数

表 14: 最终主方法的推理与展示配置。

项目	设置
模型状态	EMA，eval 模式；不更新参数
连续视频时间窗口	8 帧，窗口步长 4；不足 8 帧时重复末帧，丢弃补齐位置的输出
空间 tile/步长	64×64 packed / 56 packed；完整画面覆盖
重叠区域	时域和空域均采用等权累计、除以覆盖计数
分块并行批大小	全数据集展示使用 tile_batch=12；跨传感器审计入口配置为 2，原始全帧评估入口常用 8；均不改变训练 bs=1
输出裁剪	归一化域 $[0, 1]$，再按对应管线恢复 DN
跨传感器静态采样	输入与参考奇偶帧池互斥；每片段 8 帧、原视频 stride=2。SC465SL 每方向 5 片段（40 帧），sc635hai 零样本每方向 3 片段（24 帧），专用头尾段复评每方向 1 片段（8 帧）
静态有效区	奇偶参考置信度 ≥ 0.9
展示采样	每流首、中、尾各 1 个连续 8 帧片段，共 24 帧；45 流共 1080 帧
去马赛克	canonical Bayer 重建，OpenCV edge-aware
曝光选择	每条流由输入 99.5 百分位确定；Reinhard 后线性目标 0.8，EV 范围 $[-6, 8]$；输入与输出共享冻结值
白平衡	各流 manifest 中的固定 WB，输入与输出共享
色调与高光	Reinhard tone mapping；高光重建开启；随后 sRGB gamma
其他 ISP 项	2DNR/3DNR 关闭，false color suppression 关闭
色彩模式	uncalibrated camera RGB；未使用传感器 ColorMatrix
实际预览视频	HEVC（libx265），CRF16，yuv444p，1920×1080，6fps；每视频 24 帧
面板布局	输入左、方法 3 右；上为全景、下为固定中心裁剪

表 14 的 ISP 与视频项对应 45 流全数据集预览。奇偶参考面板和方法 8 对比使用原审计固定渲染：固定白平衡与曝光、普通 Bayer 去马赛克、sRGB 变换，不包含 Reinhard 与高光重建；各对比内部共享参数。

分块实现见 `src/raw_fusion/finetune/a4.py`；跨传感器清单见 `configs/a3_cross_sensor_zero_shot_20261012.json` 和 `configs/a3_cross_sensor_extension_20261012.json`；全数据集设置见 `configs/a3_all_dataset_traditional_isp_preview_20261017.json`。该配置的 `preferred_encoder` 记为 libx264，但 45 个实际视频及对应 `video_manifest.json` 均为 libx265，表 14 按实际产物记录。

A.7 方法 8 的 sc635hai 专用头完整配置

表 15: 专用可选输出头的训练设置。

项目	实际设置
初始化与范围	方法 3 step-5000 EMA；主干冻结且 eval，仅训练输出头
可训练模块	`norm`、`conv_after_body`、`conv_last`，共 6 张量、12,400 参数
头部结构与参数	LayerNorm108：216；Linear108→84：9156；Conv3d84→4，kernel=$(1,3,3)$：3028
目标传感器样本	sc635hai 131x 低色温，共 150 帧，完整范围 $[0,150)$
输入/目标帧池	偶池 0,2,…,148 与奇池 1,3,…,149 互换；每池 75 帧，目标为对侧静态均值
时间窗口	同一池 8 帧，即原视频 frame stride=2
训练 batch / 步数	1 / 500
随机种子	20261013
学习率与优化器	固定 10^{-5}，Adam，betas=$(0.9,0.999)$，eps=10^{-8}，weight decay=0，amsgrad=False；无调度器
精度与损失	BF16 autocast，损失转 FP32；与式 (8) 相同，权重 1/0.1/0.1
EMA / 梯度裁剪	decay=0.999 / gradient norm=1.0
patch 与有效区域	64×64 packed；静态置信度 ≥ 0.9，输入未饱和；有效比例至少 0.25，最多尝试 32 次裁剪
目标域增强	水平翻转、垂直翻转、转置，各以 0.5 概率施加
回放概率与实绩	MIS20S1 回放概率 0.5；实际回放 262 步，sc635hai 采样 238 步；回放沿用主方法数据管线
检查点间隔	每 100 步保存，最终保留 step-500 EMA
131x 静态复评片段	偶输入 134,136,…,148；奇输入 135,137,…,149。该尾段参与训练采样，不作为独立留出
独立动态保留集	sc635hai 16x 运动彩色 200 帧，不参与训练；仅无参考诊断与固定 ISP 观察
用途	sc635hai 专用可选头，不替代默认方法 3

配置为 `configs/a8_sc635hai_adaptation_20261013.json`；实际训练摘要与保存配置位于 `artifacts/a8_sensor_adaptation/sc635hai/training_20261013/`；实现为 `src/raw_fusion/finetune/a8_adaptation.py`。

A.8 结果来源与复现入口

主方法静态评估位于 artifacts/finetune_mis20s1/evaluation/；跨传感器静态结果位于 artifacts/a3_cross_sensor_zero_shot_20261012/ 和 artifacts/a3_cross_sensor_extension_20261012/；45 流完整预览位于 artifacts/a3_all_dataset_traditional_isp_preview_20261017/。专用输出头的解释与检查结果见 docs/A8_SC635HAI_ADAPTATION_RESULT_2026-10-13.md。这些文件名保留原始实验标识，以便定位已有产物。

从项目根目录执行以下只评测命令，可按对应协议复现主要结果；命令中的 python 指本附录记录的 Python 环境。

```
python scripts/run_a4_eval.py --max-frames 200 \
  --tile-batch 8 \
  --output-dir artifacts/finetune_mis20s1/evaluation
python scripts/run_native_1000x_eval.py --max-frames 200 \
  --tile-batch 8 \
  --output-dir artifacts/finetune_mis20s1/evaluation/native_1000x
python scripts/evaluate_a3_cross_sensor.py \
  --config configs/a3_cross_sensor_zero_shot_20261012.json \
  --output-dir artifacts/a3_cross_sensor_zero_shot_20261012 \
  --phase all --device cuda:0 --tile-batch 2
python scripts/evaluate_a3_cross_sensor.py \
  --config configs/a3_cross_sensor_extension_20261012.json \
  --output-dir artifacts/a3_cross_sensor_extension_20261012 \
  --phase all --device cuda:0 --tile-batch 2
```

结果表中的 645x 为训练覆盖域复评，1000x 为真实增益留出；零样本跨传感器表只使用方法 3，sc635hai 专用头的 131x 尾段属于训练数据复评。复现时应沿用这些数据身份与各自参考定义。

B 补充探索的记录与图表来源

第 3 节依据 -djc/deliverable_20261025/ 整理；以下路径均相对此交付目录。核查范围包括研究报告与台账、服务器历史实验、本地训练与补充验证、模型实现和图像来源。正文按研究问题归纳，不将部署自检、草案预算和实际优化器更新混为一谈。

表 16: ExposureDiffusion 路线的主要证据入口。

内容	对应记录
早期噪声研究	project/code/noise_model/ 下的 TWO_SHOTS_CVPR2026.md、ONE_FRAME_DARK_VALIDATION.md、PNNP_DECOMPOSITION_COMPARISON.md、QUANTIZED_LIKELIHOOD.md 与 STATIC_CONDITIONAL_RESIDUAL.md
多传感器自标定	archive/server/calibration/report.md
单帧 1000 步适配	archive/server/reports/gpu_start/completion_audit.json，及 archive/server/runs/company_mixed_gpu_001/
历史模块试验与解冻	archive/server/experiments/、archive/server/runs/、archive/server/evaluation/；汇总表 results/tables/historical_validation_all_metrics.csv
最终五帧结构与实际训练	project/code/company_exposure/burst_detail/model.py；project/code/scripts/exposure_output_residual_local.py；project/work_v3/runs/residual_v3_001/
固定与补充验证	上述运行目录中的 fixed_validation.json、baseline_validation.json 与 validation_2300.json；results/tables/supplement_validation.csv、supplement_sensitivity.csv
165 例图像与权重身份	results/report_comparisons/ 中各流的 best_full.png、best_detail.png 及 best_provenance.json；results/all165/inference_contract.json

早期噪声建模的数值按上述研究记录转述；对应 runs/noise/ 的原始拟合 JSON 与 NPZ 未包含在本次交付包中，故本次仅核对其报告与实现，不将它们作为新完成的独立验收。后续历史训练的 352 项汇总指标已与原运行 JSON 逐项比对；五帧候选的固定验证、补充裁块和图像权重身份亦分别核对。

本报告插入的五张场景图保持原始 PNG 内容，排版仅裁去原小字号表头并重排标签。复制来源、文件哈希和最佳权重身份保存在本项目 docs/assets/stage2_report_20261023/djc/figure_sources.json。曲线与分域图由同目录 plot_djc_results.py 基于随附最小 CSV 重绘，来源记录为 plot_sources.json。这组图中的官方 RViDeformer 与第 5 节的微调方法 3 始终作为不同权重处理。