# 视频去噪研究报告

方法探索、最终方案与多数据集泛化效果

肖纬杰　邸锦承

**摘要**

本报告记录 Stage2 RAW 视频去噪项目从公司数据适配、静态监督构建到跨传感器验证的研究过程。针对预训练教师在公司 RAW 上噪声与细节难以兼顾的问题，项目先建立可信的时域均值参考和实测噪声合成管线，再依次考察动态监督、冻结运动专家、教师融合、传感器适配、统一微调及推理门控。最终采用方法 3：以 RViDeformer-L 为基座，混合真实跨增益样本与标定噪声合成样本，使用带有效区域掩码的重建、梯度和高通损失进行全参数微调，并固定第 5000 步的 EMA 权重用于推理。sc635hai 另保留方法 8 的专用可选输出头。

效果展示覆盖公司 MIS20S1、SC465SL、sc635hai 和 sc450ai 多个数据集与拍摄条件。方法 3 在 MIS20S1 645x 跨增益参考评测中达到 29.57 dB，在未参与训练的 1000x 原生参考评测中达到 53.27 dB；在未进行目标传感器训练的 SC465SL 和 sc635hai 静态序列上，零样本 PSNR 分别提升约 10.52–13.21 dB 和 13.59 dB。报告同时展示高增益动态及 sc450ai 的实际输出，按静态定量、动态观察和专用适配三种协议解释结果。正文依次介绍方法探索、最终方案和多数据集效果，附录集中列出采纳方案的训练超参数、损失、模型与推理配置。

**关键词：** RAW 视频去噪；RViDeformer；时域均值监督；跨传感器泛化；固定 ISP

# 目录

**1 引言** **3**
1.1 项目起点与研究目标 . . . 3
1.2 研究过程与报告主线 . . . 3

**2 相关工作与数据基础** **3**
2.1 技术背景 . . . 3
2.2 公司数据集与实验分工 . . . 4
2.3 RAW 适配与参考资格 . . . 4
2.4 评测口径 . . . 5

**3 试过的方法与方案选择** **5**
3.1 方法 0 至方法 4：形成静态基线 . . . 5
3.2 方法 5 至方法 7：运动保真探索 . . . 5
3.3 方法 8 至方法 10：跨传感器适配与退化验证 . . . 6
3.4 方法 11：高增益推理门控 . . . 6
3.5 最终方案的确定 . . . 7

**4 最终采纳的方法** **7**
4.1 整体流程 . . . 7
4.2 真实样本与静态监督构建 . . . 7
4.3 实测噪声合成与混合采样 . . . 8
4.4 网络与优化目标 . . . 8
4.5 训练、权重选定与完整画面推理 . . . 9
4.6 sc635hai 专用可选输出头 . . . 9

**5 多数据集泛化效果展示** **9**
5.1 展示范围与分组 . . . 9
5.2 MIS20S1：训练覆盖增益与未见真实增益 . . . 10
5.3 SC465SL 与 sc635hai：跨传感器零样本静态泛化 . . . 11
5.4 sc635hai 专用输出头：适配域与动态保留集 . . . 13
5.5 室外、高增益和 sc450ai 数据集的实际输出 . . . 14

**A 采纳方法的超参数与模型配置** **19**
A.1 权重与运行环境 . . . 19
A.2 方法 3 训练超参数 . . . 19
A.3 参考、归一化与损失设置 . . . 20
A.4 网络构造参数 . . . 21
A.5 噪声合成参数 . . . 22
A.6 推理、评测与固定 ISP 参数 . . . 23
A.7 方法 8 的 sc635hai 专用头完整配置 . . . 25
A.8 结果来源与复现入口 . . . 26

# 1 引言

## 1.1 项目起点与研究目标

Stage1 使用预训练的 RViDeformer-L_CRVD 教师生成伪干净目标。在公司 MIS20S1 数据上，该教师对图卡细线、棋盘和文字边缘的处理偏软，影响了下游监督质量。Stage2 因而把研究对象转向教师本身：利用现有公司 RAW 数据进行微调，兼顾噪声抑制与高频结构，并检查模型在不同传感器、增益和运动条件下的表现。

项目没有公司数据的逐像素干净动态真值。可利用的资源是低增益静态序列、同场景不同增益拍摄、平场与黑帧标定，以及少量其他传感器的真实场景流。因此，研究首先需要解决监督从哪里来，再判断相应监督能够支撑哪些模型改动。

## 1.2 研究过程与报告主线

项目从静态去噪出发。方法 0 至方法 4 依次完成数据适配、参考构建、噪声合成、模型微调和评估，形成方法 3 这一可用基线。随后，静态监督中的运动排除机制暴露出动态内容被过度平滑的现象，推动了方法 5 至方法 7 的运动保真探索。跨传感器测试又引出了方法 8 至方法 10 的适配与退化建模。最后，全数据集预览中的高增益动态表现促成了方法 11 的置信门控实验。

这些探索均以同一基线作比较，最终默认权重仍为方法 3 的第 5000 步 EMA；方法 8 仅保留 sc635hai 专用输出头。下文先简述各条路线的设计、结果及取舍，再完整说明最终采纳方案，最后集中展示其在多种公司数据集上的泛化效果。方法编号沿用原实验顺序；复现文件保留项目中的原始名称。

# 2 相关工作与数据基础

## 2.1 技术背景

RAW 保留了传感器的线性响应和 Bayer 采样信息，适合在噪声统计层面建立恢复模型。CRVD/RViDeNet[1]、RViDeformer[2] 和 RVRT[3] 利用多帧信息进行恢复；HDR+[10]、Deep Burst Denoising[9] 与核预测方法 [17] 则体现了对齐和帧间融合对低照度成像的作用。EMVD[15]、FastDVDNet[16] 以及 DnCNN[14]、CBDNet[20] 提供了不同的时空恢复与真实噪声建模思路；NL-means[18] 和 BM3D[19] 是非局部恢复的经典参照。本项目采用官方 CRVD 权重初始化 RViDeformer-L，在公司数据上微调。

在缺少干净真值时，Noise2Noise[4] 依赖噪声观测之间的统计关系，Noise2Void[5] 与 Noise2Self[6] 通过盲点构造自监督。静态长序列还可利用时域均值降低随机噪声，但运动区域的均值会混合不同时间的内容。项目据此将静态均值监督与动态探索分开处理，不把动态均值直接当作干净目标。

噪声标定以信号相关方差模型 [7] 为基础，并参考 RAW 数据合成的思路 [8]。实际生成器采用逐增益经验系数、通道相关高斯采样、固定图样偏置和量化。动态探针使用 DIS 光流 [11]。视觉比较在各自协议内冻结 ISP 参数；全数据集预览使用 Reinhard 色调映射 [12]，奇偶参考面板

和专用头比较沿用原审计渲染。

## 2.2 公司数据集与实验分工

全数据集预览覆盖 4 种传感器的 45 条原始 RAW 流，其中 27 条为场景流、18 条为标定流。按传感器统计，MIS20S1 为 29 条（含 18 条标定），SC465SL 为 12 条，sc635hai 和 sc450ai 各 2 条。包含其他算法 2DNR/3DNR 处理的 03 组派生流不计入这 45 条。

表 1: 主要数据集、内容与实验用途。

| 数据集 | 内容 | 用途 |
|---|---|---|
| MIS20S1 暗房 | 同场景 7 档增益，10x–1000x | 10x 静态主参考；128x/313x/632x/645x 真实训练；1000x 真实增益留出 |
| MIS20S1 室外 | 黄昏公园、人物运动，4 档增益 | 场景迁移与高增益动态展示 |
| MIS20S1 标定 | 9 档平场、9 档黑帧，每流 50 帧 | 噪声拟合与合成验证；不作为场景泛化成绩 |
| SC465SL 暗室 | 256x、2000x，各 300 帧 | 未参与方法 3 训练的跨传感器静态定量 |
| SC465SL 超市与复杂纹理 | 增益梯子及 difficultpattern，共 10 流 | 多场景视觉与复杂纹理动态测试 |
| sc635hai | 131x 低色温 150 帧、16x 运动彩色 200 帧 | 方法 3 零样本测试；131x 另用于方法 8 适配，16x 保留 |
| sc450ai | 804x 灯光变化 150 帧、1435x 黑物运动 210 帧 | 跨传感器压力测试；1435x 不参与适配 |

## 2.3 RAW 适配与参考资格

不同数据源的位对齐、CFA 和黑电平并不统一。04 场景流和 05 组通常需要从高 12 位右移 4 位；02 组采用低位对齐。sc450ai 虽然附带说明写为高 12 位和 4128 DN 黑电平，实测却是低位对齐、有效 10 位，样本均落在 4 DN 格点，黑电平约 256–258 DN。若直接套用说明，会把有效信号裁掉。场景流以 RGGB 为主，标定流为 GRBG；所有数据经适配器转换到统一的 R/Gr/Gb/B 通道顺序。

黑电平逐流、逐通道测量；帧数从文件字节数核实。标称增益不作为网络输入条件，因为不同档位伴随照明变化，实际噪声不随标签单调增加。例如暗房 128x 的分半绿色通道噪声约 79.05 DN，1000x 约 28.93 DN。噪声合成因此使用标定实测系数，而非只按场景文件名推断强度。

监督资格随数据而定。10x 低增益静态参考用于主方法训练；同流奇偶分半参考用于可信静态区域的测试或适配。旧教师输出、运动时域均值和盲点观测只作为对应探索的信号，不被登记为干净动态真值。

### 2.4 评测口径

静态评测在有效区域计算对应参考 DN 域的 PSNR、RMSE、高频保持率和残差。645x 使用映射到 10x 亮度的参考域，1000x 及跨传感器静态测试使用各自 native DN 域。跨传感器测试采用互斥奇偶帧池：偶数帧片段对奇数帧参考，再交换方向；只保留在全部、奇数、偶数帧池中均达到 90% 静态置信度的像素。运动筛选采用 $\text{median} + 3 \times 1.4826 \times \text{MAD}$ 的鲁棒阈值。

动态序列没有干净逐帧目标，报告其时序响应、高频与裁剪等诊断量，并结合固定 ISP 视频观察。高频比下降既可能来自去噪，也可能来自结构损失；temporal MAD 下降既可能表示抑制噪声，也可能表示运动被平均。因此，两者均与视觉结果一起解释。

所有同序列输入与输出共享白平衡和曝光，关闭 ISP 的 2DNR/3DNR。全数据集展示采用 edge-aware 去马赛克、高光重建和 Reinhard 映射。PSNR 在 RAW 域计算，展示视频用于观察降噪、纹理与运动；不同数据集的参考域和有效区域不同，绝对 PSNR 不作跨数据集排名。

## 3 试过的方法与方案选择

### 3.1 方法 0 至方法 4：形成静态基线

方法 0 建立逐流适配、配准、曝光映射与运动掩码。方法 1 用暗房 10x 的 200 帧构建静态参考，奇偶均值残差为 0.51–0.80 DN，曝光归一化后的跨增益偏差为 1.17–1.86 DN。方法 2 利用平场和黑帧生成 9 档合成噪声，最大逐通道统计误差 8.66%，低于 15% 验收阈值。上述准备共同支撑方法 3 的混合数据微调，方法 4 负责评估。

评估中出现过一次口径修正：1000x 与 10x 跨捕获曝光关系在高亮处偏离线性，同一模型按该映射仅有 18.84 dB；配准复核后，改用 1000x 自身的静态参考得到 53.27 dB，奇偶互斥验证为 53.10/53.07 dB。该结果使项目保留方法 3，并将跨捕获映射与模型误差分开检查。方法 3 的监督、损失和推理流程在第 4 节统一说明。

### 3.2 方法 5 至方法 7：运动保真探索

方法 3 的静态去噪改善后，645x 视频中的运动人物仍有半透明残影。原运动审计中，输出的运动区帧差仅为输入的 27%–32%。这推动了三条后续路线，比较时均要求运动响应改善且静态、原生增益及高频指标不回退。

表 2: 运动保真路线的简要比较。

| 方法 | 设计 | 主要结果 | 取舍 |
|---|---|---|---|
| 方法 5 | 光流对齐的动态 N2N；教师静态锚；冻结范围与损失权重实验 | 收紧运动置信规则后覆盖仅 1.81%–3.82%；多组候选未同时通过运动、静态和 1000x 门槛 | 未采纳 |
| 方法 6 | 冻结方法 3，训练空间残差运动专家；共 4 版 | 门控 IoU 达 0.533，但真实动态内容未稳定恢复；更强残差伴随静态偏移或目标误差增大 | 未采纳 |
| 方法 7 | 在运动区融合旧教师残差，扫描 36 组配置 | 最强配置的运动比相对增加 0.9162%；固定 ISP 未见稳定的人物轮廓改善 | 未采纳 |

方法 5 用 DIS 光流将后帧对齐到当前帧，以前后向误差和光度误差筛选可信像素。增加严格的 1 像素运动门槛后，监督覆盖明显缩小。方法 6 转而冻结主干，减少全模型漂移；方法 7 再取消训练，检验旧教师残差是否能直接补充运动信息。三者依次减少了参数更新带来的影响，但在既定数据与验收条件下，均未得到足以替换基线的结果。

因此，后续实验继续保留方法 3，研究重心转向跨传感器：先测同一权重在哪些数据域有效，再决定是否需要目标域适配。

### 3.3 方法 8 至方法 10：跨传感器适配与退化验证

零样本测试表明，方法 3 在 SC465SL 暗室和 sc635hai 低色温静态域有明显降噪收益，而 sc450ai 黑色运动物体仍明显发软。方法 8 据此考察逐传感器适配：sc635hai 使用奇偶静态监督，sc450ai 使用单帧盲点监督，均混入 MIS20S1 回放。结果仅保留 sc635hai 的专用输出头，详细配置见第 4.6 节；sc450ai 的 5 个检查点均没有恢复高频，1435x 端点裁剪还从 3.28% 升至 4.64%。

方法 9 尝试统一微调 4 种传感器，只更新 15,508 个参数、训练 100 步。SC465SL 和 sc635hai 静态指标略升，但 sc450ai 的高频比由 0.126621 降至 0.126589，未改善黑衣与运动轮廓，故没有作为统一模型采纳。

方法 10 随后检查 sc450ai 的监督来源。现有数据只有两条动态场景流，没有独立暗场、平场或干净 RAW 配对。其补充退化实验比较了原独立噪声、4 DN 量化独立噪声和频谱整形噪声；频谱整形虽改善 804x 的聚合相关误差，却未通过逐通道噪声与 1435x 保留集验证。该生成器未进入最终方法。

这组实验使最终方案保持清晰：默认使用同一方法 3 权重评测泛化，仅给 sc635hai 保留一个专用可选头。目标域的零样本结果与专用适配结果分别报告。

### 3.4 方法 11：高增益推理门控

全数据集预览显示，MIS20S1 室外 1500x 等序列仍有运动朦胧。四路诊断比较原始输入、正常时域推理、加权空间拼接和单帧重复 8 次的推理：改变拼接权重对主体影响很小，单帧重复则恢复了更多当前帧结构，同时带回明显彩噪。这些观察支持将时域融合视为该现象的重要来源。

方法 11 尝试用输入残差、梯度和光流置信度，在正常时域输出与单帧重复输出之间融合。两条代表序列的非零门控覆盖仅 0.487% 和 0.713%，全局输出接近原时域分支，逐帧观察也未见稳定的主体重影改善，因此未纳入最终推理流程。

### 3.5 最终方案的确定

上述探索分别检验了训练监督、可训练模块、教师残差、传感器适配和推理融合。最终保留的方法 3 具有完整的监督与评测记录，静态恢复结果稳定；后续路线未在各自目标上满足替换条件。方法 8 的 sc635hai 输出头则以专用可选权重单独保留。接下来围绕这两项说明最终实现，并将其效果统一放到多数据集测试中展示。

## 4 最终采纳的方法

### 4.1 整体流程

默认方法由四个环节组成：RAW 适配、可信静态监督、真实与合成混合训练、EMA 多帧推理。方法 0 至方法 2 提供的数据处理和监督构造均属于方法 3 的完整训练管线。

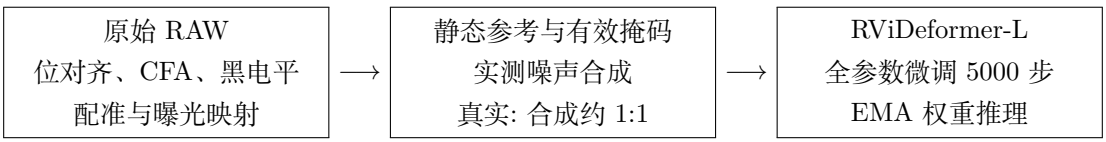



图 1: 最终方法 3 的完整流程。训练数据进入统一参考域；输出在对应协议的参考 DN 域评测，再使用该协议的固定 ISP 展示。

模型输入为 8 帧、4 通道的 packed Bayer，输出对应的 8 帧。训练采用 $64 \times 64$ packed patch，即原 Bayer 的 $128 \times 128$ 区域；推理通过重叠分块处理完整画面。方法 3 不增加增益标签输入或传感器条件分支。

### 4.2 真实样本与静态监督构建

主参考来自 MIS20S1 暗房 10x 序列的 200 帧平均。参考构建包含固定图样修正，并记录运动及无效区域。参考形状为 $4 \times 540 \times 960$。奇偶分半残差在 R/Gr/Gb/B 上分别为 0.511、0.797、0.763 和 0.560 DN；图卡高频检查确认平均后仍保留可用结构。

真实输入选用 128x、313x、632x 和 645x。对每个输入增益，先读取其位对齐、黑电平和运动记录，再使用整数配准及逐通道仿射曝光映射进入主参考坐标和亮度域。设映射后的像素为 $x_c$，参考黑电平为 $b_c$，归一化为

$$\widetilde{x}_c = \mathrm{clip}\left(\frac{x_c - b_c}{4095 - b_c}, 0, 1\right). \tag{1}$$

目标为相同位置的静态参考，在 8 个时间位置上重复。

有效掩码同时满足参考有效、输入 8 帧均为静态、全部输入通道均未饱和。饱和阈值为映射域 3800 DN，运动掩码阈值为 0.5。只有这些位置参与损失，避免对错位运动和饱和内容施加静态

均值目标。1000x 真实序列不进入训练。

### 4.3 实测噪声合成与混合采样

合成分支仍以同一静态参考为干净目标，通过 9 档平场与黑帧建立噪声模型。信号相关方差可写为

$$\sigma_c^2(s,G) = a_c\, sG + b_c^{\mathrm{read}} G^2. \tag{2}$$

实际生成器保留了每档增益的经验 shot 系数 $\alpha_{c,g}$ 和 read variance $v_{c,g}$，用于处理标定中的非单调变化。令 $d$ 为固定图样偏置，$z \sim \mathcal{N}(0, I)$，$LL^\top = C$ 为聚合通道相关矩阵的 Cholesky 分解，则合成为

$$q = y + d, \qquad s_c = \max(q_c - b_c, 0), \tag{3}$$

$$x^{\mathrm{syn}} = \mathrm{clip}\left(\mathrm{round}\left[q + \sqrt{\alpha_g \odot s + v_g} \odot (Lz)\right], 0, 4095\right). \tag{4}$$

该实现使用相关高斯采样匹配信号相关方差。合成后按 1 DN 格点量化，保留原始黑电平与合法范围。

合成增益标签为 100、200、400、800、1600、3200、6400、12800 和 25600，每档生成 8 个独立噪声时序变体。8 帧具有相同干净内容和不同噪声，真实与合成分支按约 1:1 混合。真实性检验比较合成与真实同档数据的高通差分噪声，最大逐通道相对误差 8.66%，通过 15% 阈值。逐档参数列于附录。

### 4.4 网络与优化目标

网络采用 RViDeformer-L，严格加载官方 CRVD 权重后全参数微调。构造配置包含 11 组深度参数，前 7 组深度为 4、嵌入维度 84，后 4 组深度为 2、嵌入维度 108；注意力头数均为 6，时空窗口为 $6 \times 8 \times 8$。重建使用浅层特征残差连接，最终卷积输出再与输入 RAW 相加。实际模型共有 7,505,716 个可训练参数。完整构造参数见表 9。

训练先将预测裁剪到 $[0, 1]$，再计算带掩码的损失。记

$$\langle z \rangle_M = \frac{\sum M \odot z}{\max(\sum M, 1)}, \tag{5}$$

其中掩码沿通道维展开。总损失为

$$\mathcal{L} = \mathcal{L}_{\mathrm{char}} + 0.1\mathcal{L}_{\mathrm{grad}} + 0.1\mathcal{L}_{\mathrm{hp}}. \tag{6}$$

Charbonnier 项 [13] 约束重建误差：

$$\mathcal{L}_{\mathrm{char}} = \left\langle \sqrt{(\hat{y} - y)^2 + 10^{-6}} \right\rangle_M. \tag{7}$$

若写为 $\epsilon^2$，则 $\epsilon = 10^{-3}$。梯度项约束水平、垂直梯度的幅值差：

$$\mathcal{L}_{\mathrm{grad}} = \tfrac{1}{2}\left( \langle ||D_x\hat{y}| - |D_x y|| \rangle_{M_x} + \langle ||D_y\hat{y}| - |D_y y|| \rangle_{M_y} \right), \tag{8}$$

其中 $M_x, M_y$ 是相邻有效掩码的乘积。高通项为

$$H(u) = u - \mathrm{AvgPool}_{3\times3}(u), \qquad \mathcal{L}_{\mathrm{hp}} = \langle |H(\hat{y}) - H(y)| \rangle_M. \tag{9}$$

高通仅在空间计算，不跨时间平均。重建项负责整体恢复，两个 0.1 权重的结构项补充边缘和局部高频约束。

### 4.5 训练、权重选定与完整画面推理

方法 3 使用 batch size 1、固定学习率 $10^{-4}$ 的 Adam，以 FP32 完成总计 5000 步训练。训练从第 200 步恢复至第 5000 步；总步数不额外累加。EMA 衰减为 0.999，逐优化步更新。最终固定第 5000 步 EMA，后续探索和多数据集测试均使用该权重作为默认模型。

完整画面推理采用 8 帧时间窗口、时间步长 4，空间 tile 为 $64 \times 64$ packed、步长 56。空间和时间重叠处等权平均；不足 8 帧时重复末帧补齐。输出归一化裁剪后，按相应评测管线恢复 DN 值。分块批大小仅影响一次并行处理多少 tile，不改变训练 batch size。

### 4.6 sc635hai 专用可选输出头

方法 8 在方法 3 EMA 基础上冻结主干，仅更新 `norm`、`conv_after_body` 和 `conv_last`，共 6 个张量、12,400 个参数。对应头部由 108 维 LayerNorm、$108 \to 84$ 线性映射及 $84 \to 4$、核为 $1 \times 3 \times 3$ 的卷积组成。

适配使用 sc635hai 131x 低色温序列，奇偶输入与参考帧池互斥；以 0.5 概率混入 MIS20S1 回放，减少原域漂移。batch size 为 1、学习率 $10^{-5}$、训练 500 步，采用 BF16 autocast、FP32 损失和 0.999 EMA；梯度范数裁剪为 1.0。实际 500 步中，sc635hai 采样 238 步，回放 262 步。16x 运动彩色序列完整保留，不参与反向传播。

该输出头通过既定自动检查并被登记为 sc635hai 专用可选权重；默认方法 3 继续用于统一比较。下节分别展示默认权重的零样本结果和专用头的适配结果。

## 5 多数据集泛化效果展示

### 5.1 展示范围与分组

本节展示的是**公司多数据集、跨传感器及跨拍摄条件的泛化表现**。默认方法 3 只在 MIS20S1 暗房真实样本及其合成噪声上训练；SC465SL、sc635hai 和 sc450ai 均以同一权重先做零样本测试。MIS20S1 室外用于检查场景变化，1000x 用于检查未参与训练的真实增益。另列的方法 8 结果只表示 sc635hai 专用适配。

45 条原始流均完成输入与方法 3 的固定 ISP 对比。每流取首、中、尾 3 个连续 8 帧片段，共 24 帧，总计 1080 帧。27 条场景流用于观察画质，18 条标定流用于噪声与数值诊断；45/45 表示推理覆盖。以下按具体数据集给出静态指标和代表画面。

### 5.2 MIS20S1：训练覆盖增益与未见真实增益

表 3: MIS20S1 静态结果。645x 在训练覆盖内，使用 10x 跨增益参考；1000x 真实序列未参与训练，使用原生静态参考。

| 协议 | 输入 PSNR (dB) | 方法 3 PSNR (dB) | 提升 (dB) | 输入 RMSE (DN) | 方法 3 RMSE (DN) | HF 比 |
|---|---|---|---|---|---|---|
| 645x 跨增益参考 | 24.3519 | 29.5729 | +5.2210 | 248.1197 | 136.0228 | 0.9712 |
| 1000x 原生参考 | 44.6204 | 53.2675 | +8.6471 | 24.0565 | 8.8895 | 0.8562 |

645x 的噪声显著下降，高频比 0.9712，说明静态图卡结构与参考较为接近。图 2 展示同帧输入与最终输出：墙面和图卡周围的彩噪减少，棋盘、文字及卡片轮廓仍可分辨。由于 645x 参与训练，这一行用于说明训练域的恢复效果，不作为未见增益成绩。




图 2: MIS20S1 暗房 645x 固定 ISP 对比，上为全景，下为固定中心裁剪。该图展示最终方法 3 在训练覆盖域的恢复效果；静态定量只统计有效区域。

1000x 原生参考评测的 PSNR 提升 8.65 dB，RMSE 由 24.06 DN 降至 8.89 DN。为检查同流参考的影响，另使用互斥奇偶帧池验证，方法 3 得到 53.10/53.07 dB。该结果与完整原生参考评测接近，支持模型对未参与训练的 1000x 真实流具有静态去噪能力；它仍是同一暗房场景下的真实增益测试。




图 3: MIS20S1 1000x 输入、方法 3 与原生参考。该序列不参与主方法训练；展示保持相同亮度映射，定量按表 3 所列协议计算。

### 5.3　SC465SL 与 sc635hai：跨传感器零样本静态泛化

表 4 中所有结果使用同一方法 3 EMA，没有目标传感器训练。SC465SL 两档增益的提升为 10.52–13.21 dB，sc635hai 低色温静态提升约 13.59 dB。两个奇偶方向的结果接近，且高频保持率为 0.911–0.958；输出 legal RAW fraction 均为 100%。

表 4: 不同数据集上的零样本静态泛化。偶/奇表示输入帧池，参考使用相反奇偶池；HF 为输出/参考高频 RMS，MAD 为时序平均绝对差。

| 数据集 | 输入池 | 输入 PSNR (dB) | 方法 3 PSNR (dB) | 提升 (dB) | HF 比 | MAD 输入 → 输出 (DN) |
|---|---|---|---|---|---|---|
| SC465SL 256x | 偶 | 41.840 | 55.052 | +13.211 | 0.957 | 31.889→1.567 |
| | 奇 | 41.840 | 54.999 | +13.158 | 0.958 | 31.886→1.578 |
| SC465SL 2000x | 偶 | 46.039 | 56.563 | +10.523 | 0.911 | 20.238→1.312 |
| | 奇 | 46.034 | 56.647 | +10.613 | 0.912 | 20.248→1.301 |
| sc635hai 131x | 偶 | 38.737 | 52.325 | +13.588 | 0.919 | 47.481→2.165 |
| | 奇 | 38.736 | 52.324 | +13.587 | 0.921 | 47.481→2.163 |

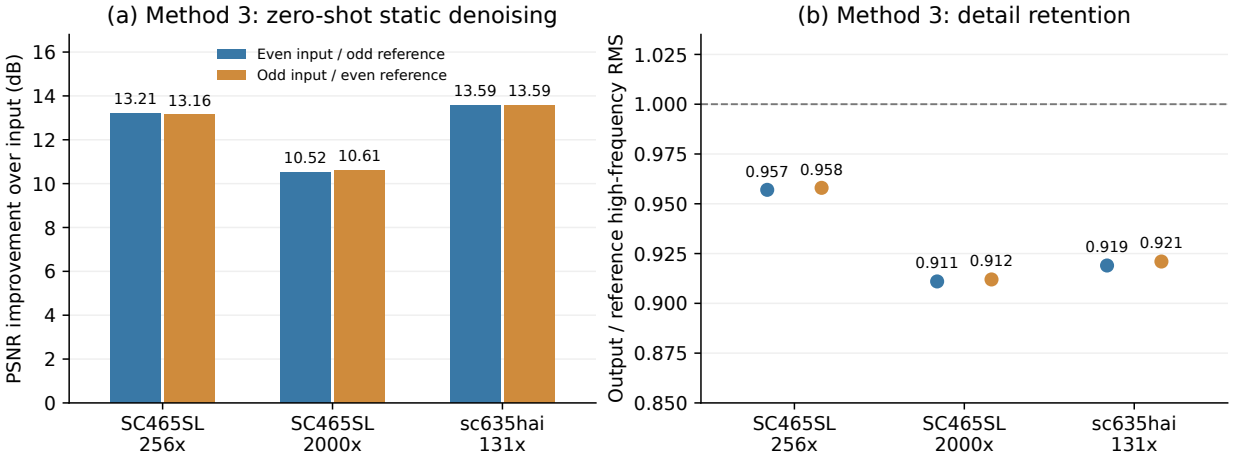



图 4: 方法 3 在三组未参与训练的目标域静态数据上的泛化：左为相对输入的 PSNR 提升，右为高频保持率。数据来自表 4，参考均采用互斥奇偶帧池。

SC465SL 两档结果在图 5 和图 6 中展示。输入中的细碎彩噪和背景波动得到抑制，风扇、人偶、线缆及背景卡片仍可辨。两图来自完整画面预览，静态定量则按各自的有效区域计算。

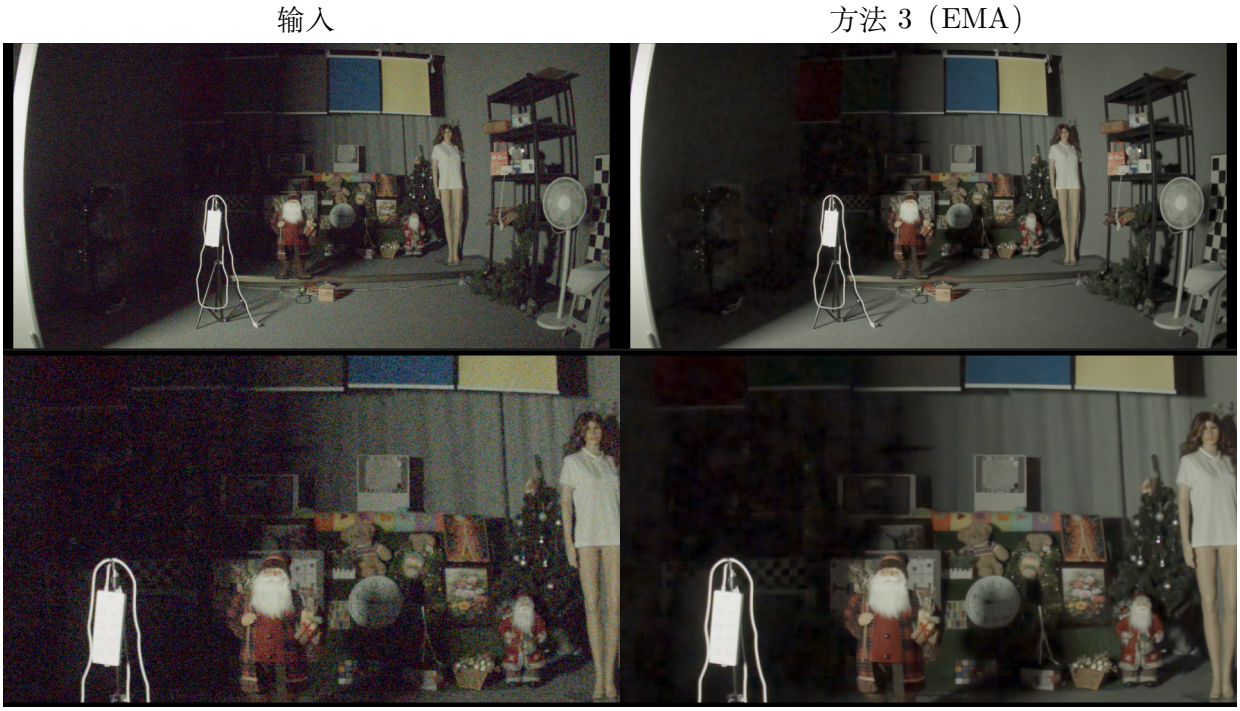



图 5: SC465SL 暗室 256x 的零样本结果，上为全景，下为中心裁剪。模型未在 SC465SL 训练；固定 ISP 下可观察到明显降噪及背景结构保留。




图 6: SC465SL 暗室 2000x 的零样本结果，使用与 256x 相同的方法 3 权重和推理流程。静态 PSNR 提升约 10.52–10.61 dB，高频比约 0.911–0.912。

sc635hai 131x 在低色温和较大蓝通道白平衡补偿下，仍显示较强的静态去噪能力。图 7 给出输入、方法 3 与相反奇偶池静态参考，展示背景卡片和人偶结构的保留。表 4 对应方法 3 的零样本结果；后续使用 131x 训练专用头所得的数字单独列在第 5.4 节，保持两个实验的含义独立。




图 7: sc635hai 131x 低色温数据集的零样本静态对比，选自偶输入方向的第 8 帧。参考为对侧奇数帧池的静态均值，动态像素不计入静态指标。

### 5.4 sc635hai 专用输出头：适配域与动态保留集

方法 8 的 131x 指标来自训练数据尾段复评，该尾段参与过训练采样，不计为独立泛化结果。表 5 显示，专用头在静态域仅带来约 0.034 dB 的小幅变化，高频与时序指标保持接近。其 16x 动态保留集未参加训练；由于缺少干净动态目标，只报告诊断量。

表 5: sc635hai 专用头效果。131x 为训练数据尾段复评，16x 为完整保留的动态序列；本表与零样本表采用不同评测样本，基线数值不混用。

| 数据与协议 | 指标 | 方法 3 | 方法 8 专用头 |
|---|---|---|---|
| 131x 适配域 | 静态 PSNR，偶方向 (dB) | 52.3535 | 52.3875 |
| | 静态 PSNR，奇方向 (dB) | 52.3552 | 52.3884 |
| | HF 比（约） | 0.9199 | 0.9181 |
| | temporal MAD(DN) | 2.1628 | 2.1247 |
| 16x 动态保留集 | HF 诊断比 | 0.763605 | 0.763078 |
| | motion/input ratio | 0.599602 | 0.596438 |
| | temporal MAD(DN) | 14.6745 | 14.6218 |
| | 端点裁剪 | 2.1994% | 1.9344% |
| | legal RAW fraction | 100% | 100% |

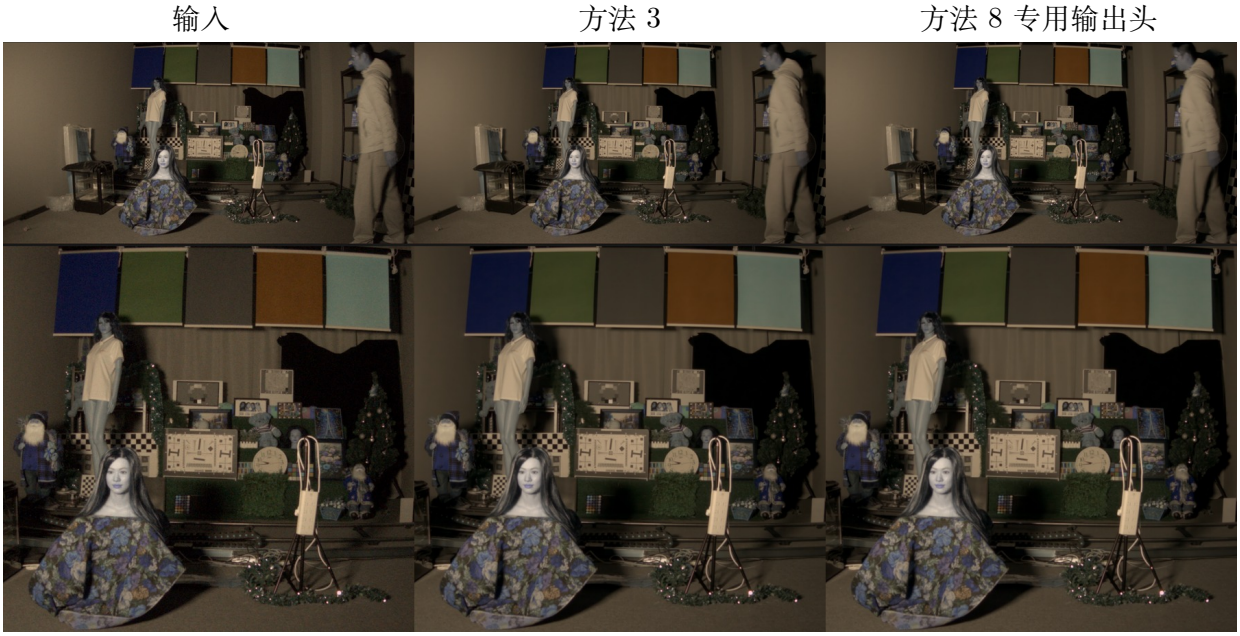



图 8: sc635hai 16x 动态保留集：输入、默认方法 3 和方法 8 专用输出头。两种输出在结构与纹理上接近，固定 ISP 首、中、末帧复核未见明显新增重影、断边或色偏。

方法 8 的变化主要集中在输出映射，未形成可辨的动态结构提升，因此保留其“sc635hai 专用可选头”的身份。跨传感器静态泛化的主要证据仍是未经目标域适配的方法 3。

### 5.5 室外、高增益和 sc450ai 数据集的实际输出

多数据集展示也包含强噪声、运动和复杂纹理。MIS20S1 室外 1500x 与训练暗房具有场景和噪声差异。图 9 中方法 3 明显压低彩噪，但人物局部有姿态平均，树木纹理偏软。该序列没有干净动态参考，因此不提供动态 PSNR。

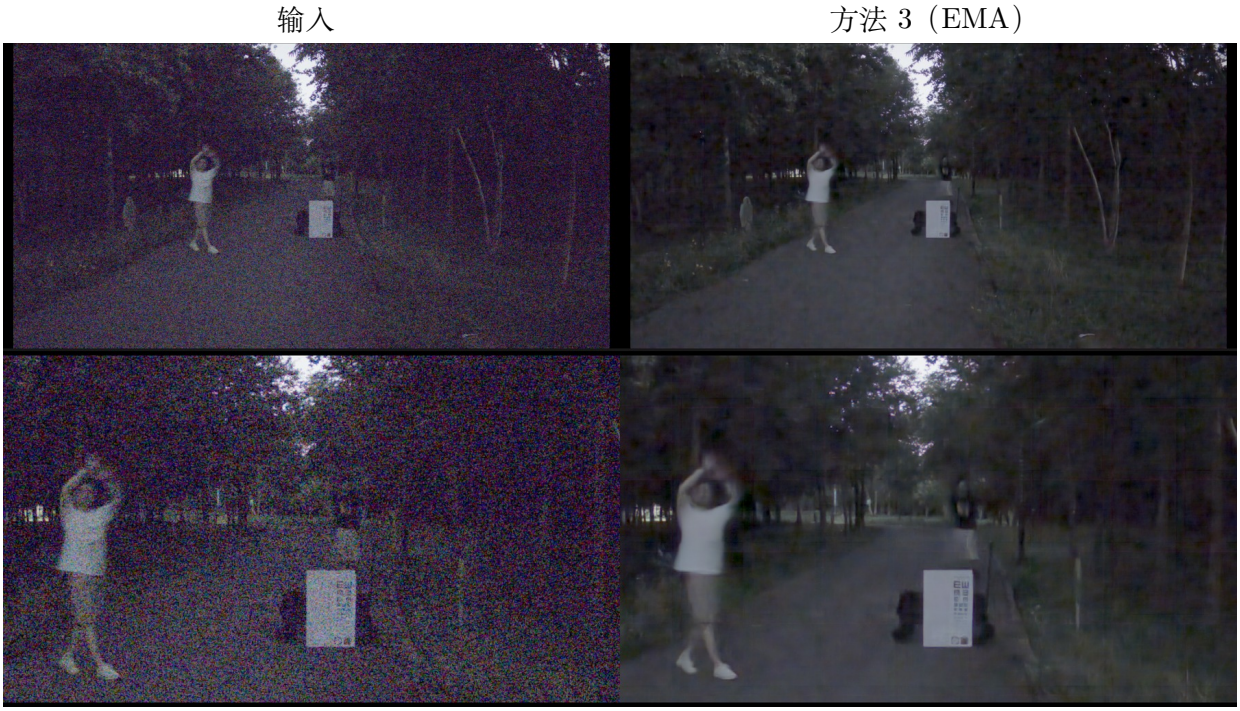



图 9: MIS20S1 室外 1500x 跨场景输出。上为全景，下为中心裁剪；同一默认方法 3 显著降噪，同时可见人物与背景细节的平滑现象。

sc450ai 1435x 黑物运动在零样本诊断中，高频比为 0.127，端点裁剪约 3.28%，运动/静态时序比为 0.057/0.088。图 10 保留了方法 3 原始结果：黑衣内部结构偏空、边界偏软。804x 灯光变化的高频比为 0.690，暗部仍有低频色斑。SC465SL difficultpattern 视频也观察到拖影和重影。上述画面与前三组静态定量共同构成了多数据集展示的完整结果。

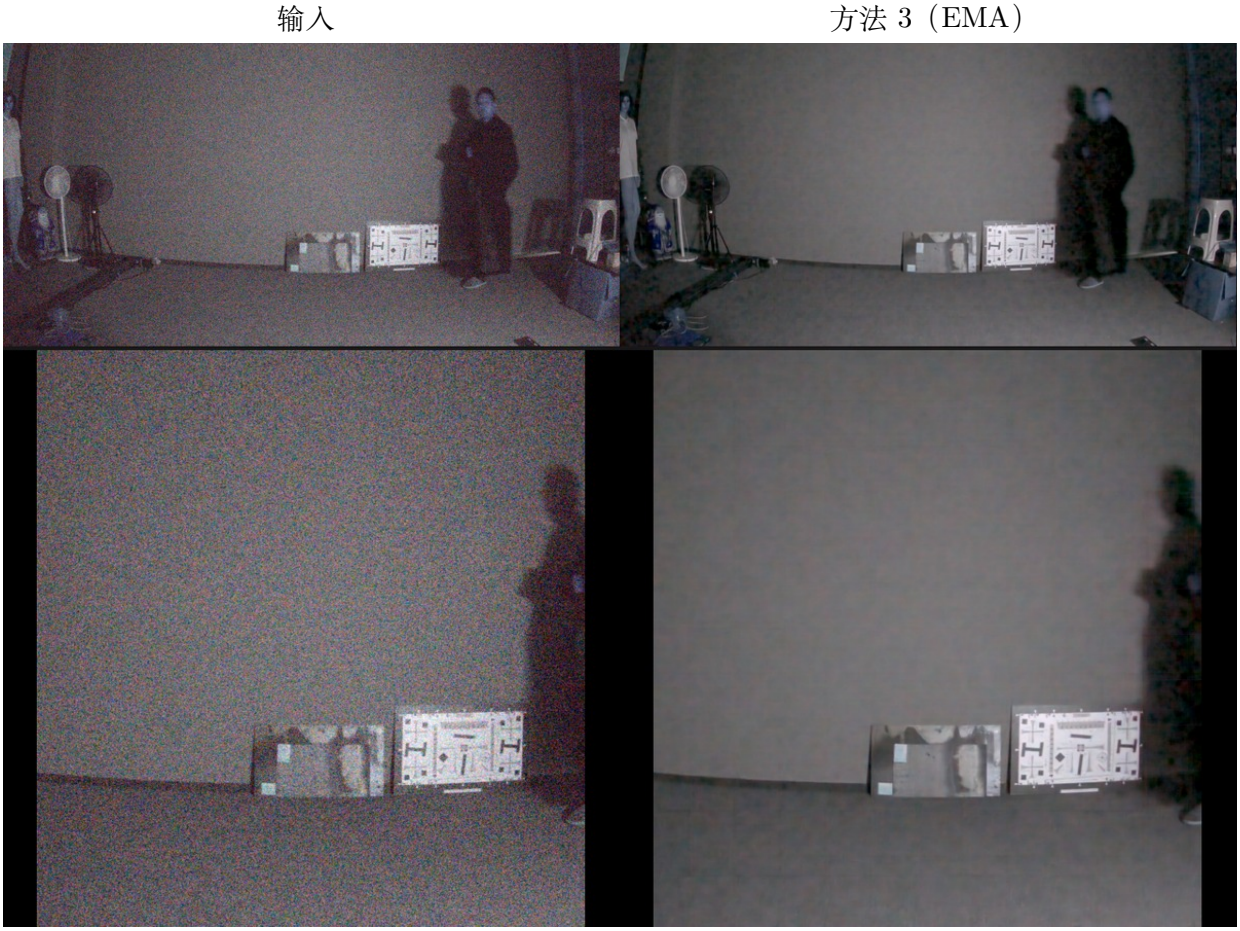



图 10: sc450ai 1435x 黑物运动的零样本结果。此处仅显示原对比图的输入与最终方法 3 两列；黑色衣物内部与运动轮廓仍偏软。

表 6: 最终方法在不同公司数据集中的展示结果。

| 数据条件 | 使用权重与协议 | 已观察结果 |
|---|---|---|
| MIS20S1 暗房 645x | 方法 3；训练覆盖域、跨增益参考 | +5.22 dB，HF 0.971 |
| MIS20S1 暗房 1000x | 方法 3；真实增益留出、原生参考 | +8.65 dB；互斥奇偶验证 53.10/53.07 dB |
| SC465SL 暗室 256x/2000x | 方法 3；跨传感器零样本静态 | +10.52–13.21 dB，HF 0.911–0.958 |
| sc635hai 低色温 131x | 方法 3；跨传感器零样本静态 | 约 +13.59 dB，HF 0.919–0.921 |
| sc635hai 动态 16x | 方法 3 及方法 8 专用头；动态保留集 | 两者画面接近；专用头未见明显新增伪影 |
| MIS20S1 室外 1500x | 方法 3；跨场景动态观察 | 噪声下降，人物姿态与树木结构偏平滑 |
| sc450ai、复杂纹理动态 | 方法 3；零样本压力测试 | 可见结构平滑、色斑或重影，不计为通过的静态泛化结果 |

# 参考文献

[1] H. Yue, C. Cao, L. Liao, R. Chu, and J. Yang. Supervised Raw Video Denoising With a Benchmark Dataset on Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2301–2310, 2020.

[2] H. Yue, C. Cao, L. Liao, and J. Yang. RViDeformer: Efficient Raw Video Denoising Transformer With a Larger Benchmark Dataset. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(9):8929–8944, 2025. DOI: 10.1109/TCSVT.2025.3553160.

[3] J. Liang, Y. Fan, X. Xiang, R. Ranjan, E. Ilg, S. Green, J. Cao, K. Zhang, R. Timofte, and L. Van Gool. Recurrent Video Restoration Transformer with Guided Deformable Attention. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[4] J. Lehtinen, J. Munkberg, J. Hasselgren, S. Laine, T. Karras, M. Aittala, and T. Aila. Noise2Noise: Learning Image Restoration without Clean Data. In *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 80:2965–2974, 2018.

[5] A. Krull, T.-O. Buchholz, and F. Jug. Noise2Void – Learning Denoising from Single Noisy Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2129–2137, 2019.

[6] J. Batson and L. Royer. Noise2Self: Blind Denoising by Self-Supervision. In *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 97:524–533, 2019.

[7] A. Foi, M. Trimeche, V. Katkovnik, and K. Egiazarian. Practical Poissonian-Gaussian Noise Modeling and Fitting for Single-Image Raw-Data. *IEEE Transactions on Image Processing*, 17(10):1737–1754, 2008.

[8] T. Brooks, B. Mildenhall, J. T. Barron, J. Chen, D. Sharlet, and R. Ng. Unprocessing Images for Learned Raw Denoising. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11036–11045, 2019.

[9] C. Godard, K. Matzen, and M. Uyttendaele. Deep Burst Denoising. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.

[10] S. W. Hasinoff, D. Sharlet, R. Geiss, A. Adams, J. T. Barron, F. Kainz, J. Chen, and M. Levoy. Burst Photography for High Dynamic Range and Low-Light Imaging on Mobile Cameras. *ACM Transactions on Graphics*, 35(6):192, 2016.

[11] T. Kroeger, R. Timofte, D. Dai, and L. Van Gool. Fast Optical Flow Using Dense Inverse Search. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 471–488, 2016.

[12] E. Reinhard, M. Stark, P. Shirley, and J. Ferwerda. Photographic Tone Reproduction for Digital Images. *ACM Transactions on Graphics*, 21(3):267–276, 2002.

[13] P. Charbonnier, L. Blanc-Feraud, G. Aubert, and M. Barlaud. Two Deterministic Half-Quadratic Regularization Algorithms for Computed Imaging. In *Proceedings of the IEEE International Conference on Image Processing (ICIP)*, vol. 2, pp. 168–172, 1994.

[14] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.

[15] D. Maggioni, E. Sanchez-Monge, and A. Foi. Efficient Multi-Stage Video Denoising With Recurrent Spatio-Temporal Fusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[16] M. Tassano, J. Delon, and T. Veit. FastDVDNet: Towards Real-Time Deep Video Denoising Without Flow Estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[17] B. Mildenhall, J. T. Barron, J. Chen, D. Sharlet, R. Ng, and R. Carroll. Burst Denoising with Kernel Prediction Networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.

[18] A. Buades, B. Coll, and J.-M. Morel. A Non-Local Algorithm for Image Denoising. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2005.

[19] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian. Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering. *IEEE Transactions on Image Processing*, 16(8):2080–2095, 2007.

[20] S. Guo, Z. Yan, K. Zhang, L. Zhang, and W. Zuo. Toward Convolutional Blind Denoising of Real Photographs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

# A 采纳方法的超参数与模型配置

本附录记录最终方法 3 及方法 8 的 sc635hai 专用可选头。训练设置以最终 checkpoint 中保存的配置和优化器状态为准，模型与损失以对应实现核对；展示视频的编码以实际产物为准。下列路径均相对于项目根目录。

## A.1 权重与运行环境

**项目目录** `/Data4/Xiao/RECOVERED_Stage2_DenoiseModel_20261010`

**Python** `/home/jingzeliang/miniconda3/envs/aaa_312/bin/python`

**方法 3 最终权重** `artifacts/finetune_mis20s1/training/checkpoint_step_005000.pth`，读取 `ema` 字段。

**方法 3 SHA-256** `97c4332f685f98959b243e4b100434469f714aed6329e100d22b6d8552592e0b`

**方法 8 专用权重** `artifacts/a8_sensor_adaptation/sc635hai/training_20261013/checkpoint_step_000500.pth`，读取 `ema` 字段。

**方法 8 SHA-256** `8e4980a43767b5b83ecc064e8cdce2f685ea452e94af48a1f4ca252004765b3f`

## A.2 方法 3 训练超参数

表 7: 最终主方法的训练与采样配置。

| 项目 | 实际设置 |
|---|---|
| 初始化 | 官方 `RViDeformer-L_CRVD.pth`，strict 加载；恢复后的本地预训练文件位于 `artifacts/pretrained/` |
| 可训练范围 | 全模型，共 7,505,716 个参数、1208 个参数张量 |
| 总优化步数 | 5000；从 step 200 恢复至 step 5000 |
| 训练 batch size | 1；每次优化包含 1 个 8 帧样本 |
| 学习率 | 固定 $1 \times 10^{-4}$，无学习率调度器 |
| 优化器 | Adam，$\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$ |
| 优化器其他项 | weight decay 为 0，amsgrad 为 False |
| 数值精度 | FP32；无 autocast、GradScaler 或梯度累积 |
| 梯度裁剪 | 未使用 |
| EMA | decay=0.999，每次 optimizer step 后更新参数，buffer 直接复制；推理读取 EMA |

| 项目 | 实际设置（续） |
|---|---|
| 随机种子 | 20260921；设置 Python、NumPy、PyTorch 和 CUDA 随机种子 |
| 输入/输出 | $(B,T,C,H,W)=(1,8,4,64,64)$，输出对应 8 帧 |
| 真实: 合成比例 | 配置 0.5:0.5；512 项采样序列的前 256 项为真实、后 256 项为合成 |
| 真实训练序列 | MIS20S1 暗房 128x、313x、632x、645x；不含 1000x 真实序列 |
| 真实时间采样 | 随机起点的连续 8 帧，frame stride=1 |
| 合成时间采样 | 每个增益 8 个噪声变体，从变体池循环取 8 帧，干净内容相同 |
| 裁剪与增强 | 随机 $64\times64$ packed 裁剪、真实时窗、合成噪声；未加入翻转或旋转 |
| 样本随机状态 | 索引 $i$ 使用 `seed + i * 104729`；合成变体使用 `seed + record_index * 1009 + variant` |
| DataLoader | 默认 512 项，shuffle=False，num_workers=0，drop_last=True；耗尽后重新遍历 |
| 训练输出裁剪 | 预测先 clamp 到 $[0,1]$，再计算损失 |
| 最终权重选择 | step-5000 EMA；未将后续运动、统一微调或门控候选合并进去 |

实际配置文件为 `artifacts/finetune_mis20s1/training/a3_config.json`；训练及采样实现为 `src/raw_fusion/finetune/a3.py`。

## A.3 参考、归一化与损失设置

表 8: 主方法监督与损失参数。

| 项目 | 设置 |
|---|---|
| 主参考 | MIS20S1 暗房 10x 的 200 帧；packed 形状 $(4,540,960)$ |
| 通道顺序 | R、Gr、Gb、B |
| 主参考黑电平 | R=266.125、Gr=275.625、Gb=275.375、B=267.0 DN |
| 白电平 | 4095 DN |
| 真实输入映射 | 按每条流 manifest 中的整数位移配准；逐通道 slope/intercept 映射到参考域，再按式 (1) 归一化 |
| 有效掩码 | 参考有效区 ∩ 8 帧均静态 ∩ 全部 8 帧/4 通道均未饱和；合成样本不另加运动掩码 |
| 饱和阈值 | 映射参考域 3800 DN，归一化阈值按各参考通道黑电平换算 |

| 项目 | 设置（续） |
|---|---|
| 运动阈值 | 对应采样位置的运动 mask $< 0.5$，全部 8 帧同时满足 |
| 损失总式 | $\mathcal{L}_{\text{char}} + 0.1\mathcal{L}_{\text{grad}} + 0.1\mathcal{L}_{\text{hp}}$ |
| Charbonnier | $\sqrt{(\hat{y}-y)^2 + 10^{-6}}$；标准 $\epsilon^2$ 记法下 $\epsilon = 10^{-3}$ |
| 梯度损失 | 水平、垂直梯度幅值差的 masked L1，两方向各 0.5；相邻 mask 相乘 |
| 高通损失 | $H(u) = u - \text{AvgPool3d}(u)$ 后的 masked L1 |
| 高通池化 | kernel=$(1,3,3)$，stride=1，padding=$(0,1,1)$；默认零填充且包含填充计数 |
| 掩码归约 | 掩码沿通道展开；分母为 mask.sum().clamp_min(1)，逐有效元素平均 |
| 动态损失/教师蒸馏 | 最终方法 3 未使用 |

参考统计与空间资源分别见 `artifacts/finetune_mis20s1/supervision/references/a1_reference_report.json` 和同目录 `a1_reference_manifest.json`。配准、曝光系数与运动掩码逐流记录于 `artifacts/finetune_mis20s1/supervision/stream_manifests/`，因此不以单组曝光系数替代所有流。

## A.4 网络构造参数

表 9: RViDeformer-L 在最终方法中的实际构造配置。

| 参数 | 设置 |
|---|---|
| 输入/输出通道 | 4 / 4 |
| `upscale` | 1 |
| `img_size` | [8, 64, 64] |
| `window_size` | [6, 8, 8] |
| `depths` | [4, 4, 4, 4, 4, 4, 4, 2, 2, 2, 2] |
| `embed_dims` | [84, 84, 84, 84, 84, 84, 84, 108, 108, 108, 108] |
| `num_heads` | [6, 6, 6, 6, 6, 6, 6, 6, 6, 6, 6] |
| `indep_reconsts` | [11, 12]，按构造实参记录 |
| `mul_attn_ratio` | 0.75 |
| `mlp_ratio` | 2 |
| `qkv_bias / qk_scale` | True / None |

| 参数 | 设置（续） |
|---|---|
| drop_path_rate | 0.2（配置最大值） |
| 归一化 | LayerNorm |
| pa_frames | 2 |
| deformable_groups | 12 |
| spynet_path | None |
| recal_all_flows | False |
| nonblind_denoising | False |
| 激活检查点构造参数 | use_checkpoint_attn=False，use_checkpoint_ffn=False；no_checkpoint_attn_blocks 和 no_checkpoint_ffn_blocks 均为空列表 |
| 前 7 级空间尺度 | [1, 2, 4, 8, 4, 2, 1]；先降采样再恢复 |
| 参数与 buffer | 参数 7,505,716 个；buffer 57 个，共 2,668,800 个元素 |
| 状态字典 | 每套 model/EMA 共 1265 张量，其中 1208 个为参数张量；张量个数不等于参数量 |

模型配置入口为 src/raw_fusion/finetune/a3.py 的 build_rvideformer，结构实现为 src/raw_fusion/finetune/rvideformer_arch.py。

## A.5 噪声合成参数

表 10 和表 11 列出实际生成器使用的逐档经验参数。增益标签 $g$ 对应的 $G$ 为标签除以 100；shot 系数已包含该档增益，不应在式 (4) 中再乘一次 $G$。表中数值保留 6 位小数，精确复现读取原 JSON 的完整精度。

表 10: 逐增益经验 shot 系数 $\alpha_{c,g}$，单位 DN。

| 增益标签 | $G$ | R | Gr | Gb | B |
|---|---|---|---|---|---|
| 100 | 1 | 0.146240 | 0.133124 | 0.134059 | 0.153964 |
| 200 | 2 | 0.303604 | 0.262204 | 0.263975 | 0.301672 |
| 400 | 4 | 0.595802 | 0.525547 | 0.529092 | 0.569351 |
| 800 | 8 | 1.234060 | 1.038338 | 1.045279 | 1.185013 |
| 1600 | 16 | 2.553175 | 2.271041 | 2.286595 | 2.535520 |
| 3200 | 32 | 5.057363 | 4.411844 | 4.442612 | 4.909565 |
| 6400 | 64 | 10.160087 | 8.932881 | 8.913312 | 10.015178 |
| 12800 | 128 | 24.593596 | 24.830152 | 24.722971 | 25.129168 |
| 25600 | 256 | 48.717270 | 50.454506 | 50.209071 | 50.189296 |

表 11: 逐增益 read variance $v_{c,g}$，单位 $\mathrm{DN}^2$。

| 增益标签 | $G$ | R | Gr | Gb | B |
|---|---|---|---|---|---|
| 100 | 1 | 1.582505 | 1.582505 | 1.582505 | 1.582505 |
| 200 | 2 | 2.813700 | 2.813700 | 2.813700 | 2.813700 |
| 400 | 4 | 8.617427 | 8.616957 | 8.616957 | 8.617427 |
| 800 | 8 | 29.718838 | 29.718838 | 29.718838 | 29.718838 |
| 1600 | 16 | 4.396071 | 4.396071 | 4.396071 | 4.396071 |
| 3200 | 32 | 11.254265 | 11.254265 | 11.254265 | 11.254265 |
| 6400 | 64 | 39.564642 | 34.466890 | 34.466890 | 34.467829 |
| 12800 | 128 | 114.346263 | 114.346263 | 114.346263 | 114.346263 |
| 25600 | 256 | 364.052709 | 364.046605 | 364.049657 | 364.049657 |

生成器使用的聚合通道相关矩阵为

$$C = \begin{bmatrix} 1 & 0.01588756 & 0.00647320 & 0.00093781 \\ 0.01588756 & 1 & 0.00753526 & 0.00049242 \\ 0.00647320 & 0.00753526 & 1 & 0.02030878 \\ 0.00093781 & 0.00049242 & 0.02030878 & 1 \end{bmatrix}. \tag{10}$$

固定图样偏置读取主参考 manifest 中的 `fpn_paths.offset_dn` 空间数组。每档 8 个噪声变体使用独立随机数，随后先 round 至 1 DN 格点、再 clip 至 $[0, 4095]$，保存为 uint16。完整模型位于 `artifacts/finetune_mis20s1/noise_model/noise_model.json`；生成器位于 `src/raw_fusion/finetune/noise.py` 的 `generate_noisy_frame`。

## A.6 推理、评测与固定 ISP 参数

表 12: 最终主方法的推理与展示配置。

| 项目 | 设置 |
|---|---|
| 模型状态 | EMA，eval 模式；不更新参数 |
| 连续视频时间窗口 | 8 帧，窗口步长 4；不足 8 帧时重复末帧，丢弃补齐位置的输出 |
| 空间 tile/步长 | $64 \times 64$ packed / 56 packed；完整画面覆盖 |
| 重叠区域 | 时域和空域均采用等权累计、除以覆盖计数 |
| 分块并行批大小 | 全数据集展示使用 tile_batch=12；跨传感器审计入口配置为 2，原始全帧评估入口常用 8；均不改变训练 bs=1 |
| 输出裁剪 | 归一化域 $[0, 1]$，再按对应管线恢复 DN |
| 跨传感器静态采样 | 输入与参考奇偶帧池互斥；每片段 8 帧、原视频 stride=2。SC465SL 每方向 5 片段（40 帧），sc635hai 零样本每方向 3 片段（24 帧），专用头尾段复评每方向 1 片段（8 帧） |
| 静态有效区 | 奇偶参考置信度 $\geq 0.9$ |
| 展示采样 | 每流首、中、尾各 1 个连续 8 帧片段，共 24 帧；45 流共 1080 帧 |
| 去马赛克 | canonical Bayer 重建，OpenCV edge-aware |
| 曝光选择 | 每条流由输入 99.5 百分位确定；Reinhard 后线性目标 0.8，EV 范围 $[-6, 8]$；输入与输出共享冻结值 |
| 白平衡 | 各流 manifest 中的固定 WB，输入与输出共享 |
| 色调与高光 | Reinhard tone mapping；高光重建开启；随后 sRGB gamma |
| 其他 ISP 项 | 2DNR/3DNR 关闭，false color suppression 关闭 |
| 色彩模式 | uncalibrated camera RGB；未使用传感器 ColorMatrix |
| 实际预览视频 | HEVC（libx265），CRF16，yuv444p，1920×1080，6fps；每视频 24 帧 |
| 面板布局 | 输入左、方法 3 右；上为全景、下为固定中心裁剪 |

表 12 的 ISP 与视频项对应 45 流全数据集预览。奇偶参考面板和方法 8 对比使用原审计固定渲染：固定白平衡与曝光、普通 Bayer 去马赛克、sRGB 变换，不包含 Reinhard 与高光重建；各对比内部共享参数。

分块实现见 `src/raw_fusion/finetune/a4.py`；跨传感器清单见 `configs/a3_cross_sensor_zero_shot_20261012.json` 和 `configs/a3_cross_sensor_extension_20261012.json`；全数据集设置见 `configs/a3_all_dataset_traditional_isp_preview_20261017.json`。该配置的 `preferred_encoder` 记为 libx264，但 45 个实际视频及对应 `video_manifest.json` 均为 libx265，表 12 按实际产物记录。

## A.7 方法 8 的 sc635hai 专用头完整配置

表 13: 专用可选输出头的训练设置。

| 项目 | 实际设置 |
|---|---|
| 初始化与范围 | 方法 3 step-5000 EMA；主干冻结且 eval，仅训练输出头 |
| 可训练模块 | `norm`、`conv_after_body`、`conv_last`，共 6 张量、12,400 参数 |
| 头部结构与参数 | LayerNorm108：216；Linear108→84：9156；Conv3d84→4，kernel=$(1,3,3)$：3028 |
| 目标传感器样本 | sc635hai 131x 低色温，共 150 帧，完整范围 $[0,150)$ |
| 输入/目标帧池 | 偶池 0,2,…,148 与奇池 1,3,…,149 互换；每池 75 帧，目标为对侧静态均值 |
| 时间窗口 | 同一池 8 帧，即原视频 frame stride=2 |
| 训练 batch / 步数 | 1 / 500 |
| 随机种子 | 20261013 |
| 学习率与优化器 | 固定 $10^{-5}$，Adam，betas=$(0.9,0.999)$，eps=$10^{-8}$，weight decay=0，amsgrad=False；无调度器 |
| 精度与损失 | BF16 autocast，损失转 FP32；与式 (6) 相同，权重 1/0.1/0.1 |
| EMA / 梯度裁剪 | decay=0.999 / gradient norm=1.0 |
| patch 与有效区域 | $64 \times 64$ packed；静态置信度 $\geq 0.9$，输入未饱和；有效比例至少 0.25，最多尝试 32 次裁剪 |
| 目标域增强 | 水平翻转、垂直翻转、转置，各以 0.5 概率施加 |
| 回放概率与实绩 | MIS20S1 回放概率 0.5；实际回放 262 步，sc635hai 采样 238 步；回放沿用主方法数据管线 |
| 检查点间隔 | 每 100 步保存，最终保留 step-500 EMA |
| 131x 静态复评片段 | 偶输入 134,136,…,148；奇输入 135,137,…,149。该尾段参与训练采样，不作为独立留出 |
| 独立动态保留集 | sc635hai 16x 运动彩色 200 帧，不参与训练；仅无参考诊断与固定 ISP 观察 |
| 用途 | sc635hai 专用可选头，不替代默认方法 3 |

配置为 `configs/a8_sc635hai_adaptation_20261013.json`；实际训练摘要与保存配置位于 `artifacts/a8_sensor_adaptation/sc635hai/training_20261013/`；实现为 `src/raw_fusion/finetune/a8_adaptation.py`。

## A.8 结果来源与复现入口

主方法静态评估位于 artifacts/finetune_mis20s1/evaluation/；跨传感器静态结果位于 artifacts/a3_cross_sensor_zero_shot_20261012/ 和 artifacts/a3_cross_sensor_extension_20261012/；45 流完整预览位于 artifacts/a3_all_dataset_traditional_isp_preview_20261017/。专用输出头的解释与检查结果见 docs/A8_SC635HAI_ADAPTATION_RESULT_2026-10-13.md。这些文件名保留原始实验标识，以便定位已有产物。

从项目根目录执行以下只评测命令，可按对应协议复现主要结果；命令中的 python 指本附录记录的 Python 环境。

```
python scripts/run_a4_eval.py --max-frames 200 \
  --tile-batch 8 \
  --output-dir artifacts/finetune_mis20s1/evaluation
python scripts/run_native_1000x_eval.py --max-frames 200 \
  --tile-batch 8 \
  --output-dir artifacts/finetune_mis20s1/evaluation/native_1000x
python scripts/evaluate_a3_cross_sensor.py \
  --config configs/a3_cross_sensor_zero_shot_20261012.json \
  --output-dir artifacts/a3_cross_sensor_zero_shot_20261012 \
  --phase all --device cuda:0 --tile-batch 2
python scripts/evaluate_a3_cross_sensor.py \
  --config configs/a3_cross_sensor_extension_20261012.json \
  --output-dir artifacts/a3_cross_sensor_extension_20261012 \
  --phase all --device cuda:0 --tile-batch 2
```

结果表中的 645x 为训练覆盖域复评，1000x 为真实增益留出；零样本跨传感器表只使用方法 3，sc635hai 专用头的 131x 尾段属于训练数据复评。复现时应沿用这些数据身份与各自参考定义。