视频去噪研究报告

从静态基线到跨传感器泛化的完整实验历程

肖纬杰　邸锦承

摘要

本报告系统记录了 Stage2 RAW 视频去噪项目的完整研究历程。项目起点是 Stage1 伪 GT 主线中 RViDeformer-L_CRVD 教师在 RAW 数据上过度平滑的问题；目标是通过公司数据微调得到一个既抑制噪声又保留高频细节、并能在多种传感器与增益条件下工作的 RAW 视频去噪模型。报告按四条主线展开：静态基线（A0–A4）、运动保真（A5–A7）、跨传感器泛化（A3 零样本审计、A8–A10b）以及高增益动态失效（全数据集预览、四路诊断、A11 置信门控）。我们给出了 A3 这一可靠的静态基线（645x 跨增益 29.57 dB，native 1000x 53.27 dB），也完整记录了一连串探索实验：A4 的 1000x 跨捕获曝光拟合失效、A5 的动态监督与标量扫描、A6 的四种冻结运动专家、A7 的 36 组旧教师融合、A8 的 sc450ai 盲点适配、A9 的统一多传感器微调、A10b 的全部退化生成器，以及 A11 的置信门控。核心结论是：静态去噪可以通过可信的时域均值监督解决；运动保真、高增益动态和 sc450ai 空间细节的瓶颈不是网络容量或训练步数，而是缺少可信的干净动态/空间监督。报告最后给出失败模式分类、方法论反思与后续研究建议。

关键词： RAW 视频去噪；RViDeformer；跨传感器泛化；运动保真；高增益；负结果；固定 ISP 评测

目录

1 引言 **5**

1.1 研究背景 5

1.2 研究问题 5

1.3 主要工作与贡献 5

1.4 报告组织 6

2 相关工作与技术背景 **7**

2.1 RAW 视频去噪 7

2.2 无干净真值的监督 7

2.3 噪声建模与合成 7

2.4 运动对齐、光流与固定 ISP 7

2.5 本文的定位 8

3 数据、监督与评测 **8**

3.1 数据集全景 8

3.2 五类元数据陷阱 9

3.3 噪声统计：标称增益为何不可信 9

3.4 监督资源分级 10

3.5 评测协议与指标 11

3.6 小结 11

4 静态基线：A0–A4 **11**

4.1 技术路线 11

4.2 A0：数据管线与适配层 12

4.3 A1：干净参考构建 12

4.4 A2：噪声模型与合成数据 13

4.5 A3：RViDeformer 微调 13

4.6 A4：第一次评估与“假失败” 14

4.7 A3 的接受与残余风险 16

4.8 小结 16

5 运动保真：A5–A7 的连续否决 **17**

5.1 现象：运动被时域平均掉 17

5.2 根因：静态监督把运动排除了 17

5.3 A5：动态监督探针与第一次修正 17
5.4 A5：九组训练实验与标量扫描的关闭 18
5.5 为什么 A5 注定失败：N2N 目标不是干净真值 20
5.6 A6：冻结运动专家 v1–v4 20
5.7 A7：旧教师确定性融合的 36 组配置 21
5.8 A7 真实运动采集方案：一条未能执行的路 22
5.9 阶段结论 22

6 跨传感器泛化：审计、A8–A10b 22
6.1 零样本审计协议 22
6.2 审计结果：支持边界并不一致 23
6.3 A8 数据准入：先证明“能训”，再谈“怎么训” 24
6.4 A8 sc635hai：输出头适配的条件通过 24
6.5 A8 sc450ai：盲点适配的全部否决 25
6.6 A9：统一多传感器小步微调 26
6.7 A10：sc450ai 现有数据到底能支持什么 27
6.8 A10b：退化生成器的独立验证与全部否决 28
6.9 阶段结论 30

7 高增益动态失效：全数据集预览、四路诊断与 A11 30
7.1 45 条序列的全数据集预览 30
7.2 失效模式：时域对齐/融合在低信噪比下失效 31
7.3 四路诊断结果 32
7.4 A11：输入证据驱动的置信门控 33
7.5 A11 结果：保守、干净，但覆盖不足 34
7.6 A11 的逐项裁决 36
7.7 为什么 A11 失败：覆盖与证据的悖论 37
7.8 阶段结论 37

8 综合讨论 38
8.1 已经建立的能力 38
8.2 失败模式分类 38
8.3 方法论反思 38
8.4 核心科学判断：缺少可信动态/空间真值 39
8.5 局限性 39

8.6 后续工作建议 40
8.7 小结 40

9 结论 **41**

A 实验索引 **45**

B 关键产物与复现入口 **45**

C 术语表 **46**

1 引言

1.1 研究背景

RAW 域视频去噪位于计算摄影与图像处理的核心位置。与 sRGB 域相比，RAW 域保留了传感器的线性响应、Bayer 采样和噪声统计，理论上更有利于在去噪的同时恢复真实的高频细节[1, 2, 8]。近年来，CRVD/RViDeNet[1]、RViDeformer[2]、RVRT[3]、EMVD[15]、FastDVDNet[16]等工作把深度时空模型引入 RAW 视频去噪，在公开数据上取得了显著进展。然而，这些模型通常在特定传感器、特定增益和特定场景分布上训练；一旦部署到公司自采数据，传感器响应、黑电平、CFA 相位、增益档位、噪声相关性和场景统计都会发生变化，零样本迁移往往出现过度平滑、细节塌陷或颜色异常。

本项目源于一个更具体的工程问题。Stage1 的伪 GT 主线使用 RViDeformer-L_CRVD 作为教师，为下游学生模型生成伪干净目标。该教师在 CRVD 上表现良好，但在公司 MIS20S1 RAW 上会把图卡细线、棋盘纹理和文字边缘一起抹平。主线只能在学生端打补丁，无法从根源上解决教师端的高频损失。因此，Stage2 的目标不是再训练一个学生，而是直接对公司数据微调教师：让教师在真实噪声域上学会“抑噪但不抹细节”，并最终反哺伪 GT 主线。

1.2 研究问题

围绕上述目标，本项目逐步形成了四个研究问题：

1. **RQ1（静态基线）**：在只有少量公司数据、且没有逐像素干净 GT 的条件下，能否构造可信的静态监督，使 RViDeformer 在公司 RAW 上显著优于零样本教师，同时保留高频细节？
2. **RQ2（运动保真）**：静态去噪模型在运动区域会把真实运动误当作噪声平均掉。能否在不引入旧教师伪真值的前提下，恢复运动区域的真实内容？
3. **RQ3（跨传感器泛化）**：在 MIS20S1 上微调的模型能否零样本迁移到 SC465SL、sc635hai、sc450ai？如果不能，逐传感器适配需要什么样的监督，边界在哪里？
4. **RQ4（高增益动态）**：在更高总增益、更低信噪比的动态场景中，模型出现朦胧、重影和过度平滑。失效主因是空间拼接、ISP、时域对齐，还是训练分布？在不训练的前提下能否修复？

这四个问题并不是预先设计好的四条平行实验，而是在项目推进中依次暴露出来的。A3 解决了 RQ1，却把 RQ2 推到了前台；A5–A7 的连续失败说明 RQ2 的瓶颈是监督而不是模型；跨传感器审计把 RQ3 从“泛化好不好”变成了“哪些传感器根本没有可用监督”；全数据集预览又把 RQ4 从“某个视频的编码问题”变成了“高增益时域融合的系统性失效”。报告将按这一真实顺序展开，而不是按事后整理的四条平行线展开。

1.3 主要工作与贡献

本报告的主要工作可以概括为：

1. **建立了一个可复现的静态去噪基线**：A3 step-5000 在 MIS20S1 645x 跨增益留出上达到 29.57 dB（输入 24.35 dB），在 native 1000x 上达到 53.27 dB（输入 44.62 dB），并通过奇偶分半参考验证。
2. **建立了一套多证据评测协议**：分离增益、场景、奇偶帧池；同时报告 PSNR/RMSE、高频保持率、平坦区残差、temporal MAD、legal RAW fraction 与固定 ISP 视频；硬留出从不参与调参。
3. **系统记录并分类了失败路线**：A5 动态监督、A6 冻结运动专家、A7 旧教师融合、A8 sc450ai 盲点、A9 统一多传感器、A10b 退化生成器、A11 置信门控。每条路线都给出明确的否决理由，而不是“略有改善、建议继续观察”。
4. **给出了传感器支持边界**：SC465SL 在已测静态域支持；sc635hai 静态低色温条件支持，且仅保留一个 12,400 参数的可选输出头；sc450ai 不支持；MIS20S1 高增益动态未解决。
5. **总结了若干可复用的方法论经验**：实验前预注册通过门槛、保留硬留出与互斥帧池、用固定 ISP 复评视觉结果，并区分指标变化究竟来自模型能力还是评价域设置。A4 的 1000x 案例表明，评价域选择本身就可能改变对模型的判断。

1.4 报告组织

第 2 节介绍相关工作与技术背景；第 3 节描述数据集、元数据陷阱、噪声统计与评测协议；第 4 节记录 A0–A4 静态基线的建立与第一次评价失败；第 5 节记录 A5–A7 的运动保真探索；第 6 节记录跨传感器审计与 A8–A10b；第 7 节记录高增益动态诊断与 A11；第 8 节进行综合讨论；第 9 节总结。附录给出实验索引、复现入口与术语表。

图 1 给出了整个项目的四阶段时间线与五个关键决策点。

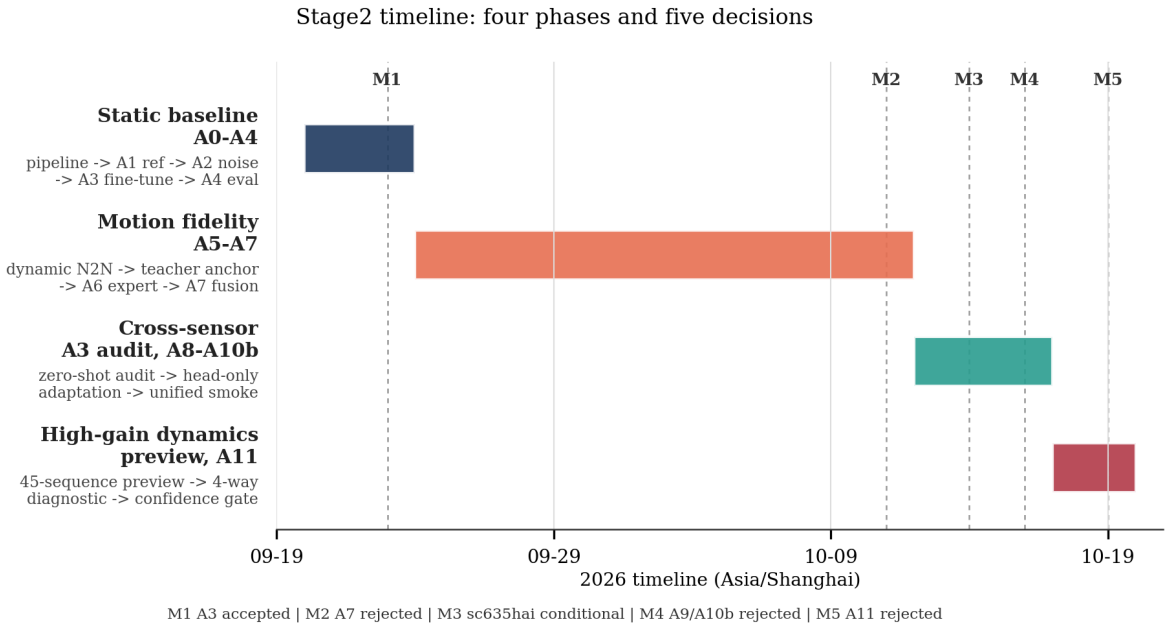


图 1: Stage2 项目时间线。四个科学阶段（静态基线、运动保真、跨传感器、高增益动态）依次推进；M1–M5 为五个关键决策点。

2 相关工作与技术背景

2.1 RAW 视频去噪

RAW 视频去噪的早期工作多采用多帧对齐加时空融合。HDR+[10] 与 Deep Burst Denoising[9] 通过 burst 对齐和帧间融合提升低照度信噪比；KPN[17] 使用核预测网络进行 burst 去噪；EMVD[15] 与 FastDVDNet[16] 则把循环或非局部时空融合引入视频去噪。经典方法方面，NL-means[18] 与 BM3D[19] 仍是重要的非局部先验来源。在图像域，DnCNN[14] 等判别式 CNN 奠定了残差去噪范式；CBDNet[20] 则把真实噪声估计与盲去噪结合起来，说明“噪声模型 + 网络”的组合对真实数据尤为重要。

CRVD/RViDeNet[1] 首次提供了动态场景的 RAW 视频 noisy-clean 配对基准，并采用 Bayer 打包、可变形卷积对齐和时空融合。RViDeformer[2] 在此基础上引入多分支空间/时间注意力与重参数化，在更大的 ReCRVD 数据集上训练，显著提升了 RAW 视频去噪的效率与质量。RVRT[3] 则提供了递归视频 Transformer 与引导式可变形注意力的通用框架。本项目的基座正是 RViDeformer-L_CRVD：它不是从零训练，而是在官方 CRVD 权重上做小学习率全参数微调。

2.2 无干净真值的监督

公司数据无法提供逐像素干净 GT，因此项目大量依赖无干净真值监督。Noise2Noise[4] 表明，在噪声独立同分布的假设下，可以用另一张噪声观测作为目标；Noise2Void[5] 与 Noise2Self[6] 则通过盲点（blind-spot）结构从单张噪声图中构造自监督。盲点方法可以学习噪声统计，但它有一个根本限制：如果某个空间结构在输入中已经被抹掉，盲点目标无法“凭空”恢复该结构。A8 的 sc450ai 失败正是这一限制的实证。

另一个重要资源是时域平均。对于静态场景，低增益流的长时间平均可以逼近干净参考；HDR+[10] 与 burst 去噪 [9, 17] 都利用了多帧平均。但时域平均在运动区域会产生重影，因此不能直接作为动态真值。这一区分贯穿 A1、A5 和 A7。

2.3 噪声建模与合成

Foi 等人 [7] 提出的 Poisson-Gaussian 模型把 RAW 噪声方差写成信号相关项与读出噪声项之和；Unprocessing[8] 则把 sRGB 图像反处理回 RAW 域以构造训练对。本项目在 A2 中使用标定平场与黑帧拟合

$$\sigma^2(\mu, G) = a\,\mu\,G + b\,G^2, \tag{1}$$

其中 μ 为信号均值，G 为增益因子，a 为 shot 系数，b 为读出噪声系数。该模型用于从 A1 干净参考合成不同增益的噪声对，并以 15% 的相对误差作为真实性硬门槛。

2.4 运动对齐、光流与固定 ISP

A5 的动态探针使用 DIS 光流 [11] 把后一帧 warp 到当前帧，并以 forward-backward error 和光度误差构造置信度。A11 的置信门控同样使用 DIS 光流，但只把它作为输入证据之一，而不是直

接做光流融合。固定 ISP 评测使用 Bayer 去马赛克、固定曝光/白平衡、Reinhard tone mapping[12] 和高光重建；2DNR/3DNR 一律关闭，以避免把 ISP 的时域处理误认为模型效果。

损失函数方面，A3 使用 Charbonnier 主项 [13]，并叠加梯度损失与高通损失。Charbonnier 是 L1 的平滑近似，较 L2 更适合保留边缘；梯度与高通项则直接约束高频结构。

2.5 本文的定位

与追求单一 benchmark 最高 PSNR 的工作不同，本项目更像一次 “部署前的系统性可行性审计”。我们关心的不是某一个数字，而是：在真实公司数据、真实传感器差异、真实运动和高增益条件下，哪些结论可以成立、哪些不能成立、失败的原因是什么。因此，报告中有大量 “负结果”，它们与 A3 的正结果具有同等的重要性。

3 数据、监督与评测

3.1 数据集全景

公司数据集包含 5 个顶层分组、45 条原始 RAW 流，覆盖 4 种传感器：MIS20S1、SC465SL、sc635hai、sc450ai。分辨率包括 1920×1080、2560×1440、2688×1520、3200×1800；位对齐包括高 12 位（存储值需右移 4 位）、低 12 位和低对齐有效 10 位；CFA 以 RGGB 为主，标定流为 GRBG；黑电平逐流实测，范围约 250–321 DN。表 1 给出了主要数据源及其在项目中的角色。

表 1: 主要数据源与项目角色。

分组/场景	内容	规模	项目角色
04/shdarkroom	MIS20S1 暗房，同一布景 7 个增益点（10x–1000x）	200 帧 ×6 + 300 帧 ×1	主监督源；10x 时域均值作为 A1 主参考；跨增益配对
04/mis20s1_outdoor	MIS20S1 公园黄昏, 4 个增益点（128x–1500x）	195–200 帧 ×4	运动丰富；高增益失效代表序列
04/calibration	ColorChecker 平场 + 盖镜头黑帧，9 个增益（100x–25600x）	50 帧 ×18	A2 噪声模型与合成数据
02/SC465SL	SC465SL 暗房, 两条流（标称 256x/2000x）	300 帧 ×2	跨传感器静态审计
05/SC465SL	超市布景 6 级增益梯子 + difficultpattern	100–200 帧 ×10	细节压力测试；不作为干净真值
01/sc635hai	131x 低色温 + 16x 运动彩色	150/200 帧	跨传感器静态/动态审计；A8 条件适配
01/sc450ai	1435x 黑物运动 + 804x 灯光变化	210/150 帧	跨传感器压力测试; 1435x 硬留出
03/MIS20S1	别家 2DNR/3DNR 输出	200 帧 ×4	仅作已处理流参考，不进主训练

3.2 五类元数据陷阱

数据勘查阶段最重要的发现不是“数据有多少”，而是“元数据有多不可信”。项目最终总结了五类陷阱，并在 A0 适配层中逐源处理：

1. **位对齐**：04 场景流与 05 高 12 位（读取后需 `>>4`）；02、03 低 12 位；01 组内分裂。sc450ai 随数据提供的 readme 给出的处理方式是：数据按高 12 位存储，读取后应右移 4 位（`>>4`），并以 4128 DN 作为黑电平。但实测数据是低对齐、有效 10 位（抽样值全部不超过 4095，且 `value % 4 == 0` 占 100%），黑电平约 256–258 DN。若按 readme 右移 4 位，像素值会被压到 0–255；再减 4128，整幅图会被裁成负数或零。这不是精度损失，而是直接把数据破坏。

2. **黑电平**：传感器名义 256 DN，但场景底座在 250–273 DN 之间漂移；标定流约 256.7 DN；03 组约 300–321 DN。任何跨流对齐都必须使用各自实测黑电平，不能用常数 256 或 252。

3. **CFA 相位**：场景流均为 RGGB；标定流为 GRBG，与场景流相位相反，使用前必须翻相位。绿通道两相位类均等 0.5–0.7% 曾在两次独立测量中确认。

4. **帧数**：文件名中的帧数不可信。标定组每档实际 50 帧而非文件名暗示的 10 帧；1500x 为 195 帧、512x 为 198 帧、313x 为 300 帧。

5. **增益标签**：标称增益完全不预测噪声量级。shdarkroom 的 128x 反而比 1000x 更噪（79.05 DN vs. 28.93 DN），因为每档增益重新打过灯；标定梯度的 1600x/3200x 也出现非单调。模型条件不能使用标称增益，只能使用实测噪声统计。

这些陷阱听起来是工程细节，但它们直接决定了监督是否可信。A1 的黑电平错误会让时域均值出现系统性偏置；A2 的位对齐错误会让合成噪声的方差偏大 16 倍；A5 的运动 mask 如果建立在错误的黑电平上，会把噪声误判为运动。项目在 A0 阶段花了整整一天做逐源适配与复核，这是后续所有数字能够对齐的前提。

3.3 噪声统计：标称增益为何不可信

图 2 给出了两组实测噪声。左图是 shdarkroom 场景流的时域分半 σ_{Gr}：10x 为 21.60 DN，64x 为 54.31 DN，128x 达到峰值 79.05 DN，之后 313x 为 52.39 DN、632x 为 32.92 DN、645x 为 37.95 DN、1000x 为 28.93 DN。右图是标定平场梯度的分半 σ_{Gr}：100x 为 1.26 DN，800x 为 5.45 DN，1600x 反而降到 2.10 DN，3200x 为 3.35 DN，之后才恢复单调上升，25600x 达到 19.08 DN。

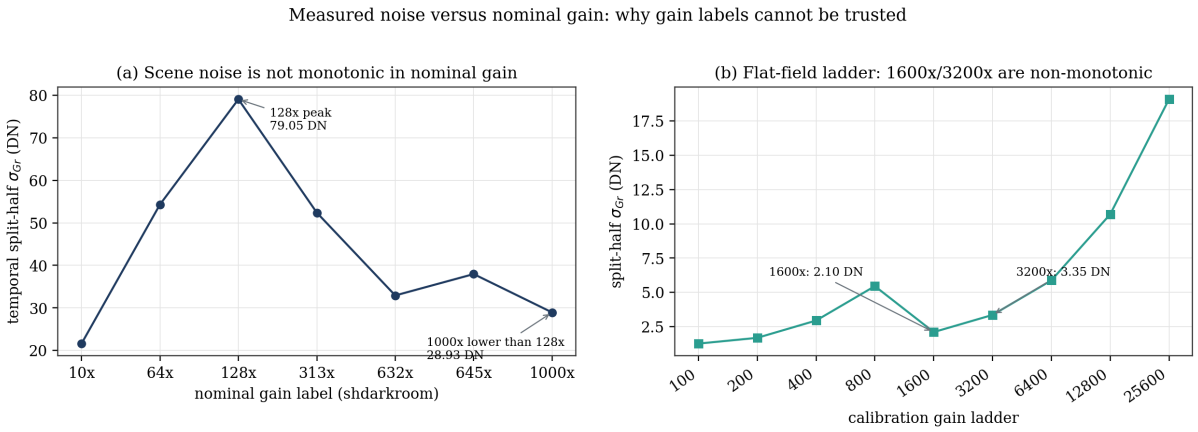


图 2: 实测噪声与标称增益的关系。(a) shdarkroom 场景流的时域分半 σ_{Gr} 在 128x 达到峰值，1000x 反而低于 128x；(b) 标定平场梯度在 1600x/3200x 出现非单调。两图共同说明：不能把标称增益当作模型条件。

这一发现改变了 A2 的设计。最初计划按标称增益拟合 $\sigma(G)$，但数据表明标称增益与真实噪声之间没有稳定映射。最终 A2 改为按每个增益点的实测 σ 拟合，并在合成时使用实测 shot/read 系数；标称增益只作为文件名标签，不进入模型。

另一个容易被忽略的问题是量化下限。标定组 100x 的真实读出约 0.3 dn12，低于 1 LSB；实测 1.26 DN 是量化地板，不是真实读噪。A2 在低增益端做了量化感知处理，否则合成噪声会系统性偏小。

3.4 监督资源分级

项目逐渐形成了一张“监督资源分级表”（表 2）。这张表解释了为什么某些路线可行、某些路线从一开始就注定失败。

表 2: 监督资源分级。级别越低，可信度越差。

级别	资源	适用条件	项目中的使用
A	跨增益静态参考（10x 时域均值）	同一场景、静态、未饱和、已配准	A1 主参考；A3 静态监督
B	同流奇偶分半参考	静态、帧池互斥	跨传感器审计；A8/A9 静态适配
C	同流时域均值	静态区域可信，动态区域有重影	次级参考；不作为动态真值
D	旧教师输出	有运动行为，但不是干净目标	A6/A7 仅作诊断，不作真值
E	单帧盲点自监督	可学噪声统计，不能恢复已丢失结构	A8 sc450ai 失败
F	无监督/无参考	只能做压力测试	sc450ai 1435x、difficultpattern

A3 之所以成功，是因为它站在 A 级资源上；A5/A6/A7 之所以失败，是因为它们试图用 C/D 级资源去监督动态细节；A8 sc450ai 之所以失败，是因为它只有 E 级资源；A10b 之所以被否决，是因为 F 级资源连噪声统计都不足以跨拍摄条件迁移。

3.5 评测协议与指标

项目最终固定了以下评测协议：

1. **静态定量**：对每条流测逐通道黑电平；构造初步时域均值；用 $\text{median} + 3 \times 1.4826 \times \text{MAD}$ 规则剔除运动帧；保留在全部、偶数、奇数帧中至少 90% 静态的像素；用偶数帧 8 帧片段对奇数参考评估，再反向评估。输入与目标来自互斥帧池。
2. **指标**：native DN 域的 PSNR/RMSE、temporal MAD、输出偏置、legal RAW fraction、归一化裁剪率、高频保持率、平坦区残差 σ、可用覆盖率。
3. **动态压力**：对连续 8 帧片段报告输出变化、temporal MAD、motion/static 时序比、空间高频比、legal fraction、端点裁剪；只做诊断，不用无干净目标的 PSNR。
4. **固定 ISP**：Bayer 去马赛克、固定曝光/白平衡、Reinhard tone mapping、高光重建；2DNR/3DNR 关闭；Input 与所有模型分支共享完全相同的 ISP 参数。
5. **硬留出**：sc450ai 1435x 黑色运动物体序列、MIS20S1 1000x 原生增益、SC465SL difficult-pattern 等，不参与训练、不参与阈值选择。

指标的定义与陷阱需要在报告开头说清楚。PSNR/RMSE 只在有可信参考时使用；高频保持率是输出高频能量与参考高频能量之比，接近 1 表示细节保留，但降低也可能是去噪，必须结合噪声指标解释；temporal MAD 是帧间平均绝对差，过低表示时域被过度平均，过高表示闪烁或噪声回流；legal RAW fraction 只说明数值范围合法，不说明画质；motion/input ratio 只说明输出跟随输入运动的程度，不是干净参考质量。项目在 A5 之后明确规定：motion/input ratio 永远不能单独作为通过依据。

3.6 小结

本章的核心结论是：数据与评测协议本身是研究的一部分。A3 的成功不仅来自模型，更来自 A1/A2 对监督的精细构造；A5–A11 的失败也不仅来自模型，更来自监督资源的级别不足。理解了这一点，后面的实验序列就不再是“不断换模型”，而是“不断验证当前监督能支持到哪一步”。

4 静态基线：A0–A4

4.1 技术路线

项目选择 RViDeformer-L_CRVD 作为基座，而不是从零训练。理由有三：第一，公司数据量有限（约两个场景、十余个增益点），从零训练必然过拟合；第二，RViDeformer 已在 CRVD 上

学习了 RAW 域的时空先验，小学习率微调可以保留这些先验；第三，官方权重提供了可复现的起点，便于把“模型能力”和“数据适配”分开分析。

整体路线如图 3 所示：数据经过 A0 适配层进入监督构造（A1 干净参考、A2 噪声模型、运动/饱和 mask），再进入 A3 微调，最后由 A4 在分离增益上评估。评估结果如果失败，反馈到监督或模型，而不是直接加训练步数。

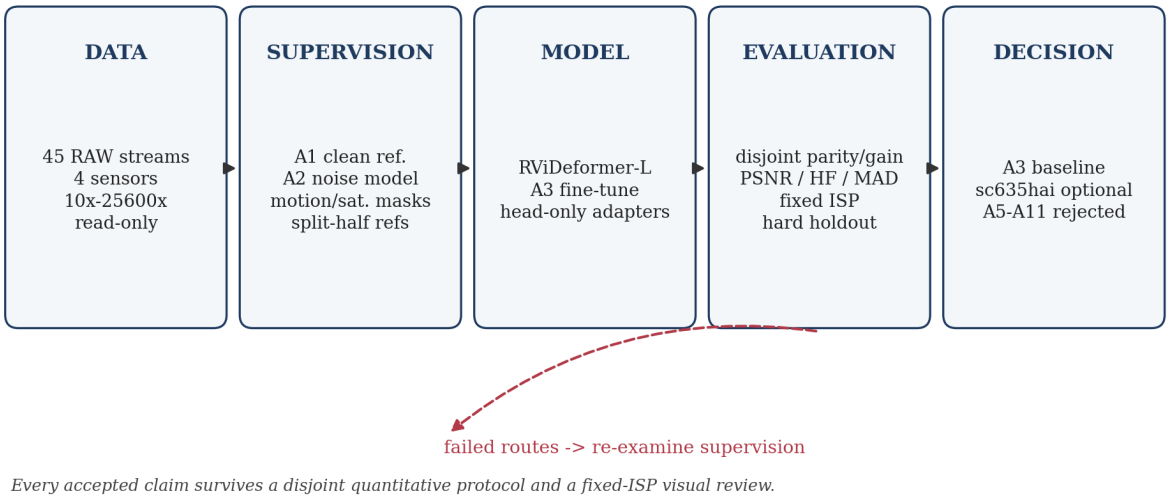


图 3: 研究设计与证据流。数据、监督、模型、评测、决策五个环节构成闭环；失败路线会回到监督与证据层重新审视，而不是盲目延长训练。

4.2 A0：数据管线与适配层

A0 的目标是把 33 条流变成可复现的 manifest。新增子包 `src/raw_fusion/finetune/` 包含适配器、流读取、配准、运动 mask、曝光拟合、统计与 manifest 编排。每条流落一份 `stream_manifest.json`，记录帧数、逐通道黑电平、分半 σ、运动统计、配准位移与曝光拟合系数。50/50 个单元（33 流 + 11 配准 + 6 曝光拟合）全部成功，15 份运动 mask 全部生成。

配准是一个典型坑。632x 与 1000x 相对 645x 整体横移约 62 像素（packed 坐标 -31），这是采集间碰了相机造成的；如果不配准，跨增益监督会把场景结构错位当成噪声。A0 用相位相关估计整数位移，并把浮点位移写入 manifest；后续 A3/A4 都使用 packed 整数位移。1000x 的配准重叠率为 0.9677，说明配准本身不是后来 A4 失败的原因。

曝光拟合是另一个坑。A0 在每个 (noisy, reference) 对上用静态区稳健回归拟合逐通道线性系数。645x 的拟合在 256–2048 DN 范围内残差约 -70 到 $+45$ DN，表现稳定；1000x 的拟合在高亮端严重失效，这为 A4 的“假失败”埋下伏笔。

4.3 A1：干净参考构建

A1 以 shdarkroom 10x 的 200 帧时域平均作为主参考。10x 是同一场景的最低增益，噪声最小，且图卡细节仍然存在。具体做法是分块累加 200 帧，扣除长平均估计的 FPN（DSNU+PRNU），

并用 A0 的运动 mask 标记无效区域。最终参考形状为 $(4, 540, 960)$，单位为 12-bit DN。

A1 设置了三项硬校验：

1. **分半残差**：奇偶帧各自平均后的残差 σ 在 R/Gr/Gb/B 上分别为 0.511/0.797/0.763/0.560 DN，全部低于 1 DN 门槛。
2. **跨增益一致性**：与 64x 时域平均（曝光归一化后）逐通道 signed median 偏差为 1.17–1.86 DN，低于 2 DN 门槛。
3. **高频真实性**：图卡区 10x 参考的归一化细节能量是 645x 单帧噪声校正后细节的 2.97 倍，远高于 0.9 的门槛；这证明时域平均没有把真实高频平均掉。

这里有一个值得记录的方法论错误。最初的分半 σ 估计使用 1.2533（半正态分布的均值系数）作用在 $|even - odd|$ 的中位数上，系统性低估约 15.5%。后来改为 1.4826（中位数无偏系数），并与逐帧两遍精确 std 交叉验证，才得到上表的数字。这个错误没有影响最终结论，但它说明：在一个没有外部 GT 的项目里，估计器本身的偏差可能比模型误差更大。项目随后把所有“分半 σ”统一到 1.4826，并在报告中明确口径。

A1 还生成了 64x、128x、645x 的次级参考。64x 的静态比例为 88.50%，128x 为 84.56%，645x 为 89.84%。这些次级参考用于中增益课程和交叉验证，但主 GT 始终是 10x。

4.4 A2：噪声模型与合成数据

A2 用标定平场与黑帧拟合式 (1)。四个通道的 shot 系数为 R=0.1543、Gr=0.1320、Gb=0.1329、B=0.1482；读出项 b 在 0.063–0.232 之间。这个结果与勘察阶段的 $a \approx 0.136$–0.157 一致，说明标定数据内部自洽。

合成器从 A1 干净参考出发，按目标增益加入 shot+read 噪声、FPN、量化与黑电平，生成 9 个增益点（100x–25600x）的 noisy-clean 对。真实性硬门槛是：合成对的 3×3 高通差分 σ 与同增益真实流实测 σ 的相对误差不超过 15%。实际最大逐通道相对误差为 8.66%（6400x 的 Gb），全部通过。这个门槛很重要：如果合成噪声统计不对，模型会把没见过的高频当成噪声抹掉，或者把噪声当成细节保留。

A2 还显式处理了两个异常：1600x/3200x 的非单调（疑似模数混合增益分级），以及 100x 的量化地板。前者没有被当作离群点一删了之，而是保留在拟合中并记录残差；后者在低增益端使用量化感知合成。

4.5 A3：RViDeformer 微调

A3 的训练配置见表 3。模型为 RViDeformer-L，输入 8 帧 packed RGGB（$4 \times 64 \times 64$ patch），输出 8 帧。真实数据使用 128x/313x/632x/645x 四个增益，1000x 作为独立 holdout；合成数据覆盖 9 个增益点。真实与合成比例约 1:1。

表 3: A3 训练配置。

项目	设置
基座	RViDeformer-L_CRVD（官方 checkpoint，strict 加载）
输入/输出	8 帧 packed RGGB，$4 \times 64 \times 64$ patch，8 帧输出
真实训练增益	128x、313x、632x、645x（1000x 为 holdout）
合成数据	A2 的 9 个增益点，每点 8 个时序变体
真实: 合成	约 1:1
损失	Charbonnier + 0.1× 梯度 + 0.1× 高通
掩码	运动区、饱和区、无效区不计损失
优化	Adam，lr 1×10^{-4}，batch 1，5000 步，EMA 0.999
参数	全参数微调；model/EMA 各 1265 个张量

A3 的关键设计不是损失函数，而是“什么不算损失”。运动 mask 排除所有被判定为运动的像素；饱和 mask 排除接近 3800 DN 的像素；无效区排除参考不可信的位置。这样做避免了把时域均值中的运动重影当作目标，但也埋下了 A5 的隐患：被排除的运动区域没有得到任何正向监督。

A3 训练从 step 200 恢复到 step 5000，最终 checkpoint 为 `checkpoint_step_005000.pth`，SHA-256 为 `97c4332f...592e0b`。该文件后来成为整个项目的不可变基线，所有后续实验都以它为参照，且从未被覆盖。

4.6 A4：第一次评估与“假失败”

A4 使用 leave-one-gain-out 协议，完整评估 645x 与 1000x 各 200 帧。645x 的结果符合预期：输入 24.35 dB，A3 29.57 dB，提升 5.22 dB；RMSE 从 248.12 DN 降到 136.02 DN；高频保持率 0.971；平坦区残差 83.19 DN；legal fraction 1.0。图 4 给出了 645x 的固定 ISP 对比：输入彩噪严重，A3 输出干净且图卡、棋盘、文字边缘仍然可辨。



图 4: MIS20S1 645x 固定 ISP 对比。左列为输入，右列为 A3 EMA；上半部为全景，下半部为固定中心裁剪。A3 显著抑制彩噪，同时保留图卡与棋盘结构。

1000x 的结果却像一次灾难：输入 18.73 dB，A3 18.84 dB，仅提升 0.10 dB；高频保持率只有 0.339；平坦区残差 226.19 DN。更奇怪的是，旧教师也只有 18.78 dB。三个方法都“失败”，这提示问题可能不在模型。图 5 的四宫格显示了当时的困惑：input、旧教师、A3 都比 A1 参考暗很多，且高频几乎消失。

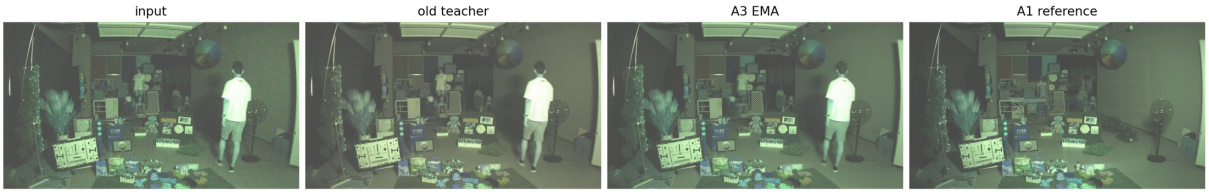


图 5: 645x 四宫格：input、旧教师、A3 EMA、A1 参考。A3 明显优于旧教师，但旧教师与输入都带有明显噪声/偏色；该图用于说明“有参考时”的视觉判断必须与定量指标一起看。

项目没有立即改模型，而是先问：这是模型的错，还是评价协议的错？A4 之后的诊断按以下顺序进行：

1. **配准检查**：1000x manifest 的浮点位移为 $(-61.94, -0.60)$ 传感器像素，除以 2 得 packed $(-30.97, -0.30)$，整数位移 $(-31, 0)$ 正确；packed 重叠率 0.9677。配准不是根因。
2. **曝光分桶**：1000x 到 10x 的线性曝光映射在高亮端严重欠映射：参考 1024–2048 DN 时残差约 −570 到 −705 DN，2048–3072 DN 时约 −1.4k 到 −1.8k DN，更高区间约 −2.7k 到

−3.1k DN。645x 在 256–2048 DN 的残差仅 −70 到 +45 DN。这说明 1000x 与 10x 不是同一照明条件下的简单线性关系。

3. **直接 1000x–645x 配对**：低亮度 256–512 DN 残差约 +3 到 +10 DN，512–1024 DN 约 −211 到 −247 DN，更高区间几乎没有 1000x 对应样本。稳健拟合的中位数残差约 −6 到 −7 DN，但只覆盖低亮度可配对样本。

4. **原生参考探针**：用 1000x 自身 200 帧构造 motion-aware 时域均值，valid fraction 0.9321，逐帧曝光尺度 0.98–1.02，分半残差 σ 为 R=2.09、Gr=2.35、Gb=2.34、B=2.02 DN。这个参考足够稳定。

用原生参考重新评估后，A3 在 1000x 上达到 53.27 dB，输入 44.62 dB，提升 8.65 dB；RMSE 从 24.06 DN 降到 8.89 DN；高频保持率 0.856；平坦区残差 7.17 DN；legal fraction 1.0。奇偶分半验证也稳定：奇数输入对偶数参考 53.10 dB，偶数输入对奇数参考 53.07 dB。

表 4 汇总了 A4 的三组结果。最关键的一行是 “1000x cross-capture”：它不是模型失败，而是跨捕获曝光拟合失败。项目从此确立一条原则：**评价域本身是模型的一部分；不能把协议失败归因于模型能力**。

表 4: A3 在三种评估域上的结果。1000x cross-capture 行仅用于诊断，不是有效质量门槛。

协议	输入 PSNR (dB)	A3 PSNR (dB)	Δ (dB)	输入 RMSE (DN)	A3 RMSE (DN)	HF 比	平坦 σ (DN)
645x 跨增益	24.3519	29.5729	+5.2210	248.1197	136.0228	0.9712	83.19
1000x 原生	44.6204	53.2675	+8.6471	24.0565	8.8895	0.8562	7.17
1000x 跨捕获（无效）	18.7349	18.8372	+0.1023	473.7036	468.1600	0.3394	226.19

4.7 A3 的接受与残余风险

A3 step-5000 EMA 被接受为当前候选基线。接受依据不是单一 PSNR，而是：645x 跨增益提升 5.22 dB 且高频保持 0.971；native 1000x 提升 8.65 dB 且奇偶分半一致；legal RAW fraction 为 1.0；固定 ISP 下没有明显色偏或结构断裂；完整测试套件 34 项通过。

但 A3 的接受是有边界的。第一，它的静态监督排除了运动区域，因此运动保真没有保障；第二，1000x 是训练 holdout，模型在该增益上的成功依赖于 native 参考，而不是跨增益泛化；第三，MIS20S1 只有一个暗房场景提供可信静态 GT，场景多样性不足；第四，sc450ai 等传感器完全没有进入训练。A3 是一个强静态基线，但不是通用去噪模型。

4.8 小结

A0–A4 完成了项目的第一条闭环：数据适配、干净参考、噪声模型、微调、评估。A3 证明了“在可信静态监督下，RViDeformer 可以适应公司传感器并显著优于零样本教师”。A4 则给了一个更重要的教训：当评估协议本身失效时，模型会被误判。这个教训在后续的 A5、A8、A9 中反复出现。

5 运动保真：A5–A7 的连续否决

5.1 现象：运动被时域平均掉

A3 在静态区域表现很好，但在 645x 固定 ISP 预览中，移动的人被时域平均成了半透明残影。运动审计脚本 `audit_motion_temporal_fidelity.py` 给出了量化证据：运动 mask 在 packed 分辨率下覆盖约 3.91% 的像素；A3 在运动区的帧间差只有输入的 27%–32%；个别转场的 prediction/input 变化比只有约 0.10。这不是 MP4 编码伪影，而是模型行为。

更严重的是，A3 比官方教师更压制运动。官方教师在 645x 上的 motion/input ratio 为 R/Gr/Gb/B = 0.334/0.371/0.406/0.399；A3 降到 0.270/0.323/0.308/0.286；最低转场比从 0.176–0.224 降到 0.097–0.127（图 6）。这说明 A3 的微调在改善静态去噪的同时，把“运动也是噪声”这一错误先验强化了。

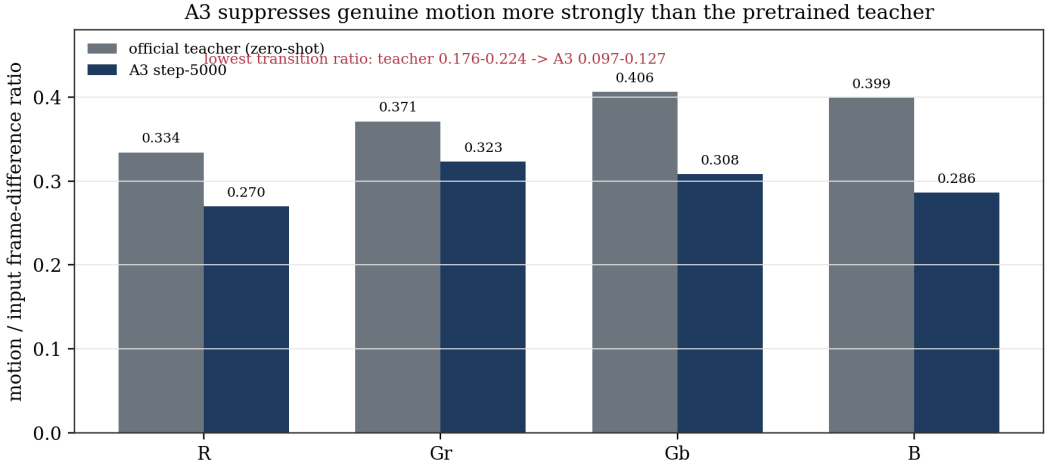


图 6: 官方教师与 A3 在 645x 上的 motion/input ratio。A3 在所有通道上都更强烈地压制真实运动；该指标是诊断量，不是干净参考质量。

5.2 根因：静态监督把运动排除了

A3 的真实数据采样器把每个被标记为运动的像素从训练 mask 中排除，损失只作用于剩余静态像素；合成时序数据则是同一张干净图加独立噪声，重复 8 次，没有任何运动内容。因此，模型收到的信号是：静态区域越平均越好，运动区域没有正向目标。时域融合在静态区被奖励，在运动区不受约束，模型自然学会了“把运动平均掉”。

这不是一个可以通过调 loss 权重解决的问题。只要监督目标里没有“运动物体在该时刻的干净纹理”，任何权重组合都只能在“静态更干净”和“动态更清晰”之间移动，而不会产生缺失的真细节。A5–A7 的整个失败序列，本质上是在反复验证这一点。

5.3 A5：动态监督探针与第一次修正

A5 的第一步是构造动态 Noise2Noise 目标。具体做法是：用 DIS 光流 [11] 把后一帧 warp 到当前帧坐标，取两帧的噪声独立性作为监督信号；用 forward-backward error 和光度误差构造置信

度；只在置信区域内计算 Charbonnier 损失。初始探针包含三对样本 (34→38、50→54、148→152)，置信度覆盖 37%–44% 的动态像素，FB 误差 P95 为 1.16–1.28 packed 像素，warped 绿色通道光度误差 P95 约 0.072–0.073（归一化 A1 单位）。

随后构造 8 帧窗口（gap 4，起点 30/46/140），以匹配模型的 8 帧输入。窗口的平均置信度覆盖 31%–41% 的动态像素，高通源/目标相关均值为 0.039–0.105（绿色通道约 0.08–0.20）。这些数字说明 N2N 假设 “勉强可用”，但远不是干净监督。

真正的打击来自运动 mask 噪声审计。脚本 `diagnose_motion_mask_noise.py` 发现，初始置信规则里混入了大量低 Flow 像素：三个窗口中分别有 39.2%、77.0%、65.8% 的置信像素 Flow 小于 1 px，第二个窗口甚至有 51.6% 小于 0.5 px。低 Flow 不一定都是噪声（慢速运动或低纹理物体也可能），但这说明初始 mask 不是可靠的 “纯运动区域”。项目因此把规则收紧到 `flow_magnitude_px >= 1.0`，重新生成 strict-1px 探针；新探针的置信度覆盖降到 1.81%/2.27%/3.82%，高通相关仍为 0.027/0.099/0.096（绿色通道低于 0.19）。

这是一次重要的自我修正：如果直接用初始 mask 训练，模型会把噪声和静态纹理当成运动目标，动态损失越大，引入的伪影越多。A5 之后的所有动态实验都使用 strict-1px mask。

5.4 A5：九组训练实验与标量扫描的关闭

A5 使用固定协议：训练帧 $[0, 160)$，动态留出 $[160, 200)$，native 1000x 留出 $[0, 40)$；每次从 A3 step-5000 EMA 初始化，训练 20 步。**表 5 中的 645x 指标均来自 $[160, 200)$ 的 40 帧不相交留出，与第 4 章全 200 帧的 29.57 dB 不可直接比较**。基线为：motion/input ratio 0.488799，645x 静态 PSNR 29.51644 dB，HF 0.973896，temporal MAD 11.758 DN，native PSNR 52.363733 dB，RMSE 9.864323 DN。表 5 汇总了九组候选。

表 5: A5 运动监督实验矩阵。所有候选均从 A3 EMA 初始化，训练 20 步；加粗表示未通过的门槛。

候选	motion/input	645x PSNR (dB)	native PSNR (dB)	结论
A3 基线	0.488799	29.516440	52.363733	基线
A1 静态控制，lr 10^{-5}	0.485890	29.554080	51.016080	仅控制；native 回退
全模型，lr 10^{-5}，dyn 0.1	0.494240	29.525200	51.055440	否决；native 回退
全模型，lr 10^{-6}，dyn 1.0	0.489270	29.510660	52.281960	否决；运动增益小
仅互注意力，lr 10^{-5}，dyn 1.0	0.487940	29.511750	52.339290	否决；无运动增益
教师锚定 w=1，live	0.494620	29.489150	52.393620	有希望，但静态回退
教师锚定 w=1，EMA	0.488450	29.511550	52.369880	否决；无运动增益
教师锚定 w=2，live	0.491590	29.501140	52.403570	否决；静态/细节回退
教师锚定 w=2，EMA	0.488160	29.512810	52.370020	否决；无运动增益
同窗锚定，live	0.493882	29.485918	52.385133	否决；静态/HF/时序回退
同窗锚定，EMA	0.488084	29.513075	52.345669	否决；无运动增益

图 7 把候选放进三维门槛空间：横轴是 645x 静态 PSNR，纵轴是 motion/input ratio，颜色是 native 1000x PSNR。可行域要求三者在基线上方；没有任何候选同时满足。这个图比单看表格更能说明问题：A5 不是“差一点”，而是所有候选都落在可行域的不同侧面。

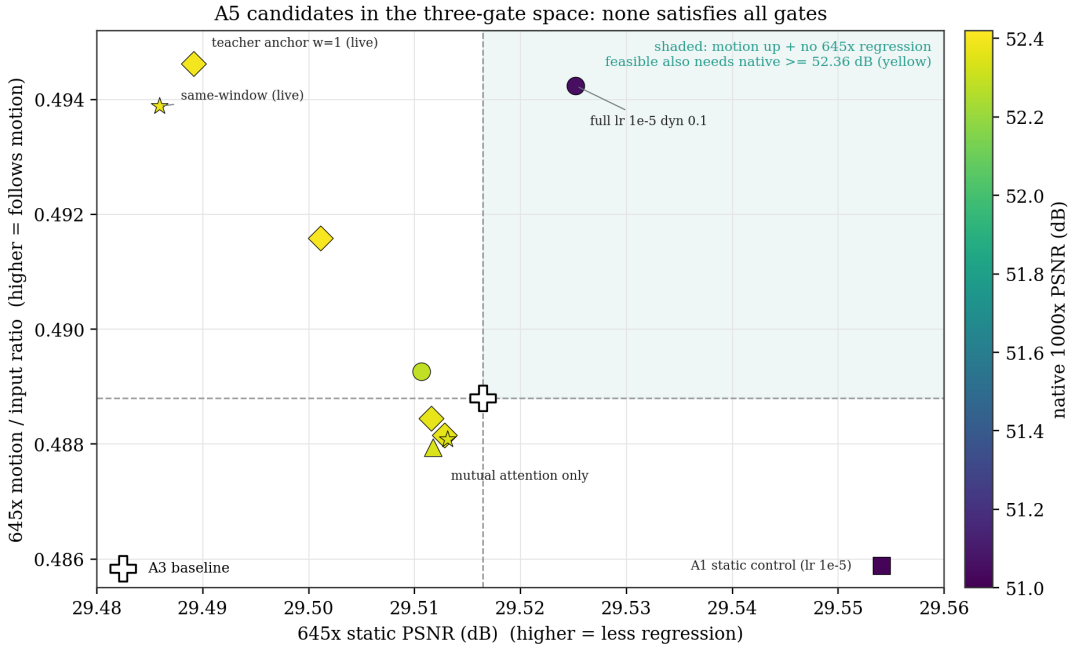


图 7: A5 候选的三门槛空间。横轴为 645x 静态 PSNR，纵轴为 motion/input ratio，颜色为 native 1000x PSNR。阴影区只表示“运动提升且 645x 不退化”；可行还要求 native 不低于基线（亮黄色）。没有候选同时满足三项。

几组结果值得单独解释：

1. **静态控制**：只继续原来的 A1 静态目标、不加动态损失，native PSNR 就从 52.364 掉到 51.016 dB（−1.348 dB）。这说明在 lr 10^{-5} 下，普通的继续微调本身就会造成大部分域漂移；不能把动态候选的 native 回退全部归因于动态损失。

2. **教师锚定 w=1 live**：这是第一个同时出现运动增益（+0.00582）和 native 增益（+0.030 dB）的候选，但 645x 静态 PSNR 回退 0.027 dB，HF 也下降。它证明“冻结 A3 输出作为静态锚”方向有效，但还不能上线。

3. **教师锚定 w=2**：把静态锚权重翻倍，静态回退从 −0.027 降到 −0.015 dB（改善约 44%），但运动增益从 +0.00582 降到 +0.00279（减少约 52%）。这是一个标量 trade-off，不是一个可通过的工作点；继续扫权重没有意义。

4. **同窗锚定**：把冻结 A3 教师直接作用于同一动态窗口的静态像素，并对 strict mask 做 1 像素膨胀以排除边界。live 模型运动比升到 0.493882，但 645x 静态 PSNR 降到 29.485918 dB，HF 降到 0.9610，temporal MAD 从 11.758 升到 12.057 DN；EMA 则失去运动增益，native 也回退。两条权重集都没有通过全部门槛。

A5 的结论是：**简单标量/冻结范围扫描已经关闭**。继续调 `static_anchor_weight`、`dynamic_weight` 或冻结层，只会在已知的 trade-off 上移动，不会产生新的监督信息。

5.5 为什么 A5 注定失败：N2N 目标不是干净真值

A5 的动态目标是“后一帧 warp 到当前帧”的噪声观测，不是干净真值。N2N 的独立性假设只能在统计意义上成立；在高增益、低信噪比、遮挡和快速运动的组合下，warp 误差、遮挡边界和噪声相关性都会破坏这个假设。A5 的验证报告显示，高通源/目标相关只有 0.03–0.10，绿色通道低于 0.20；这足以做“目标构造探针”，但不足以让模型学到“运动物体在该时刻的干净纹理”。

更根本的是，N2N 只能告诉模型“另一个噪声观测长什么样”，不能告诉模型“被时域平均抹掉的细节应该是什么”。当运动物体的纹理在输入中已经被噪声淹没、在参考中又被平均掉时，任何只依赖输入的损失都无法恢复它。A5 的失败不是优化问题，而是信息问题。

5.6 A6：冻结运动专家 v1–v4

A6 换了一个思路：保留 A3 主干，冻结全部参数，只训练一个小的门控残差专家：

$$\hat{y} = y_{\mathrm{A3}} + g(x) \odot r(x), \tag{2}$$

其中 $g(x)$ 是运动门控，$r(x)$ 是空间残差。专家只使用空间卷积，不能在时间上平均；门控由运动 mask 监督；静态像素由 A3 教师锚定。A6 还尝试了同帧 10x 动态目标、旧教师蒸馏和程序化局部运动。四版实验见表 6。

表 6: A6 冻结运动专家四版实验。所有版本均未通过推广门槛。

版本	设计	结果与裁决
v1	噪声输入时序特征，100 步	live exact holdout RMSE 79.89→82.94 DN；EMA 79.87 DN；无时序增益。否决。
v2	A3 时序特征 + 纯空间专家, 200 步	EMA 79.68 DN；静态偏移 1.10 DN；门控 IoU 0.533；temporal ratio 0.292258→0.292305。门控能定位运动，但残差没有恢复内容。否决。
v3	10x 精确目标 + 旧教师 645x 蒸馏，200 步	旧教师 holdout 166.54→153.55 DN；10x exact 79.89→84.60 DN；静态偏移 4.78 DN。旧教师行为与低噪声目标冲突。否决。
v4	真实 10x + 程序化局部运动，300 步	程序化 holdout 35.57→35.60 DN；真实 10x 79.89→79.93 DN；时序比略降。单参考平移不能代表真实人体运动。否决。

A6 的结论很重要：门控可以学会定位运动（v2 的 IoU 0.533 证明这一点），但残差分支没有足够监督去判断“应该恢复什么干净动态结构”。旧教师携带的运动纹理与目标域冲突；程序化平移又过于狭窄。A6 解决了全局参数漂移，却没有解决信息缺失。

5.7 A7：旧教师确定性融合的 36 组配置

A7 是最后一条“不训练”的路线：把旧教师的残差限制在运动区域，按置信度融合进 A3。评估帧同样为 $[160, 200)$ 的 40 帧不相交留出：

$$\hat{y} = y_{\mathrm{A3}} + \alpha\, w\, \mathrm{clip}\left(y_{\mathrm{teacher}} - y_{\mathrm{A3}}, \pm c\right), \tag{3}$$

其中 w 是 flow/motion 权重，$\alpha \in \{0.1, 0.2, 0.3, 0.4\}$，$c \in \{32, 64, 96\}$ DN，膨胀半径 $r \in \{3, 7, 11\}$，共 36 组。静态 guard 强制 $w = 0$，因此静态 PSNR、HF、temporal MAD 在所有配置中保持不变，静态非零权重为 0。

最强的配置是 r11/$\alpha = 0.4$/$c = 96$：motion/input ratio 从 0.488790 升到 0.493269，相对提升 0.9162%；运动区平均位移 9.116 DN，P95 位移 38.386 DN；静态位移 mean 1.16×10^{-5} DN，max 2.28×10^{-4} DN；融合覆盖率 2.808%。图 8 给出了人体裁剪的五路对比，图 9 给出了 36 组配置的位移–增益关系。



图 8: A7 人体裁剪对比：A3 基线、旧教师（诊断用）、r3/r7/r11 最强配置。旧教师的纹理更“活”，但带有明显噪声和伪细节；r3/r7/r11 的差异在正常观看尺度下几乎不可辨。

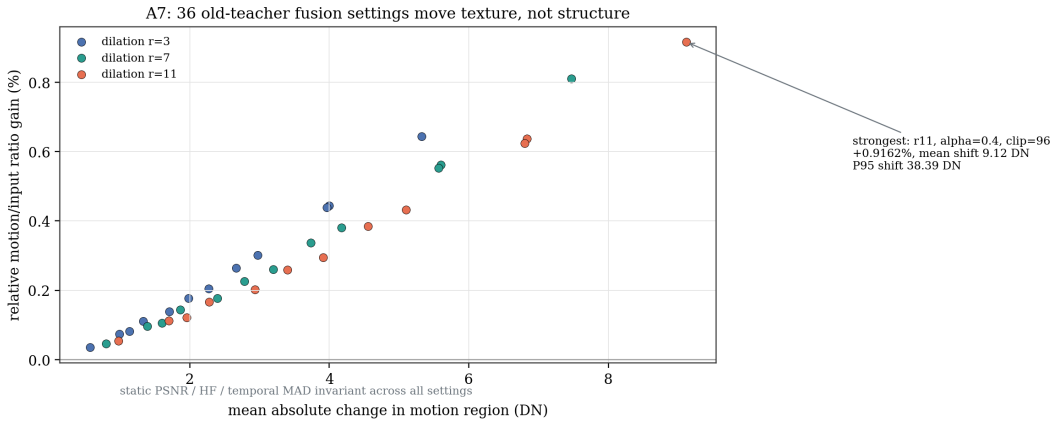


图 9: A7 的 36 组配置：横轴为运动区平均位移，纵轴为 motion/input ratio 相对增益。最强配置也只有 +0.9162%，却带来 9.12 DN 平均位移和 38.39 DNP95 位移；静态指标不变。

固定 ISP 逐帧复核的结论是：在 frames 167–173 上，预览配置和最强配置都没有产生稳定可见的脸、手臂、躯干、短裤、腿或鞋边界改善；旧教师在白衬衫、短裤、四肢和运动边缘上的局部纹理与 A3 明显不同，但没有干净动态目标证明那是恢复的细节还是教师噪声/时序残留；没有出现大的新双影或边缘断裂；r7/r11 只是扩大了旧教师的暴露面积，没有带来相应的清晰度收益。

因此，全部 36 组配置被否决，没有保留任何 A7 可选后处理。这一步确认了一个关键原则：**旧教师不是干净动态真值；扩大融合区域或增加残差强度不能产生不存在的干净信息**。

5.8 A7 真实运动采集方案：一条未能执行的路

A7 还设计了一套真实运动采集协议：4 个训练场景 + 2 个验证场景，每个场景 5 种运动类型（横向行走、纵深行走、快慢手势、遮挡进出、细纹理运动），每段至少 160 帧（最好 200 帧），总计至少 30 段、4800 帧；低增益干净拍摄，后期用 A2 校准噪声合成同帧 noisy 输入；关闭 2DNR/3DNR、自动曝光/增益/白平衡，固定曝光、增益、WB、FPS、光照、焦距和光圈；自动验收门槛包括场景不重叠、每场景 5 种运动、不少于 160 帧、高位对齐、静态噪声 $\leq$8 DN、背景 CV $\leq$1.5%、饱和 $\leq$1%、运动活跃帧比例 $\geq$25%、变化面积 1%–60% 等。

这套协议在科学上是正确的：它把“动态监督”从“猜”变成了“可控采集”。但项目硬约束是不能重新拍摄，因此 A7 采集从未执行。这个未执行项后来成为整个项目最重要的“缺口”：所有动态失败最终都回到“没有可信干净动态真值”这一件事上。

5.9 阶段结论

A5–A7 的连续否决给出了一个清晰结论：运动保真的瓶颈不是“找不到运动区域”，而是“没有可信的干净动态目标”。A5 的 N2N 目标、A6 的冻结专家、A7 的旧教师融合，都只能利用已有的噪声观测或带噪教师，无法凭空恢复被抹掉的内容。A3 因此继续作为唯一基线；A5/A6/A7 不再重复。

6 跨传感器泛化：审计、A8–A10b

6.1 零样本审计协议

在讨论“适配”之前，项目先回答了“A3 在别的传感器上到底怎么样”。A3 跨传感器审计覆盖 8 条序列：SC465SL darkroom18 的 256x/2000x、sc635hai 的 131x 低色温和 16x 运动彩色、sc450ai 的 1435x 黑物运动和 804x 灯光变化、SC465SL difficultpattern 的 4717/8880。每条序列都有显式 manifest，记录宽高、位对齐、CFA、标称黑电平、评估帧数、clip 起点、固定 ISP 白平衡/曝光和面板裁剪；文件名与实测冲突时以像素为准。

静态协议是：每条流测逐通道黑电平；构造初步时域均值；用 median + 3×1.4826×MAD 剔除运动帧；保留在全部、偶数、奇数帧中至少 90% 静态的像素；用偶数帧 8 帧片段对奇数参考评估，再反向评估。输入与目标互斥。A3 保留 8 帧时序输入、64×64 packed tile、56 像素 stride 和 EMA 权重；推理实现从固定 540×960 扩展到任意不小于 64×64 的 native 形状，不改变模型算术。

6.2 审计结果：支持边界并不一致

表 7 给出了静态定量结果。SC465SL 256x 在两个奇偶方向上分别提升 13.211/13.158 dB，HF 保持 0.957/0.958；SC465SL 2000x 提升 10.523/10.613 dB，HF 0.911/0.912；sc635hai 131x 提升 13.588/13.587 dB，HF 0.919/0.921。三组都 legal 100%，temporal MAD 从 20–47 DN 降到 1.3–2.2 DN，说明 A3 在这些静态域上确实有效。

sc450ai 则是另一幅图景：1435x 黑物运动的 HF 只有 0.127，端点裁剪 3.28%，temporal ratio 0.063，运动/静态比 0.057/0.088；视觉上黑色衣物内部结构消失，边界发软发空，墙面有持续低频伪影。804x 灯光变化的 HF 为 0.690，裁剪 1.855%，暗部有低频色斑，运动人物明显发软。SC465SL difficultpattern 的 HF 为 0.635/0.527，主要细节还在，但暗部有低频色斑，不能作为干净细节证据。

表 7: A3 跨传感器零样本静态结果。even 表示偶数帧输入 / 奇数帧参考，odd 反之；HF 为输出/参考高频 RMS 比；Clip 为归一化端点裁剪比例。

序列	输入 PSNR (dB)	A3 PSNR (dB)	增益 (dB)	HF	temporal MAD 输入 →A3 (DN)	Clip
SC465SL 256x even	41.840	55.052	+13.211	0.957	31.889→1.567	0.603%
SC465SL 256x odd	41.840	54.999	+13.158	0.958	31.886→1.578	0.592%
SC465SL 2000x even	46.039	56.563	+10.523	0.911	20.238→1.312	0.083%
SC465SL 2000x odd	46.034	56.647	+10.613	0.912	20.248→1.301	0.079%
sc635hai 131x even	38.737	52.325	+13.588	0.919	47.481→2.165	0.743%
sc635hai 131x odd	38.736	52.324	+13.587	0.921	47.481→2.163	0.725%

图 10 把静态 PSNR 与 HF 保持率放在一起。左图显示 A3 在所有已测静态域上都有 5–14 dB 的提升；右图显示 HF 保持率从 0.856 到 0.971 不等，sc450ai 的 0.127 是明显的断崖。这个断崖不是“去噪更强”，而是“细节被抹掉”。

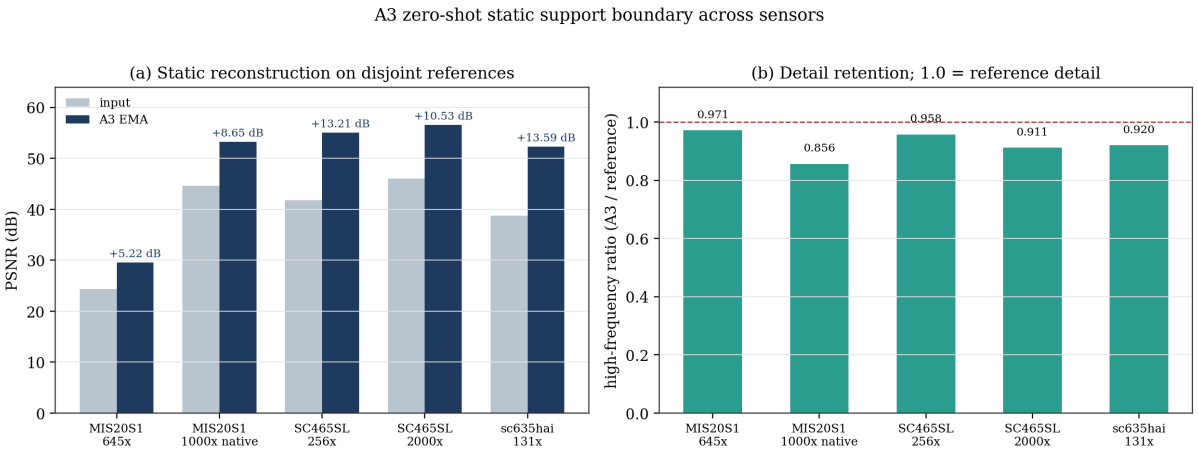


图 10: A3 零样本静态支持边界。(a) 输入与 A3 的 PSNR；(b) A3 的高频保持率，1.0 为参考细节。MIS20S1 与 SC465SL/sc635hai 静态域支持，sc450ai 明显塌陷。

审计的最终裁决是：SC465SL 在已测 darkroom18 256x/2000x 域支持（difficultpattern 仍条件）；sc635hai 静态低色温支持，动态/颜色条件；sc450ai 不支持部署。这个结论直接推动了 A8 的“逐传感器适配”，也提前暴露了一个问题：如果目标传感器的数据本身没有干净监督，适配可能从第一步就走不通。

6.3 A8 数据准入：先证明“能训”，再谈“怎么训”

A8 的第一版计划是对 sc635hai 和 sc450ai 做保守微调。但在动手前，项目先写了一个数据准入 gate：它检查文件存在性、字节推导帧数、源位置、inode 身份、全文件 SHA-256、目标语义，并与冻结的八条审计序列逐项比对；任何被审计使用的流都不能同时作为训练源，任何复制/硬链接/同内容别名都会被拒绝；训练源必须有哈希绑定的监督 manifest、独立目标产物和互斥帧池。

结果是没有一个目标传感器有合规训练源：sc635hai 的两条流都在冻结审计中，sc450ai 的两条流也都在冻结审计中；SC465SL 的 8 条非审计流是已处理显示流，不是干净 RAW。gate 状态为 `blocked_no_compliant_training_source`。这不是 GPU 或实现失败，而是数据资格失败。

项目没有偷偷把审计流拿来训练。直到用户明确授权“数据集可自行合理划分”后，才把 sc635hai 131x 与 sc450ai 804x 重新分类为适配数据，同时保留 sc635hai 16x 与 sc450ai 1435x 作为独立留出。这个治理步骤看似繁琐，但它避免了“用测试集训练、再用测试集报告”的经典错误。

6.4 A8 sc635hai：输出头适配的条件通过

sc635hai 的适配采用最保守的方案：冻结 A3 主干，只训练 `norm`、`conv_after_body`、`conv_last` 三个模块，共 6 个张量、12,400 个参数；500 步，lr 10^{-5}，BF16 autocast，EMA 0.999；sc635hai 131x 奇偶分半静态监督，50% 概率混入 MIS20S1 回放；16x 运动彩色完整保留，不参与反向传播。实际采样为 sc635hai 238 步、MIS20S1 回放 262 步。

静态结果：A3 52.3535/52.3552 dB，A8 52.3875/52.3884 dB，提升约 0.034 dB；HF 从 0.9199 降到 0.9181（−0.0017）；temporal MAD 从 2.1628 降到 2.1247 DN；clip 从 0.00741 降到 0.00644。动态 16x 留出：temporal MAD 14.6745→14.6218 DN，motion ratio 0.599602→0.596438，static ratio 0.101329→0.101169，HF 0.763605→0.763078，legal 1.0，clip 0.021994→0.019344；平均输出偏置从 −2.3691 变为 −2.9808 DN（多负 0.61 DN）。固定 ISP 首/中/末帧未见新增双影、拖影、断边、色偏或静态污染；A8 与 A3 的差异很小，符合“只更新输出头”的预期。

9 项自动安全门槛全部通过：静态 PSNR 不低于 A3−0.10 dB；HF 不恶化 0.02；动态 legal；裁剪受控；动态 HF 受控；运动响应受控；静态闪烁受控；MIS20S1 PSNR 不遗忘；MIS20S1 HF 不遗忘。因此 sc635hai step-500 EMA 被登记为“sc635hai 专用可选权重”，不能替换 A3，也不能宣传为统一模型。

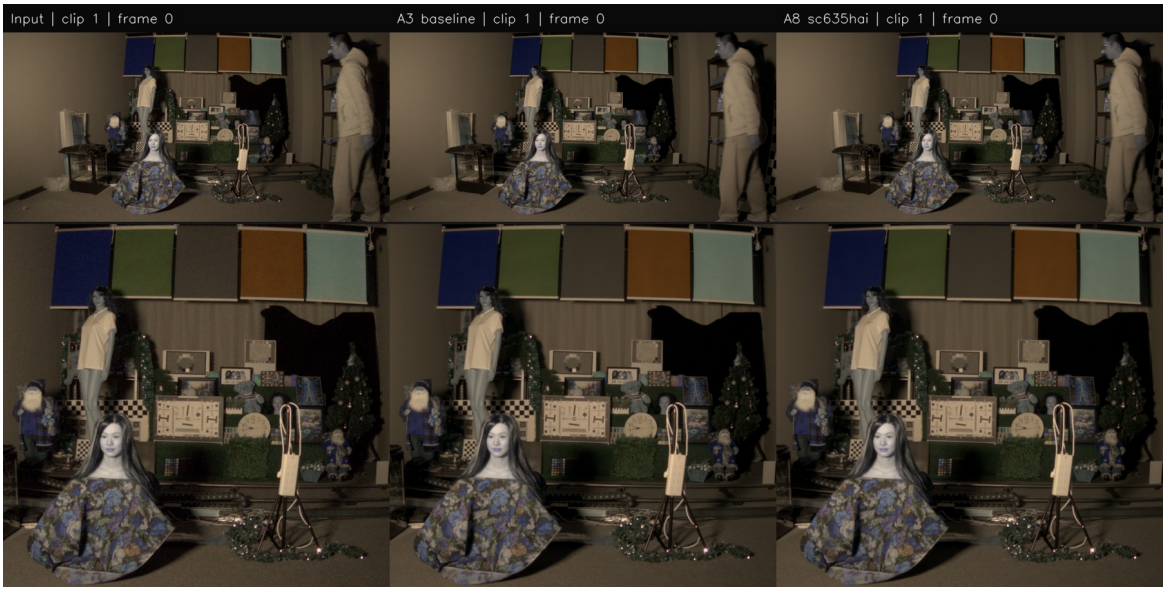


图 11: A8 sc635hai 固定 ISP 对比：Input、A3、A8。A8 只更新 12,400 个输出头参数，视觉差异很小；未见新增重影或颜色异常。

6.5 A8 sc450ai：盲点适配的全部否决

sc450ai 的适配采用单帧盲点自监督：同一帧复制为 8 帧输入，随机选 5% packed 空间位置，在全部时刻与全部通道同时遮挡，遮挡位置用半径 2 的同 CFA packed 通道邻域替换；只在遮挡位置对原始 RAW 计算 Charbonnier 损失。这样模型不能从相邻时刻直接读取目标像素。训练 500 步，仍只更新 6 个张量/12,400 参数，50% MIS20S1 回放。

结果是否决性的。完整 1435x 留出上，A3 的 HF 为 0.126621，step-100/200/300/400/500 分别为 0.126548/0.126429/0.126329/0.126227/0.126079，没有任何 checkpoint 达到 “HF 至少 +0.02” 的门槛；裁剪从 0.032798 升到 0.046436，负偏置从 −4.8287 扩大到 −5.3414 DN。同域 804x 未训练尾段的 HF 从 0.684561 降到 0.681220，裁剪从 0.015772 升到 0.026944。固定 ISP 中，黑衣内部结构仍然空洞、过软，A8 与 A3 几乎相同，只是整体略暗；没有可确认的细节恢复。

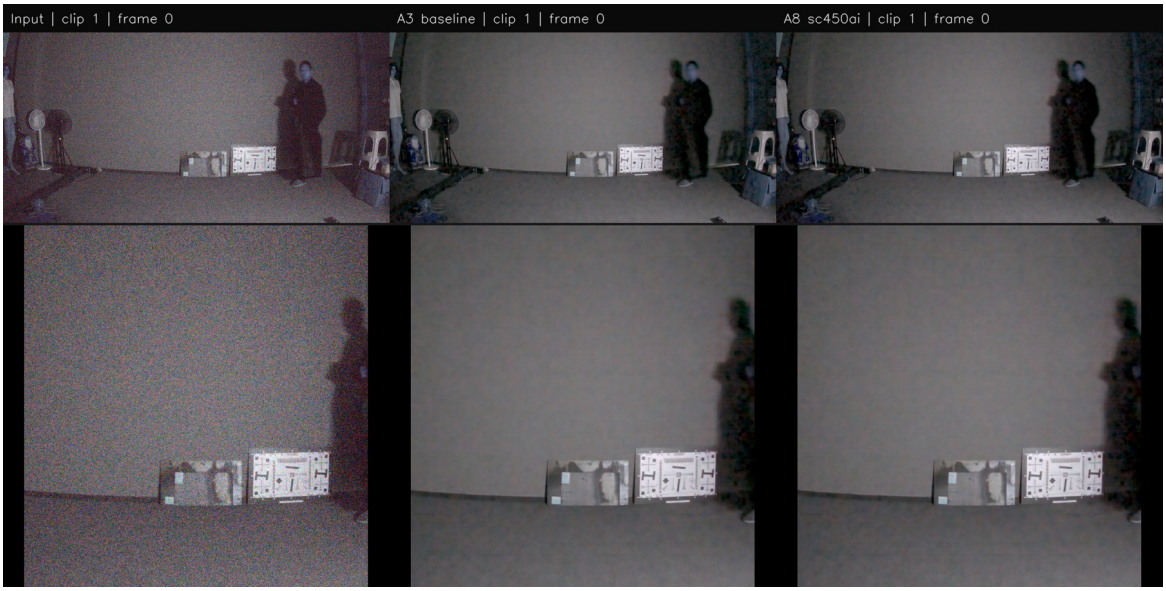


图 12: A8 sc450ai 固定 ISP 对比：Input、A3、A8 step-500。黑色运动物体在 A3 中已经空洞、发软，A8 没有恢复内部结构，反而略向更暗方向偏移。

这一步的教训是：盲点自监督可以学习噪声统计，但不能恢复被模型抹掉的确定性空间结构。sc450ai 的失败不是“训练不够久”，而是“监督里没有空间细节”。A8 因此没有任何可保留的 sc450ai checkpoint。

6.6 A9：统一多传感器小步微调

A9 试图用一个小步数、少参数的统一微调，同时覆盖 MIS20S1、SC465SL、sc635hai 和 sc450ai。配置为：从 A3 step-5000 初始化，只训练 `conv_first`、`norm`、`conv_after_body`、`conv_last`，共 8 个张量、15,508 个参数；100 步，batch 1，64×64 patch，BF16，lr 5×10^{-6}，EMA 0.999；采样比例 MIS20S1 40%、SC465SL 20%、sc635hai 20%、sc450ai 合成噪声 20%。实际样本计数为 39/19/24/18。

结果：SC465SL 2000x 留出 PSNR 56.60490→56.68683（+0.08192 dB），HF 0.9112685→0.9111807；sc635hai 131x 静态尾段 52.35436→52.36445（+0.01009 dB），HF 0.9199258→0.9198020；MIS20S1 回放 PSNR −0.000346 dB，HF +0.001016；sc450ai 1435x 的 HF 0.1266212→0.1265891（−0.0000322），motion ratio 0.0568871→0.0568476，static ratio 0.0879080→0.0882128。四段固定 ISP 视频中，MIS20S1/SC465SL/sc635hai 没有新增伪影，但 sc450ai 的黑衣与运动轮廓仍然中空、过平滑，A9 与 A3 肉眼几乎无差异。

A9 step-100 被否决，且不再继续同方案到 500 步。原因不是“步数不够”，而是 sc450ai 分支只学了经过真实性验证的信号相关噪声幅度；它没有获得 sc450ai 干净空间细节监督，也没有建模空间相关噪声、行列固定模式、PRNU/DSNU、黑电平漂移、光学模糊与 CFA 响应差异。继续训练最多改变去噪强度和裁剪行为，不能凭空恢复监督中不存在的黑衣纹理。

6.7 A10：sc450ai 现有数据到底能支持什么

A10 对 sc450ai 做了一次彻底的监督可行性审计。数据集里实际只有两条 sc450ai RAW 流：804x 灯光变化 150 帧、1435x 黑物运动 210 帧；没有暗场、平场、跨增益配对或独立干净 RAW。两条流都是低位对齐、有效 10 位、uint16 保存；抽样值全部不超过 4095，且 `value % 4 == 0` 占 100%；文件名/readme 的 “高 12 位、黑电平 4128” 与实际数据冲突（按该说明右移 4 位再减 4128 会把数据压成 0，详见 3.2 节），实测黑电平约 256–258 DN。

八帧窗口审计以 4 帧步长检查全部窗口，并用 A9 已验证的噪声方差判断像素变化是否超过 3 倍预期 σ。804x 有 36 个窗口，最佳 0–7，frame-mean CV 0.01265%，平坦稳定像素 95.49%，奇偶分半 RMSE 14.069 DN；1435x 有 51 个窗口，最佳 172–179，CV 0.01329%，平坦稳定 94.84%，分半 RMSE 14.962 DN。两条流的最佳平坦稳定比例都低于 96%，分半不确定度约 14–15 DN，且没有第二条同场景干净序列可验证场景细节。因此 `clean_reference_eligible` 固定为 false：窗口均值、奇偶均值或时域均值都不能当作干净运动真值。

空间噪声结构方面，A10 最初在高通残差上直接算邻域相关，得到约 -0.15；这个结果由 3×3 高通算子自身引入，已被否决并修正。最终方法只用高通做平坦/异常像素筛选，相关性在去除全局偏置后的原始相邻帧差分上计算。每通道水平/垂直相关约 0.015–0.030，训练/验证差异小于 0.05；行、列公共分量 σ 比在互斥范围间约 0.23–0.25。跨通道耦合没有通过：最大训练/验证差异 0.06893，主要来自 Gr/Gb（训练 +0.02914，验证 -0.03980），因此下一版退化模型必须继续使用通道独立 identity。

A10 只登记了一个 `partial_noise_model_only`：信号相关方差可继续使用 A9 噪声模型；每通道空间结构只作为初步信号；跨通道 identity；PRNU/DSNU、sensor blur/MTF、CFA 光谱响应、运动细节真值均无法识别。结论是 `next_model_training_allowed=false`。

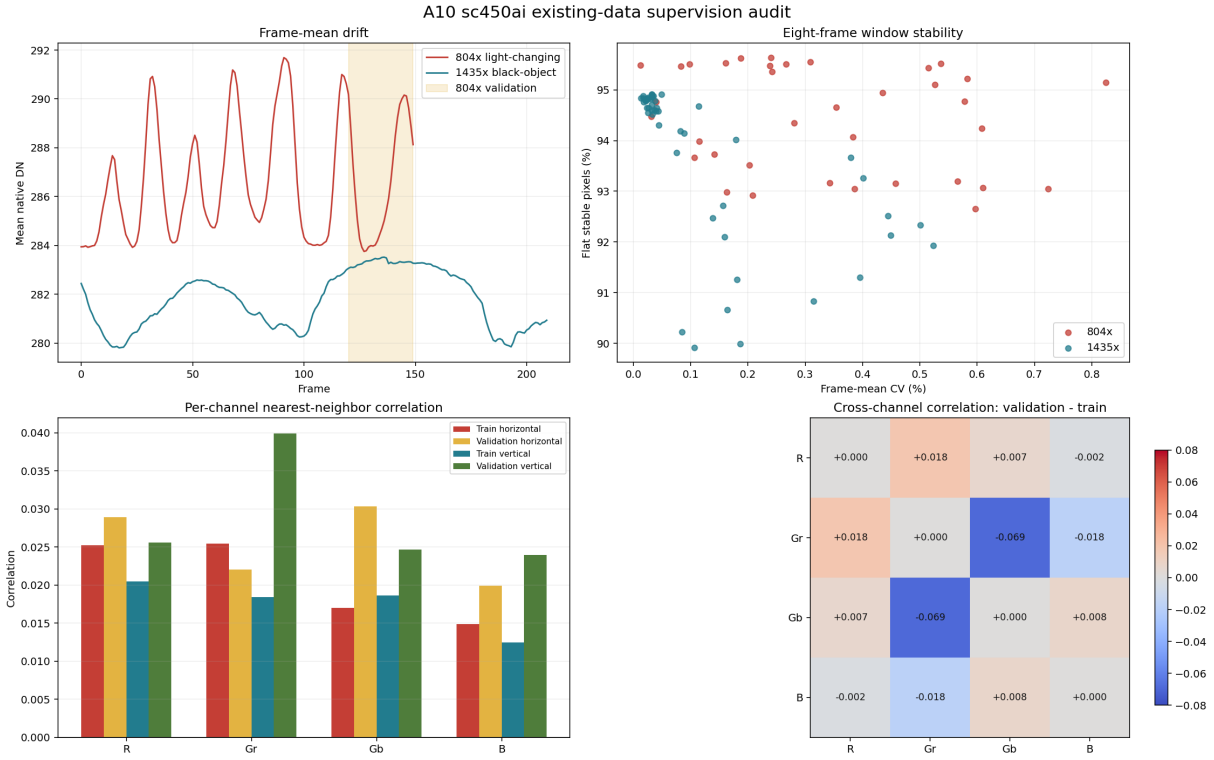


图 13: A10 sc450ai 数据审计。(a) 两条流的帧均值漂移；(b) 八帧窗口稳定性；(c) 每通道最近邻相关；(d) 跨通道相关训练/验证差异。数据只能支持噪声统计，不能支持干净空间监督。

6.8 A10b：退化生成器的独立验证与全部否决

A10b 比较了三个确定性 sc450ai 噪声生成器：A9 legacy 独立高斯（1 DN 量化）、修正为实测 4 DN 格点的独立高斯（Q4 IID）、以及在 Q4 量化基础上增加四通道共享最小水平/垂直频谱整形的 shared spectral Q4。拟合只用 804x 的 $[0, 120)$ 帧，验证用 $[120, 150)$，1435x 的 $[172, 180)$ 是传感器级硬留出。

验证门槛是预注册的：sigma 相对误差、weighted ACF MAE、lag-1 最大误差、逐通道 sigma、以及 8 个独立验证帧对中至少 7 个胜出。shared spectral 在 804x 上把聚合空间相关 RMSE 相对 Q4 IID 降低 36.58%，但：

1. lag-1 最大相关误差 0.015381，超过 0.015 门槛；
2. 8 个独立验证帧对只胜出 6 个，低于 7 个门槛；
3. Gr/Gb/B 的逐通道 sigma 门槛没有全部通过：Gr median 相对误差 0.11111（门槛 0.10），Gr P90 0.25714（门槛 0.25），B median 0.12698（门槛 0.10）；
4. 在 1435x 硬留出上，weighted ACF MAE 0.015773，lag-1 最大误差 0.049863，明显失败；Q4 IID 也失败（ACF 0.01491，lag-1 0.03386）。

表 8: A10b 三个退化生成器的独立验证与硬留出结果。

候选	sigma median	sigma P90	804x weighted ACF MAE	1435x ACF MAE / lag-1
Legacy A9 IID Q1	0.08333	0.11905	0.01319	未通过（Q1 非法）
Q4 IID	0.00000	0.15429	0.01341	0.01491 / 0.03386
A10b shared spectral Q4	0.00000	0.15429	0.00719	0.01577 / 0.04986

A10b 还修正了 A10 的一个测量错误：A10 在 Bayer 打包后先执行 `spatial_sample_stride=4`，再在抽样网格上计算“相邻”相关，因此原指标实际对应 packed lag 4，即传感器坐标 lag 8，不是最近同色像素相关。A10 中大量精确等于 0.25 的行列 σ 比值不能解释成物理行列噪声；在 full packed resolution 重算后，训练/验证区间的行列比值降为 0.0，而仅改变抽样步长就能产生原来的 0.25 平台值。这个现象主要来自量化与中位数估计器。A10 的“每通道空间结构通过”因此只保留为发现弱相关的初步信号，原建议参数不得直接进入生成器。



图 14: A10b 固定 ISP 证据：804x 验证与 1435x 硬留出上的 Real RAW、Proxy（非 GT）、Q4 IID、shared spectral。两个候选肉眼近似，频谱候选没有稳定视觉优势。

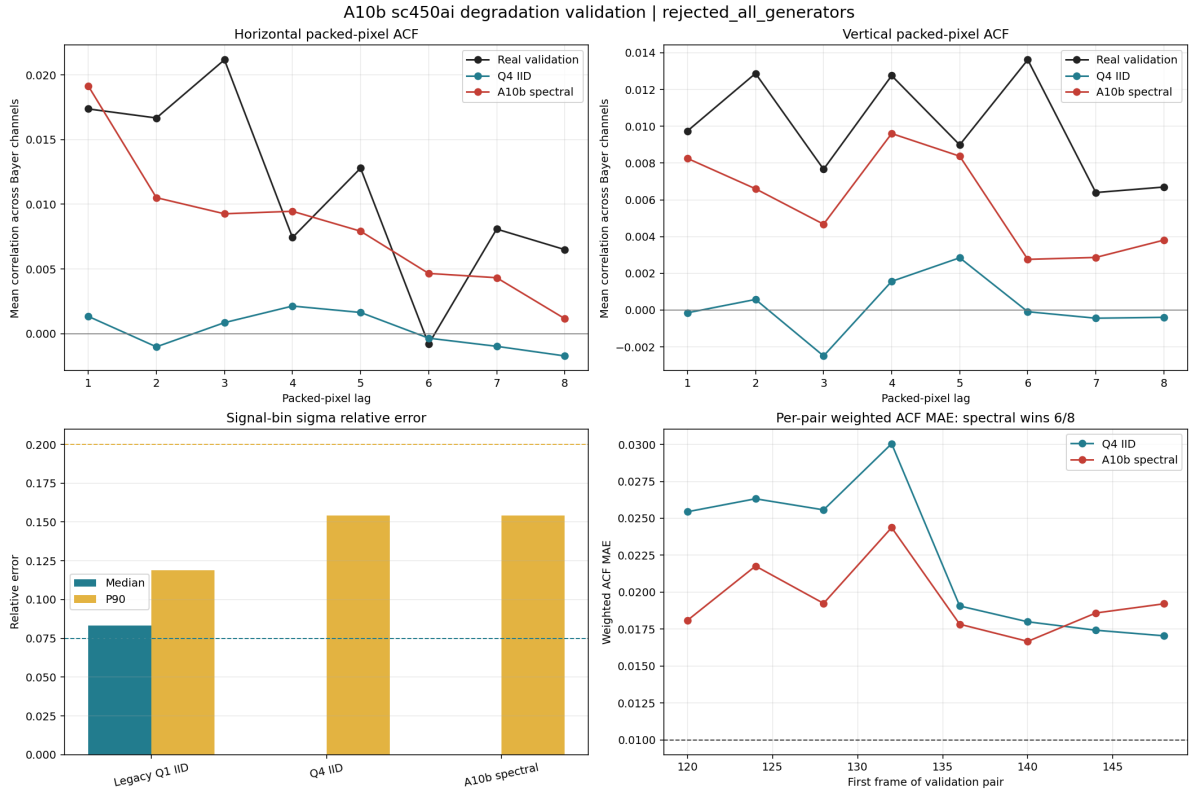


图 15: A10b 统计证据：水平/垂直 ACF、信号分桶 sigma 相对误差、逐帧 ACF MAE。shared spectral 改善了聚合 ACF，但逐通道 sigma、lag-1 与 1435x 硬留出仍失败。

A10b 的最终状态是“否决全部生成器”（`rejected_all_generators`），没有选中的生成器（`selected_generator` 为 `null`），且 `model_training_allowed` 为 `false`。即使未来噪声生成器通过，也不能自动获得训练授权，因为现有数据仍无法识别 sc450ai 的干净空间细节、sensor blur/MTF、CFA 光谱响应、PRNU/DSNU 和动态运动真值。

6.9 阶段结论

跨传感器阶段把“泛化”拆成了三个不同的问题：SC465SL/sc635hai 的静态域可以通过 A3 零样本或极少量输出头适配支持；sc450ai 的失败不是噪声幅度问题，而是空间细节和传感器响应问题；统一多传感器微调不能替代逐传感器的监督审计。最终只保留 sc635hai 的一个 12,400 参数可选输出头，A3 仍是默认基线。

7 高增益动态失效：全数据集预览、四路诊断与 A11

7.1 45 条序列的全数据集预览

在完成跨传感器审计后，项目做了一次“把所有原始流都跑一遍”的全数据集预览：45/45 条原始 RAW 流，使用 A3 EMA step-5000 推理，并为每条流生成 Input 与 A3 的固定 ISP 对比视频。每条流取首、中、尾三个连续 8 帧片段，共 24 帧；视频为 1920×1080、HEVC、yuv444p、6

fps，总计 1080 帧、918,042,365 字节；全部产物约 6.6 GiB。

ISP 设置是：按项目 canonical 通道序做 Bayer 重建；OpenCV edge-aware 去马赛克；开启高光重建；Reinhard tone mapping；**不启用 2DNR/3DNR**；每条序列根据 Input 的 99.5 百分位估计一次曝光，并在 Input/A3 间冻结共享；白平衡使用对应流的固定 WB；色彩模式为 uncalibrated camera RGB。由于没有传感器 ColorMatrix，视频只用于比较降噪、纹理和时序表现，不构成色彩准确性结论。

预览的发现是：MIS20S1 和 sc635hai 的多数场景降噪明显；SC465SL difficultpattern 高增益仍有时域拖影、重影和纹理涂抹；最刺眼的是 MIS20S1 outdoor 1500x 等高总增益序列，人物周围出现共同的朦胧、过平滑和半透明残影。图 16 给出了 1500x 的代表帧：输入彩噪极重，A3 把噪声压下去了，但人物姿态被平均、树木区域蜡化，画面像蒙了一层雾。



图 16: MIS20S1 outdoor 1500x 固定 ISP 对比：左 Input，右 A3 EMA；上半部全景，下半部中心裁剪。A3 显著降噪，但运动人物出现朦胧和姿态平均，说明问题不是噪声残留，而是结构被时域融合抹掉。

这个现象最初被怀疑是视频编码或 ISP 的 2DNR/3DNR 造成。但预览明确关闭了 2DNR/3DNR，且 MP4 使用无损/高质量编码；因此项目决定做一次专门的高增益推理诊断，而不是继续调 ISP 锐化。

7.2 失效模式：时域对齐/融合在低信噪比下失效

诊断的核心假设是：高增益输入超出 A3 的主要训练分布，邻帧对齐/融合在低信噪比和运动下失效。A3 的时域模块会把“错位的运动内容”当成噪声平均掉，导致主体朦胧、重影和过度平滑；空间 tiling 只影响拼接边界，不解释主体朦胧；ISP 只是把 RAW 中已经丢失的结构显示出来，不能恢复它。

为了分离这三个因素，项目设计了四路诊断：Input、A3 uniform（原 64/56 均匀 tiling）、A3 weighted（64/48、Hann、floor 0.05）、A3 frame-repeat（每个目标帧重复 8 次作为模型输入，取 temporal output index 4，并使用 weighted tiling）。前两者比较空间拼接，后两者比较时域融合。代表序列为 `04_mis20s1_outdoor_1500x` 与 `04_shdarkroom_1000x` 的 frames 0–7。

7.3 四路诊断结果

表 9 给出了完整指标。所有结构、高频和时序指标都以 Input 为 1.0；seam amp 是原 64/56 网格处边界/普通邻接差异相对输入的放大倍数，小于 1.0 表示没有放大输入自身的差异。

表 9: 高增益四路诊断指标（Input = 1.0）。

序列	分支	梯度保持	时序均值梯度	低频结构	高频残留	temporal MAD	seam amp	legal
outdoor 1500x	A3 uniform	0.3832	0.6111	0.7931	0.7927	0.0782	1.0147	1.0
outdoor 1500x	A3 weighted	0.3810	0.6076	0.7917	0.7926	0.0779	0.9236	1.0
outdoor 1500x	frame-repeat	0.7579	0.8474	0.9515	0.9139	0.5513	0.9831	1.0
shdarkroom 1000x	A3 uniform	0.3800	0.6303	0.8257	0.8038	0.0725	1.1415	1.0
shdarkroom 1000x	A3 weighted	0.3788	0.6285	0.8254	0.8022	0.0722	1.0655	1.0
shdarkroom 1000x	frame-repeat	0.8551	0.9074	0.9732	0.8943	0.6936	1.0008	1.0

图 17 是 outdoor 1500x 的四路细节裁剪。A3 uniform 与 weighted 都把人物姿态平均成半透明；frame-repeat 恢复了当前帧的姿态和树枝结构，但暗部彩噪明显回流。图 18 把两段序列的梯度保持、低频结构和 temporal MAD 放在一起，差异非常清楚。



图 17: outdoor 1500x 四路细节：Input、A3 uniform 64/56、A3 weighted 64/48、A3 frame-repeat。frame-repeat 恢复姿态与树枝，但彩噪显著；uniform/weighted 的朦胧几乎相同。

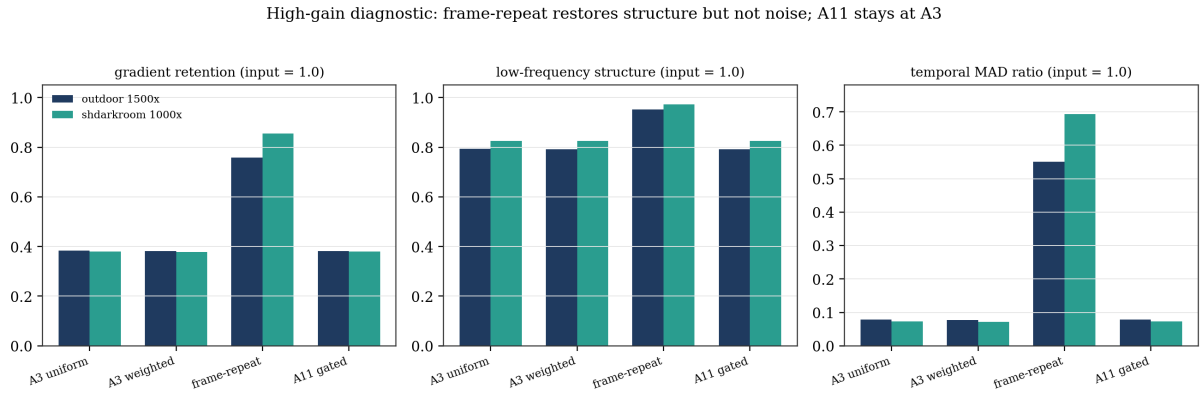


图 18: 高增益诊断指标：梯度保持、低频结构、temporal MAD。frame-repeat 把结构恢复到 0.95–0.97，但 temporal MAD 升到 0.55–0.69；A11 与 A3 weighted 几乎重合。

结果可以归纳为四点：

1. **空间拼接不是主因**。uniform 与 weighted 的结构/时序指标几乎相同（梯度 0.3832 vs. 0.3810，temporal MAD 0.0782 vs. 0.0779）；weighted 只在原 64/56 网格上把 seam amp 从 1.0147 降到 0.9236、从 1.1415 降到 1.0655，属于小幅、稳定的空间改善，但不能修复主体朦胧。

2. **时域融合是主因**。A3 uniform 的 temporal MAD 只有输入的 7.2%–7.8%，说明真实时域变化被强烈压制；frame-repeat 把低频结构恢复到 95.2%–97.3%，把 temporal MAD 恢复到 55.1%–69.4%，证明“跨帧融合”是清晰度损失的主要来源。

3. **frame-repeat 不是默认方案**。它的高频残留升到 89.4%–91.4%，固定 ISP 面板可见明显彩噪；它恢复的是“当前帧的结构”，代价是把高增益噪声也带回来。

4. **两个分支互补**。正常时域 A3 去噪强但会把错位运动平均掉；frame-repeat 细节强但噪声大；两者来自同一个 checkpoint，不需要旧教师或新训练。这直接构成了 A11 的设计依据。

7.4 A11：输入证据驱动的置信门控

A11 的目标不是“再训练一个模型”，而是在同一个 A3 checkpoint 的两个推理分支之间做保守、连续、边界平滑的 RAW 融合。A11 的后处理与 ISP 渲染均为 CPU-only，未加载模型，也未使用旧教师或动态时域均值：

$$\hat{y} = (1 - w) \cdot y_{\text{A3,weighted}} + w \cdot y_{\text{A3,frame-repeat}}, \tag{4}$$

其中 $w \in [0, 0.65]$ 只依赖 noisy input 的可观测证据。

置信证据由四部分组成：

1. **时域残差**：对 Bayer 绿通道亮度做轻度低通，在原始高频局部噪声标尺下计算鲁棒时域残差，并用 smoothstep 映射为 0–1 分数。

2. **梯度一致性**：计算梯度幅值与方向；幅值不一致和方向余弦共同构成 gradient disagreement，再乘以结构强度，避免在平坦区误触发。

3. **光流匹配可靠度**：使用前后 gap=2 的双向 DIS 光流 [11]，计算 forward-backward error、warp photometric error 和 flow magnitude；可靠运动与遮挡/错位分别进入 matched motion 与 mismatch 两项。

4. **空间后处理**：对 seed 做小连通域过滤（最小面积 48）、3 像素椭圆膨胀、Gaussian feather（$\sigma = 2.0$）；高置信静态 core 强制 $w = 0$；最大权重 0.65。

完整参数为：temporal_gap 2；residual z 2.5–6.0；gradient 0.18–0.60；structure 0.002–0.012；flow 0.75–2.50 px；FB 0.75–2.50 px；photometric 4.0–10.0 z；seed threshold 0.45；min component area 48；dilation 3；feather 2.0；max weight full 0.65。三种结构消融只用于验证证据链：residual_only、residual_gradient、full；最终候选固定为 full。项目明确没有做 alpha/clip/阈值网格扫描。

A11 还记录了一次预检修正：未平滑的高增益像素残差会被局部噪声标尺压成稀疏孤点，全部被连通域过滤。最终实现只做了一次结构性修正：在低通亮度上计算结构残差、梯度和匹配光度误差，同时保留原始高频估计作为噪声标尺；配置阈值和最大融合权重没有因此扫描或逐序列调整。

7.5 A11 结果：保守、干净，但覆盖不足

A11 在两条代表序列 frames 0–7 上生成五路固定 ISP 视频（Input、A3 uniform、A3 weighted、frame-repeat、A11 gated），并输出 overview/detail 与逐帧 PNG。表 10 给出 mask 覆盖与区域时序比，表 11 给出全局结构指标。

表 10: A11 mask 覆盖与区域时序比。

序列	配置	$w > 0$	$w \geq 0.5$	weight mean	motion temporal/input	static temporal/input
outdoor	residual only	0.4870%	0.0000%	0.000762	0.6215	0.0878
outdoor	residual + gradient	0.4527%	0.0000%	0.000889	0.6346	0.0878
outdoor	full	0.4869%	0.0951%	0.001271	0.6780	0.0878
shdarkroom	residual only	0.6760%	0.0000%	0.000969	0.6180	0.0642
shdarkroom	residual + gradient	0.5587%	0.0000%	0.001003	0.6263	0.0642
shdarkroom	full	0.7126%	0.1325%	0.001751	0.6850	0.0642

表 11: A11 全局结构指标（Input = 1.0）。

序列	分支	梯度保持	低频结构	高频残留	temporal MAD
outdoor 1500x	A3 weighted	0.3810	0.7917	0.7926	0.0779
outdoor 1500x	frame-repeat	0.7579	0.9515	0.9139	0.5513
outdoor 1500x	A11 full	0.3820	0.7919	0.7927	0.0787
shdarkroom 1000x	A3 weighted	0.3788	0.8254	0.8022	0.0722
shdarkroom 1000x	frame-repeat	0.8551	0.9732	0.8943	0.6936
shdarkroom 1000x	A11 full	0.3800	0.8256	0.8024	0.0732

A11 的全局指标几乎等于 A3 weighted：outdoor 梯度 0.3820 vs. 0.3810，低频 0.7919 vs. 0.7917，temporal MAD 0.0787 vs. 0.0779；shdarkroom 0.3800 vs. 0.3788，0.8256 vs. 0.8254，0.0732 vs. 0.0722。这证明噪声和静态背景保护得很好，但也说明门控覆盖不足以改变主要朦胧失效模式。

静态保护是严格的：outdoor 的 motion core 为 0.1475%，static core 为 20.5559%，static nonzero weight 为 0，静态 shift 为 0；shdarkroom 为 0.1945%、39.0139%、0、0。边界指标：outdoor boundary fraction 0.2249%，A11/A3 boundary gradient 1.0081，shift-gradient mean 0.000366、P99 0.002720；shdarkroom 0.3521%、1.0046、0.000370、0.002905。没有发现 halo、断裂、明显锐度台阶或 tile seam 回归。

但是，固定 ISP 逐帧检查显示：outdoor frames 0–7 的 mask 持续命中人物腿、脚、手或少数局部边缘，主体躯干、头部及大面积重影/朦胧区域多数未被覆盖；A11 在少数四肢像素上略向 frame-repeat 靠近，但 A3 weighted 与 A11 在 overview/detail 中没有稳定、明确的轮廓改善。shdarkroom 的 mask 命中人物局部轮廓、风扇/小物体边缘等稀疏区域，人物主体、标定板、钟表和复杂小物体的整体朦胧没有得到可信修复；A11 与 A3 weighted 的画面差异非常小，无法在每帧或连续视频中稳定辨认出重影减少。

图 19 是 outdoor 第 4 帧的五路细节，右下是 A11 权重热图。可以看到权重几乎只落在手臂/边缘的几个小斑块上，躯干和大面积重影区没有权重。图 20 把覆盖率和全局指标画在一起：覆盖率低于 0.72%，全局输出几乎与 A3 重合。



图 19: A11 outdoor 1500x 第 4 帧的五路细节：Input、A3 uniform、A3 weighted、frame-repeat、A11 gated，右下为 A11 权重热图。权重只覆盖手臂/边缘的稀疏区域，躯干与大面积朦胧区未被覆盖。

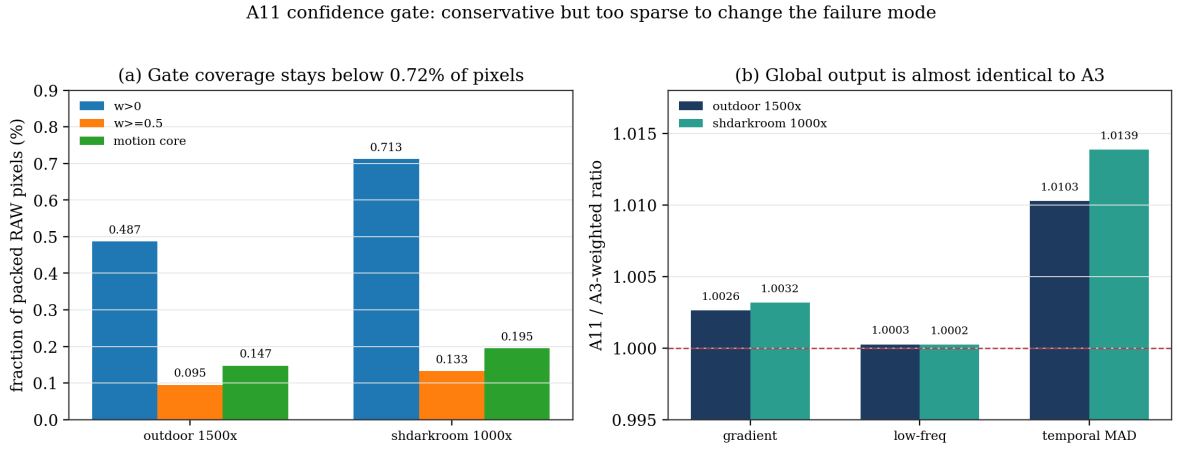


图 20: A11 覆盖率与全局指标。(a) $w > 0$ 覆盖 0.487%/0.713%，$w \geq 0.5$ 仅 0.095%/0.133%；(b) A11 与 A3 weighted 的全局梯度/低频/temporal MAD 比值接近 1。

7.6 A11 的逐项裁决

A11 的通过条件在实验前就已预注册。表 12 给出逐项结果。

表 12: A11 通过条件与逐项裁决。

条件	结果	说明
两条序列均有可重复运动边缘/重影改善	失败	局部极小，主体与主要重影未改善
噪声明显低于纯 frame-repeat	通过	高频残留接近 A3 weighted，未大面积回流
高置信静态区与 A3 基本一致	通过	static nonzero 与 shift 均为零
mask 边界无突变/halo/锐度台阶	通过	指标和逐帧检查均无异常
legal RAW fraction 为 1.0	通过	两条序列均为 1.0
无旧教师纹理、伪细节或新闪烁	通过	未使用旧教师，未见新增闪烁
指标和 fixed-ISP 肉眼结论一致	未达到	指标近零变化，视觉也无可信改善

由于第一项和第七项失败，A11a 被整体否决。它不能登记为“可选高增益后处理”，不能进入 A11b，也不能替换 A3。

7.7 为什么 A11 失败：覆盖与证据的悖论

A11 的失败不是实现错误，而是一个结构性悖论：

1. **保守证据只能覆盖很小的区域**。完整规则的 $w > 0$ 覆盖 0.49%/0.71%，$w \geq 0.5$ 只有 0.10%/0.13%，motion core 只有 0.15%/0.19%。这些区域主要是四肢、手、脚和少数边缘，而主体躯干、头部和大面积重影区没有足够强的输入证据。
2. **降低阈值会把门控变成新的标量扫描**。如果为了覆盖主体而降低 residual/gradient/flow 阈值，就会把噪声和静态纹理引入 mask；这既违反预注册，也会重蹈 A5/A7 的覆辙。
3. **frame-repeat 分支本身噪声太大**。门控只能在“A3 的朦胧”和“frame-repeat 的彩噪”之间选择，不能创造第三种“既干净又清晰”的结果。要得到后者，需要新的监督或新的生成模型，而不是更好的 mask。
4. **没有干净动态 GT 来验证“主体改善”**。即使把 mask 扩大到主体，也无法证明引入的是真实细节还是 frame-repeat 的噪声；固定 ISP 视觉复核仍然是最终裁决，而当前视觉没有可信改善。

这与 A5–A7 的结论完全一致：当监督/证据中不存在干净动态信息时，推理端的门控只能做保守选择，不能凭空恢复。A11 是这一结论在“后处理”层面的最后一次验证。

7.8 阶段结论

高增益动态问题仍未解决。A3 在低/中增益静态域可靠，但在高增益动态场景中，时域对齐/融合会把运动平均掉；frame-repeat 能恢复结构但噪声不可接受；A11 的置信门控太稀疏，无法改变主体失效模式。下一步若继续，应该是高增益条件化微调或新的动态数据，而不是继续调 mask 阈值。

8 综合讨论

8.1 已经建立的能力

尽管大量路线被否决，项目仍然建立了四项可复用的能力：

1. **A3 静态基线**：在 MIS20S1 645x 跨增益上 29.57 dB（输入 24.35 dB），native 1000x 53.27 dB（输入 44.62 dB），并通过奇偶分半验证。A3 是当前唯一默认模型。
2. **可信监督管线**：A1 的 10x 时域均值、A2 的 Poisson-Gaussian+FPN 噪声模型、A0 的逐源适配/配准/运动 mask，构成了可复现的监督基础。
3. **多证据评测协议**：分离增益/场景/奇偶帧池；同时报告 PSNR/RMSE、HF、temporal MAD、flat residual、legal RAW、固定 ISP 视频；硬留出从不调参。
4. **传感器支持边界**：SC465SL 静态支持；sc635hai 静态条件支持且保留一个 12,400 参数可选输出头；sc450ai 不支持；MIS20S1 高增益动态未解决。

8.2 失败模式分类

把失败路线放在一起看，可以发现它们并不是“同一个模型反复失败”，而是四种不同性质的失败（表 13）。

表 13: 失败模式分类。

类型	代表实验	根因	正确应对
评价协议失败	A4 1000x 跨捕获	不同照明的线性曝光拟合失效；配准不是根因	换 native 参考，不修模型
监督目标失败	A5/A6/A7；A8 sc450ai；A9 sc450ai	N2N/旧教师/盲点都不能提供干净动态或空间细节	停止同类扫描，转数据/监督问题
数据资格失败	A10；A10b；A7 采集	没有暗场/平场/配对/干净 GT；退化生成器跨拍摄不迁移	明确“当前数据不足以训练”
推理后处理失败	A11	输入证据只覆盖 <0.72% 像素；frame-repeat 噪声太大	不继续调阈值；转条件化训练/新数据

值得注意的是，“模型容量不足”并不是任何一次失败的主因。A6 的门控 IoU 达到 0.533，说明网络有能力定位运动；A9 的 15,508 参数也足以改变输出；真正缺的是“告诉模型该恢复什么”的监督。这是本项目最重要的科学判断。

8.3 方法论反思

回顾整个项目，有五条方法论教训值得记录：

1. **预注册门槛**。A5 的 promotion gate、A8 的 9 项安全检查、A10b 的 7/8 帧对门槛、A11 的 7 项通过条件，都在实验前写死。这样即使结果“差一点”，也不能事后改门槛。

2. **硬留出与互斥帧池**。sc450ai 1435x、MIS20S1 1000x、SC465SL difficultpattern、A5 的 $[160, 200)$ 都从未参与训练或调参。A8 的数据 gate 甚至拒绝了“把审计流拿来训练”的诱惑。

3. **固定 ISP 与关闭 2DNR/3DNR**。RAW 指标好不代表画面好；ISP 的时域/空域处理会掩盖或放大模型问题。所有对比视频共享完全相同的 ISP 参数，且关闭 2DNR/3DNR。

4. **指标陷阱**。PSNR 在错误域上会误导（A4 1000x）；HF 比降低可能是去噪也可能是细节塌陷；motion/input ratio 提升可能是噪声回流；legal RAW 只说明数值范围；单个 crop 不能代表全图。项目最终要求“指标 + 固定 ISP 逐帧”双重证据。

5. **负结果与自我修正**。A1 的 1.2533/1.4826 估计器错误、A10 的 stride=4 空间相关伪影、A11 的高增益残差稀疏化，都是项目自己发现并纠正的。把这些错误写进报告，比只展示成功数字更有价值。

8.4 核心科学判断：缺少可信动态/空间真值

项目的所有失败最终指向同一个瓶颈：缺少可信的干净动态/空间真值。

- 静态时域均值在静态区域可信，在动态区域有重影；不能作为动态 GT。
- 旧教师有运动行为，但带噪、带伪纹理、与目标域不一致；不能作为干净 GT。
- Noise2Noise 的 later-frame warp 是另一个噪声观测，不是干净真值；只能做目标构造探针。
- 盲点自监督可以学噪声统计，但不能恢复已经被抹掉的确定性结构。
- 噪声退化模型可以匹配幅度/相关性，但不能创造干净空间细节、blur/MTF 或 CFA 响应。

这也解释了为什么 A5–A7、A8 sc450ai、A9、A10b、A11 会连续失败：它们都在用不同方式试图“从现有噪声观测里挤出干净信息”，而信息本身不存在。要继续推进，必须引入新的数据或新的监督假设，而不是继续换模型/调阈值。

8.5 局限性

本报告的结论有以下局限：

1. **场景多样性不足**：可信静态 GT 主要来自 MIS20S1 shdarkroom 一个场景；模型可能学到“暗房先验”。

2. **传感器覆盖有限**：SC465SL、sc635hai、sc450ai 各只有少量序列；支持矩阵只对已测域成立，不能外推到所有增益/场景。

3. **没有动态 GT**：所有动态结论都是无参考诊断 + 固定 ISP 视觉，不是有监督质量评估。

4. **不能重新拍摄**：A7 的真实运动采集协议未执行，这是最大的数据缺口。

5. **固定 ISP 不是色彩校准**：没有传感器 ColorMatrix，视频不能用于色彩准确性结论；序列间绝对亮度也不可直接比较。

8.6 后续工作建议

基于当前证据，后续工作应按优先级考虑：

1. **采集可信动态数据**：按 A7 协议执行 4+2 场景、5 种运动、30 段/4800 帧的低增益干净拍摄；用 A2 校准噪声合成同帧 noisy 输入；训练/验证场景严格分离。这是解决运动保真和高增益动态的最直接路径。

2. **完善传感器退化模型**：在 A10b 基础上加入空间相关噪声、行列固定模式、PRNU/DSNU、sensor blur/MTF、CFA 光谱响应和黑电平漂移；但必须先有独立平场/暗场/配对数据，不能只用 1435x 反向拟合。

3. **高增益条件化微调**：在 A3 基础上加入增益/噪声条件 embedding，冻结大部分主干，只训练 adapter/输出头；静态区用可信均值监督，动态区用保守一致性约束；保持 A3 为不可覆盖基线。

4. **测试时自适应/自监督**：如果确实无法采集，可研究 test-time adaptation 或遮挡自监督；但必须证明它不会把噪声当细节，且在硬留出上通过。

5. **评测基准化**：把本项目的分离增益/场景/奇偶协议、固定 ISP 和硬留出固化成 benchmark，避免后续工作重复踩坑。

6. **部署打包**：默认 A3；sc635hai 可选输出头；sc450ai 明确不支持；高增益动态标注为“未解决”，不要用 A11 或 frame-repeat 冒充默认输出。

8.7 小结

回看整个过程，有四次判断转折，它们构成了这份报告真正的“心路”。

第一次转折发生在 A4。我们最初把 1000x 的 18.84 dB 当成模型失败，甚至准备修改训练；但配准检查、曝光分桶和原生参考探针一步步证明，失败的是“1000x 到 10x 的跨捕获曝光拟合”，不是 A3。用 1000x 自身 200 帧构造原生参考后，同一个 checkpoint 达到 53.27 dB。那一刻我们意识到：**评价域本身是模型的一部分**。如果不先把“我们在哪个域上比较”说清楚，后面的所有数字都可能是错的。

第二次转折发生在 A5–A7。我们试过动态 N2N、教师锚定、冻结运动专家、旧教师融合，几乎把“不引入新数据”能想到的组合都做了一遍。每一次都有一点点运动指标提升，但每一次都伴随静态、HF、native 或时序的回退。最后我们不得不承认：**不是模型不会定位运动，而是监督里没有“运动物体在该时刻的干净纹理”**。继续调权重只会在 trade-off 上移动，不会创造信息。

第三次转折发生在 A8–A10b。我们原以为“逐传感器适配”只是换一批数据再训几百步；A8 的数据 gate 却先告诉我们，目标传感器的流都在冻结审计里，根本没有合规训练源。用户授权重划后，sc635hai 的输出头适配条件通过，sc450ai 的盲点适配却全线失败；A9 的统一微调也没有救回 sc450ai；A10/A10b 进一步证明，现有 sc450ai 数据连可信的干净空间监督和跨拍摄退化模型都不支持。我们这才把“泛化”拆成“哪些域支持、哪些域不支持、为什么不支持”，而不是笼统地说“模型泛化不好”。

第四次转折发生在 A11。四路诊断已经证明高增益朦胧的主因是时域融合，frame-repeat 能恢复结构但噪声大；我们以为一个保守的置信门控可以把两者的优点结合起来。结果门控只覆盖不到 0.72% 的像素，主体朦胧区根本没有权重。A11 的失败让我们确认：**推理端的 mask 只能在已有信息之间做选择，不能创造缺失的干净细节**。这与 A5–A7 的结论是同一个事实在不同层面的表现。

所以，Stage2 的故事不是一个“模型越训越好”的故事，而是一个“逐步确认哪些事情不能做”的故事。A3 证明了静态去噪可以被可信监督解决；A5–A11 证明了运动、高增益和 sc450ai 空间细节不能被现有数据/监督解决。这个结论本身是有价值的：它把后续研究从“继续调模型”引导到“先解决数据与监督”。

9 结论

本报告完整记录了 Stage2 RAW 视频去噪项目从 A0 到 A11 的研究历程。主要结论如下：

1. **RQ1（静态基线）成立**。在可信的 10x 时域均值监督、实测噪声模型和运动/饱和掩码下，RViDeformer-L 可以适应公司 MIS20S1 数据。A3 step-5000 在 645x 跨增益上达到 29.57 dB（输入 24.35 dB），在 native 1000x 上达到 53.27 dB（输入 44.62 dB），并通过奇偶分半验证。A3 是唯一默认基线。

2. **RQ2（运动保真）不成立**。A3 在运动区只保留输入的 27%–32% 帧差；A5 的 N2N/教师锚定、A6 的冻结运动专家、A7 的 36 组旧教师融合都没有通过“运动提升 + 静态/native 不回退”的联合门槛。根因是缺少干净动态真值，不是运动定位能力。

3. **RQ3（跨传感器）部分成立**。SC465SL 在已测静态域支持（+13.21/+10.52 dB）；sc635hai 静态低色温条件支持（+13.59 dB），仅保留一个 12,400 参数输出头；sc450ai 不支持（HF 0.127、裁剪 3.28%）。A9 的统一多传感器微调没有解决 sc450ai；A10/A10b 证明现有 sc450ai 数据不具备训练级监督。

4. **RQ4（高增益动态）不成立**。45 条序列预览发现共同的高增益朦胧/重影；四路诊断证明主因是时域对齐/融合，而不是 tiling 或 ISP；A11 的置信门控覆盖低于 0.72% 像素，无法改变主体失效模式。高增益动态仍未解决。

最终的支持矩阵见表 14。项目没有达到“一个模型在所有传感器、增益、静态/动态条件下都可靠”的最终目标；但它给出了一个可信的静态基线、一套可复现的评测协议，以及一份明确的失败清单。这些负结果与 A3 的正结果一起，构成了后续工作的起点。

表 14: 最终模型与传感器支持矩阵。

对象	状态	允许用途	禁止事项
A3 step-5000	默认基线	MIS20S1 静态、已支持域、所有对比基准	不得覆盖/替换
A8 sc635hai step-500	条件保留	sc635hai 专用可选推理	不得宣传为统一模型
A8 sc450ai checkpoints	全部否决	仅历史审计	不得部署/继续盲点扫描
A9 step-100	统一模型否决	仅历史审计	不得继续同方案到 500 步
A5/A6/A7	全部否决	仅历史审计	不得原样复用
A11	全部否决	仅历史审计	不得作为高增益默认输出

表 15: 传感器/条件支持状态。

传感器/条件	状态	主要风险
MIS20S1 低/中增益静态	支持（A3）	动态仍需检查
MIS20S1 高增益动态	未解决	朦胧、重影、过度平滑
SC465SL 已测静态域	支持	不能外推到所有动态/高增益
sc635hai 静态低色温	支持/条件支持	动态和颜色域仍有风险
sc450ai	不支持	高频塌陷、黑物体发空、裁剪、监督不足
difficultpattern	条件压力测试	不能代表完整传感器支持

数据与代码可用性

项目根目录为 `/Data4/Xiao/RECOVERED_Stage2_DenoiseModel_20261010`。A3 checkpoint 的 SHA-256 为 `97c4332f...592e0b`,在全部后续实验中未被覆盖。数据集目录 `/HardDisk/jingzeliang/Data/Company_Dataset/dataset` 全程只读。所有新增代码、配置、产物均位于项目目录内。关键报告、评估 JSON、固定 ISP 视频与图像见附录 A/B。

参考文献

[1] H. Yue, C. Cao, L. Liao, R. Chu, and J. Yang. Supervised Raw Video Denoising With a Benchmark Dataset on Dynamic Scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2301–2310, 2020.

[2] H. Yue, C. Cao, L. Liao, and J. Yang. RViDeformer: Efficient Raw Video Denoising Transformer With a Larger Benchmark Dataset. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(9):8929–8944, 2025. DOI: 10.1109/TCSVT.2025.3553160.

[3] J. Liang, Y. Fan, X. Xiang, R. Ranjan, E. Ilg, S. Green, J. Cao, K. Zhang, R. Timofte, and L. Van Gool. Recurrent Video Restoration Transformer with Guided Deformable Attention. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[4] J. Lehtinen, J. Munkberg, J. Hasselgren, S. Laine, T. Karras, M. Aittala, and T. Aila. Noise2Noise: Learning Image Restoration without Clean Data. In *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 80:2965–2974, 2018.

[5] A. Krull, T.-O. Buchholz, and F. Jug. Noise2Void – Learning Denoising from Single Noisy Images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2129–2137, 2019.

[6] J. Batson and L. Royer. Noise2Self: Blind Denoising by Self-Supervision. In *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 97:524–533, 2019.

[7] A. Foi, M. Trimeche, V. Katkovnik, and K. Egiazarian. Practical Poissonian-Gaussian Noise Modeling and Fitting for Single-Image Raw-Data. *IEEE Transactions on Image Processing*, 17(10):1737–1754, 2008.

[8] T. Brooks, B. Mildenhall, J. T. Barron, J. Chen, D. Sharlet, and R. Ng. Unprocessing Images for Learned Raw Denoising. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11036–11045, 2019.

[9] C. Godard, K. Matzen, and M. Uyttendaele. Deep Burst Denoising. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.

[10] S. W. Hasinoff, D. Sharlet, R. Geiss, A. Adams, J. T. Barron, F. Kainz, J. Chen, and M. Levoy. Burst Photography for High Dynamic Range and Low-Light Imaging on Mobile Cameras. *ACM Transactions on Graphics*, 35(6):192, 2016.

[11] T. Kroeger, R. Timofte, D. Dai, and L. Van Gool. Fast Optical Flow Using Dense Inverse Search. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 471–488, 2016.

[12] E. Reinhard, M. Stark, P. Shirley, and J. Ferwerda. Photographic Tone Reproduction for Digital Images. *ACM Transactions on Graphics*, 21(3):267–276, 2002.

[13] P. Charbonnier, L. Blanc-Feraud, G. Aubert, and M. Barlaud. Two Deterministic Half-Quadratic Regularization Algorithms for Computed Imaging. In *Proceedings of the IEEE International Conference on Image Processing (ICIP)*, vol. 2, pp. 168–172, 1994.

[14] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.

[15] D. Maggioni, E. Sanchez-Monge, and A. Foi. Efficient Multi-Stage Video Denoising With Recurrent Spatio-Temporal Fusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[16] M. Tassano, J. Delon, and T. Veit. FastDVDNet: Towards Real-Time Deep Video Denoising Without Flow Estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[17] B. Mildenhall, J. T. Barron, J. Chen, D. Sharlet, R. Ng, and R. Carroll. Burst Denoising with Kernel Prediction Networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.

[18] A. Buades, B. Coll, and J.-M. Morel. A Non-Local Algorithm for Image Denoising. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2005.

[19] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian. Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering. *IEEE Transactions on Image Processing*, 16(8):2080–2095, 2007.

[20] S. Guo, Z. Yan, K. Zhang, L. Zhang, and W. Zuo. Toward Convolutional Blind Denoising of Real Photographs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

A 实验索引

表 16: Stage2 实验索引。

阶段	日期	核心问题	关键结果	裁决
A0	09-20	数据适配与 manifest	33 流、15 运动 mask、50/50 单元	完成
A1	09-20/21	干净参考	分半 σ 0.51–0.80 DN；图卡 HF 2.97×	通过
A2	09-21/22	噪声模型与合成	最大逐通道误差 8.66%	通过
A3	09-21/22	RViDeformer 微调	645x 29.57 dB；native 1000x 53.27 dB	基线
A4	09-22	增益留出评估	1000x 跨捕获假失败；native 修复	A3 接受
A5	09-24–10-01	动态监督	9 组候选全部失败	否决
A6	10-07–10-09	冻结运动专家	v1–v4 全部失败	否决
A7	10-09–10-11	旧教师融合	36 组全部否决	否决
审计	10-12–10-13	跨传感器零样本	SC465SL/sc635hai 支持；sc450ai 不支持	边界确定
A8	10-13–10-14	逐传感器适配	sc635hai 条件通过；sc450ai 全否决	条 件/否决
A9	10-16	统一多传感器	sc450ai HF 未恢复	否决
A10	10-16	sc450ai 监督审计	0 暗场/平场/配对；不可训练	阻断
A10b	10-16	退化生成器	3 个候选全部失败	否决
预览	10-17	45 条全数据	高增益共同朦胧	发现失效
诊断	10-18	四路高增益	时域融合为主因	机理解释
A11	10-19	置信门控	覆盖 <0.72%，无可见改善	否决

B 关键产物与复现入口

项目使用 Python 3.12 环境：

```
/home/jingzeliang/miniconda3/envs/aaa_312/bin/python
```

关键产物根目录（每个路径单独一行）：

A1/A2 监督 `artifacts/finetune_mis20s1/supervision/`

`artifacts/finetune_mis20s1/noise_model/`

A3 checkpoint `artifacts/finetune_mis20s1/training/checkpoint_step_005000.pth`

A4/native 评估 `artifacts/finetune_mis20s1/evaluation/`

A5/A6/A7 评估 `artifacts/finetune_mis20s1/evaluation/a5_*`

artifacts/finetune_mis20s1/evaluation/a6_*

artifacts/finetune_mis20s1/evaluation/a7_*

跨传感器审计 artifacts/a3_cross_sensor_zero_shot_20261012/

artifacts/a3_cross_sensor_extension_20261012/

A8/A9/A10/A10b artifacts/a8_sensor_adaptation/

artifacts/a9_multi_sensor_generalization/

artifacts/a10_sc450ai_supervision_audit_20261016/

artifacts/a10b_sc450ai_degradation_validation_20261016/

全数据预览/高增益/A11 artifacts/a3_all_dataset_traditional_isp_preview_20261017/

artifacts/a3_high_gain_diagnostic_20261018/

artifacts/a11_high_gain_confidence_gate_20261019/

代表性复现命令（从项目根目录执行）：

```
python scripts/run_a4_eval.py --max-frames 200 \
  --tile-batch 8 --output-dir artifacts/finetune_mis20s1/evaluation
python scripts/run_native_1000x_eval.py --max-frames 200 \
  --tile-batch 8 --output-dir artifacts/finetune_mis20s1/evaluation/native_1000x
python scripts/evaluate_a3_cross_sensor.py \
  --config configs/a3_cross_sensor_zero_shot_20261012.json \
  --output-dir artifacts/a3_cross_sensor_zero_shot_20261012 \
  --phase all --device cuda:0 --tile-batch 2
python scripts/run_a8_sensor_adaptation.py \
  --config configs/a8_sc635hai_adaptation_20261013.json
A9_OUT=artifacts/a9_multi_sensor_generalization/training_smoke_4090_retry2_20261016
python scripts/run_a9_generalization.py --output-dir "$A9_OUT" \
  --device cuda:0
python scripts/run_a11_high_gain_confidence_gate.py
python -m pytest -q src/tests
```

说明：命令中的路径与参数以项目当前脚本为准；GPU 运行前必须先 `nvidia-smi` 确认空闲卡，且不得终止其他用户进程。A3 checkpoint 的 SHA-256 为 `97c4332f...592e0b`，复现前后应校验。

C 术语表

RAW 传感器原始数据，未经过 ISP 去马赛克/降噪/色调映射。

DN Digital Number，RAW 像素数值单位。

CFA Color Filter Array，Bayer 彩色滤波阵列；本项目主要为 RGGB，标定流为 GRBG。

PSNR Peak Signal-to-Noise Ratio，峰值信噪比，单位 dB。

RMSE Root Mean Square Error，均方根误差，单位 DN。

HF ratio 高频保持率，输出高频 RMS 与参考高频 RMS 之比；接近 1 表示细节保留。

temporal MAD 帧间平均绝对差，衡量时域稳定性；过低表示过度平均，过高表示闪烁/噪声。

legal RAW 输出是否落在合法 RAW 数值范围内；只说明范围，不说明画质。

FPN Fixed Pattern Noise，固定图样噪声，包括 DSNU 与 PRNU。

N2N Noise2Noise，用另一噪声观测作为目标的无干净真值监督。

N2V/N2S Noise2Void/Noise2Self，盲点自监督。

Hard holdout 硬留出，完全不参与训练、调参和阈值选择。

Disjoint parity 奇偶帧分半，输入与参考来自互斥帧池。

motion/input ratio 运动区输出帧差与输入帧差之比；只作诊断，不作通过依据。